

UNIWERSYTET RZESZOWSKI
Wydział Nauk Ścisłych i Technicznych



Dawid Olko
nr albumu: 125148
Kierunek: Informatyka

System rekomendacji produktów oparty na filtracji współpracy, analizie sentymentu i regułach asocjacyjnych

Praca inżynierska

Praca wykonana pod kierunkiem
dr inż. Piotra Grochowskiego

Rzeszów, 2026

Spis treści

Wstęp	4
Kontekst i motywacja	4
Cel pracy	4
Zakres pracy	4
Rozdział 1: Teoretyczne podstawy systemów rekomendacyjnych	6
1.1 Historia i ewolucja systemów rekomendacyjnych	6
1.2 Klasyfikacja metod rekomendacyjnych	6
1.3 Matematyczne fundamenty algorytmów	7
Rozdział 2: Weryfikacja i analiza rozwiązań alternatywnych	9
2.1 Amazon Personalize	9
2.2 Google Recommendations AI (Vertex AI)	10
2.3 Apache Mahout	10
2.4 Podsumowanie analizy i uzasadnienie własnego rozwiązania	11
Rozdział 3: Opis projektu planowanej aplikacji	14
3.1 Cel i zakres aplikacji	14
3.2 Wymagania funkcjonalne systemu	14
3.3 Diagram przypadków użycia	16
3.4 Architektura funkcjonalna systemu	18
3.5 Kluczowe scenariusze użycia	19
3.6 Podsumowanie opisu projektu	21
Rozdział 4: Przedstawienie wykorzystanego stosu technologicznego oraz praktycznej realizacji projektu	22
4.1 Architektura systemu	22
4.2 Stos technologiczny backendu	22
4.3 Stos technologiczny frontendu	24
4.4 Baza danych PostgreSQL	25
4.5 Deployment i konteneryzacja Docker	29
4.6 Podsumowanie stosu technologicznego	30
Rozdział 5: Implementacja algorytmów rekomendacji	31
5.1 Collaborative Filtering - Item-Based z Adjusted Cosine	31
5.2 Analiza Sentymentu - wieloźródłowa agregacja	35
5.3 Algorytm Apriori - reguły asocjacyjne	38
5.4 Podsumowanie implementacji	42

Rozdział 6: Funkcjonowanie systemu rekomendacji w praktyce	44
6.1 Architektura i przepływ danych	44
6.2 Konfiguracja metod rekomendacji w panelu administratora	45
6.3 Metoda Collaborative Filtering - Item-Based	46
6.4 Metoda analizy sentymentu	49
6.5 Metoda reguł asocjacyjnych (Apriori)	52
6.6 Mechanizmy optymalizacji systemu	55
6.7 Podsumowanie funkcjonowania systemu	55
Rozdział 7: Podsumowanie i wnioski końcowe	57
Ograniczenia systemu	57
Kierunki dalszego rozwoju	57
Wnioski końcowe	58
Literatura	59
Wykaz rysunków	60
Streszczenie	61

Wstęp

Kontekst i motywacja

Nowoczesne platformy e-commerce oferują tysiące lub dziesiątki tysięcy produktów, co stanowi istotne wyzwanie zarówno dla klientów, jak i właścicieli sklepów internetowych. Użytkownik poszukujący smartfona staje przed wyborem setek modeli, w przypadku laptopów sytuacja wygląda podobnie. Bez wsparcia inteligentnych systemów rekomendacyjnych proces zakupowy staje się czasochłonny i frustrujący, co często prowadzi do rezygnacji z zakupu. Z perspektywy biznesowej oznacza to utratę potencjalnych klientów oraz sytuacje, w których nabywcy nie odkrywają produktów optymalnie dopasowanych do ich potrzeb.

Systemy rekomendacyjne stanowią rozwiązanie tego problemu poprzez automatyczną analizę historii zakupów, opinii oraz zachowań użytkowników w celu proponowania produktów o najwyższej wartości dla konkretnego klienta.

Cel pracy

Celem niniejszej pracy jest zaprojektowanie, implementacja oraz analiza kompletnego systemu e-commerce wyposażonego w autorskie mechanizmy rekomendacji produktów. Aplikacja została opracowana od podstaw jako autorskie rozwiązanie wykonane we współpracy dwuosobowej. W ramach systemu zaimplementowano łącznie sześć różnych metod rekomendacyjnych — trzech z nich dotyczy ta praca. Ich założeniem jest zapewnienie komplementarnych mechanizmów wsparcia decyzji zakupowych. Niniejsza praca koncentruje się na trzech spośród nich: Collaborative Filtering, analizie sentymetu oraz regułach asocjacyjnych. Mechanizmy rekomendacyjne zostały zaprojektowane i zaimplementowane samodzielnie na podstawie literatury naukowej, bez wykorzystania gotowych bibliotek rekomendacyjnych, co umożliwiło pełną kontrolę nad logiką algorytmów oraz ich świadome dostosowanie do specyfiki branży handlu elektronicznego.

Zakres pracy

Zakres funkcjonalny systemu obejmuje:

Implementację trzech metod rekomendacyjnych:

- Collaborative Filtering w wariantie Item-Based z metryką Adjusted Cosine Similarity [8] — metoda analizuje wzorce zakupowe użytkowników w celu identyfikacji produktów podobnych do wcześniej nabytych,

- Analizę sentymentu opartą na podejściu słownikowym [5] — metoda agreguje ocenę jakości produktu z pięciu źródeł tekstowych (opinie, opis, nazwa, specyfikacje, kategorie), rozwiązuje problem zimnego startu dla produktów bez historii opinii,
- Reguły asocjacyjne wykorzystujące algorytm Apriori [1] — metoda odkrywa wzorce współwystępowania produktów w koszyku zakupowym, wspierając strategie cross-sellingu.

Opracowanie kompletnej aplikacji webowej:

- Backend oparty na Django REST Framework zapewniający API dla wszystkich funkcjonalności systemu,
- Frontend w technologii React 18 oferujący responsywny interfejs użytkownika,
- Baza danych PostgreSQL z odpowiednio zaprojektowanym schematem przechowującym dane produktów, użytkowników, zamówień oraz wyniki algorytmów rekomendacyjnych.

Rozdział 1

Teoretyczne podstawy systemów rekomendacyjnych

1.1 Historia i ewolucja systemów rekomendacyjnych

Systemy rekomendacyjne powstały jako odpowiedź na problem wyboru spośród tysięcy produktów w sklepach internetowych. Rozwój tej dziedziny rozpoczął się w latach 90. XX wieku wraz z pojawieniem się pierwszych platform e-commerce. Wczesne zastosowania komercyjne systemów rekomendacji zostały opisane w literaturze specjalistycznej [4]. Istotnym przełomem była również publikacja wprowadzająca metodę Item-Based Collaborative Filtering z metryką Adjusted Cosine Similarity [8], która stała się standardem przemysłowym. Konkursy i inicjatywy badawcze, takie jak Netflix Prize w latach 2006-2009, w którym fundusz nagród wynosił milion dolarów, znacząco przyspieszyły rozwój zaawansowanych technik rekomendacji [2], przyciągając uwagę zarówno środowiska akademickiego, jak i przemysłowego. Obecnie systemy rekomendacyjne stanowią kluczowy element wiodących platform e-commerce (handlu elektronicznego) oraz serwisów VOD (Video on Demand - wideo na żądanie).

1.2 Klasyfikacja metod rekomendacyjnych

Istnieją trzy główne kategorie systemów rekomendacyjnych:

Collaborative Filtering — jedna z najpopularniejszych metod w systemach komercyjnych. Zakłada, że użytkownicy o podobnych preferencjach będą mieli podobne wybory w przyszłości. Istnieją dwa warianty: oparty na użytkownikach (User-Based, porównuje użytkowników) oraz oparty na produktach (Item-Based, porównuje produkty). Zalety: odkrywa nieoczywiste powiązania między produktami. Wady: problem zimnego startu (ang. cold start) dla nowych użytkowników i produktów, macierz danych jest rzadka (0.1-1% wypełnienia).

Content-Based Filtering — analizuje cechy produktów i dopasowuje je do profilu użytkownika. Zalety: brak problemu zimnego startu dla nowych produktów. Wady: rekomenduje tylko podobne produkty, co może prowadzić do zjawiska tzw. filter bubble (bańki filtrującej).

Metody Hybrydowe — łączą różne podejścia rekomendacyjne w celu wykorzystania zalet poszczególnych metod oraz kompensacji ich wad. Przykładem może być połączenie Collaborative Filtering z analizą metadanych produktów oraz analizą treści tekstowych.

Systemy rekomendacyjne w e-commerce wykorzystują różne strategie sprzedawcze. Poniżej znajdują się kluczowe terminy stosowane w branży:

Cross-selling (sprzedaż krzyżowa) — strategia polegająca na proponowaniu produktów komplementarnych, czyli dopełniających zakup główny. Przykład: klient kupuje laptop, system proponuje mysz, torbę na laptop, podkładkę pod mysz. Celem jest zwiększenie wartości koszyka poprzez dodanie produktów powiązanych funkcjonalnie.

Up-selling (sprzedaż wyższej wartości) — strategia zachęcania klienta do zakupu droższego wariantu produktu lub wersji premium. Przykład: klient przegląda telefon za 2000 zł, system proponuje model za 2500 zł z lepszymi parametrami. Celem jest zwiększenie wartości pojedynczego zakupu, przy czym skuteczność tej strategii zależy od indywidualnych preferencji i możliwości finansowych użytkownika.

Personalizacja — dostosowanie treści i rekomendacji do indywidualnego profilu użytkownika na podstawie jego historii zakupów, przeglądanych produktów i zachowań. Przykład: dwóch użytkowników widzi różne zestawy produktów na stronie głównej. Celem jest zwiększenie trafności rekomendacji i konwersji.

Cold start problem (problem zimnego startu) — sytuacja występująca gdy nowy użytkownik lub produkt nie ma historii interakcji. Przykład: nowy użytkownik nie ma zamówień, więc Collaborative Filtering nie może efektywnie generować rekomendacji. Nowy produkt nie ma opinii, co utrudnia ocenę jego jakości. Rozwiązaniem tego problemu może być wykorzystanie metod opartych na analizie treści produktu, takich jak analiza sentymentu opisów, nazw i specyfikacji technicznych.

Frequently Bought Together (często kupowane razem) — rodzaj rekomendacji prezentujący produkty, które klienci regularnie kupują w tym samym koszyku. Przykład: laptop + mysz + podkładka pod mysz. Celem jest uproszczenie procesu zakupów i zwiększenie wartości koszyka.

1.3 Matematyczne fundamenty algorytmów

Matematyczne podstawy trzech implementowanych algorytmów stanowią fundament dla szczegółowych opisów w kolejnych rozdziałach.

Adjusted Cosine Similarity dla Item-Based Collaborative Filtering (Sarwar et al. 2001) [8] stanowi kluczową metrykę podobieństwa wykorzystywaną w systemie. Wzór ten oblicza podobieństwo między dwoma produktami i i j poprzez analizę wzorców ich współwystępowania w zakupach użytkowników:

$$\text{sim}(i, j) = \frac{\sum_{u \in U} (R_{u,i} - \bar{R}_u)(R_{u,j} - \bar{R}_u)}{\sqrt{\sum_{u \in U} (R_{u,i} - \bar{R}_u)^2} \cdot \sqrt{\sum_{u \in U} (R_{u,j} - \bar{R}_u)^2}} \quad (1)$$

gdzie $R_{u,i}$ to ilość zakupu użytkownika u dla produktu i , \bar{R}_u to średnia użytkownika u , a U to użytkownicy, którzy kupili oba produkty. Centrowanie średniej ($R_{u,i} - \bar{R}_u$) eliminuje bias czyli wartość progową dla użytkowników kupujących systematycznie więcej.

Analiza sentymentu (Liu 2012) [5] używa formuły polarności tekstu:

$$S(text) = \frac{N_{pos} - N_{neg}}{N_{total}} \quad (2)$$

gdzie N_{pos} to liczba słów pozytywnych, N_{neg} negatywnych, N_{total} to wszystkie słowa. Wynik: $[-1, 1]$ (dodatnie = pozytywny, ujemne = negatywny).

Reguły asocjacyjne (Agrawal & Srikant 1994) [1] używają trzech metryk:

Wsparcie (Support) (Agrawal & Srikant 1994) [1] - jaka jest częstość współwystępowania:

$$\text{Support}(A, B) = \frac{\text{transakcje z } A \text{ i } B}{\text{wszystkie transakcje}} \quad (3)$$

Pewność (Confidence) (Agrawal & Srikant 1994) [1] - jakie jest prawdopodobieństwo warunkowe:

$$\text{Confidence}(A \rightarrow B) = \frac{\text{Support}(A, B)}{\text{Support}(A)} \quad (4)$$

Wzrost (Lift) (Agrawal & Srikant 1994) [1] - ile razy bardziej jest prawdopodobny zakup:

$$\text{Lift}(A \rightarrow B) = \frac{\text{Support}(A, B)}{\text{Support}(A) \cdot \text{Support}(B)} \quad (5)$$

$\text{Wzrost(Lift)} > 1$: pozytywna korelacja, $\text{Wzrost} = 1$: niezależność, $\text{Wzrost} < 1$: negatywna korelacja. Algorytm Apriori przyspiesza obliczenia dzięki własności: jeśli zbiór nie spełnia minimalnego wsparcia (Support), jego nadzbiór też nie.

Rozdział 2

Weryfikacja i analiza rozwiązań alternatywnych

W celu uzasadnienia sensowności tworzenia dedykowanego systemu rekommendacji przeprowadzono analizę trzech reprezentatywnych rozwiązań rynkowych. Celem weryfikacji było zidentyfikowanie ograniczeń istniejących narzędzi oraz określenie wymagań dla planowanej aplikacji e-commerce wykorzystującej trzy metody: Collaborative Filtering [8], analizę sentymentu [5] oraz reguły asocjacyjne [1].

2.1 Amazon Personalize

Amazon Personalize to zarządzana usługa AWS oferująca systemy rekommendacji oparte na algorytmach stosowanych w Amazon.com [4]. System wykorzystuje deep learning (głębokie uczenie - wielowarstwowe sieci neuronowe) oraz collaborative filtering, oferując trzy typy rekommendacji: User Personalization (personalizacja użytkownika), Similar Items (podobne produkty) oraz Personalized Ranking (personalizowane rankowanie).

Kluczowe ograniczenia w kontekście planowanego rozwiązania:

- **Wysokie koszty operacyjne** - rozwiązania chmurowe wiążą się z regularnymi opłatami licencyjnymi, które mogą być znaczące dla małych i średnich platform e-commerce. Dla porównania, własna implementacja eliminuje te koszty przy zachowaniu kontroli nad funkcjonalnościami,
- **Brak natywnej analizy sentymentu** - Amazon Personalize koncentruje się wyłącznie na collaborative filtering i nie oferuje analizy opinii produktów. Wieloźródłowa agregacja sentymentu (opinie + opis + nazwa + specyfikacje + kategorie) zastosowana w niniejszej pracy wymaga integracji z dodatkowymi usługami AWS lub samodzielnej implementacji,
- **Vendor lock-in** (uzależnienie od dostawcy) - głęboka integracja z ekosystemem AWS (S3, Lambda, EventBridge) oznacza, że migracja do innej platformy wymaga przepisania całej architektury systemu,
- **Brak kontroli nad algorytmami** - system działa jako „czarna skrzynka” (black box), uniemożliwiając dostosowanie logiki rekommendacji. Przykład: niemożliwe jest zaimplementowanie Adjusted Cosine Similarity z centrowaniem średniej dla eliminacji wartości progowej (bias) wynikającej z różnych skal zakupowych użytkowników (hurtownik vs konsument indywidualny),

- **Wymóg dużych zbiorów danych** - według dokumentacji AWS, system wymaga minimum 25000 interakcji dla zapewnienia wysokiej jakości rekommendacji. Dla nowych platform (cold start - problem zimnego startu) jakość jest ograniczona w początkowym okresie działania.

2.2 Google Recommendations AI (Vertex AI)

Google Recommendations AI to platforma GCP wykorzystująca deep learning oraz multi-armed contextual bandits (wieloramienne bandyty kontekstowe - algorytmy balansujące eksplorację nowych opcji z wykorzystaniem sprawdzonych rozwiązań). System oferuje zaawansowane rekommendacje dla e-commerce, VOD (Video on Demand - wideo na żądanie) oraz platform newsowych, z automatycznym wykrywaniem trendów i sezonowości.

Kluczowe ograniczenia w kontekście planowanego rozwiązania:

- **Bardzo wysokie koszty operacyjne** - koszty usług GCP są często wyższe niż konkurencyjnych rozwiązań chmurowych, co czyni je nieopłacalnymi dla małych i średnich platform e-commerce,
- **Brak wieloźródłowej agregacji sentymetu** - Google Recommendations AI oferuje funkcję "Frequently Bought Together" (często kupowane razem, podobną do algorytmu Apriori), ale nie wspiera agregacji sentymetu z wielu źródeł tekstowych jak w planowanym systemie,
- **Wymóg bardzo dużych zbiorów danych** - rozwiązanie zaprojektowane dla platform o skali YouTube, co czyni je nadmiarowo złożonym dla małych sklepów internetowych,
- **Brak interpretowalności** - głęboka „black box”, gdzie nawet administratorzy z dostępem do Vertex AI nie mogą zobaczyć wag embeddings (reprezentacji wektorowych) ani logiki sieci neuronowej, co uniemożliwia debugowanie i optymalizację.

2.3 Apache Mahout

Apache Mahout to open-source framework (otwartoźródłowy framework) implementujący klasyczne algorytmy collaborative filtering [8] oraz matrix factorization (faktoryzacja macierzy - technika dekompozycji macierzy user-item) - ALS (Alternating Least Squares - metoda najmniejszych kwadratów na przemian), SVD (Singular Value Decomposition - rozkład według wartości osobliwych). Projekt powstał w 2008 roku, obecnie koncentruje się na Spark-based distributed algorithms (algorytmy rozproszone oparte na Apache Spark).

Kluczowe ograniczenia w kontekście planowanego rozwiązania:

- **Wymóg zaawansowanej wiedzy technicznej** - konieczność konfiguracji klastra Apache Spark (środowisko przetwarzania rozproszonego), YARN resource manager (zarządcza zasobów), oraz monitoringu. Według Stack Overflow Developer Survey 2023, bardzo mała część programistów ma doświadczenie z Apache Spark,
- **Koszty infrastruktury** - utrzymanie klastra Spark wymaga dedykowanych zasobów serwerowych oraz czasu na implementację integracji (REST API, baza danych, cache, frontend), co generuje znaczące koszty operacyjne,
- **Brak analizy sentymentu** - Apache Mahout nie oferuje sentiment analysis. Wymagana jest integracja z zewnętrznymi bibliotekami (np. Stanford CoreNLP) lub samodzielna implementacja słownikowej analizy sentymentu,
- **Wolniejszy rozwój projektu** - aktywność projektu spadła w ostatnich latach (2-3 commity miesięcznie w 2023-2024 vs 20-30 commitów w latach 2012-2014), co skutkuje ograniczoną dokumentacją dla nowszych wersji.

2.4 Podsumowanie analizy i uzasadnienie własnego rozwiązania

Analiza rozwiązań alternatywnych ujawniła fundamentalny kompromis: **zaawansowanie technologiczne vs koszty i elastyczność**. Rozwiązania chmurowe od Amazona oraz Google oferują wysoką jakość rekomendacji dzięki algorytmom deep learning, ale wiążą się z wysokimi kosztami operacyjnymi, vendor lock-in (uzależnieniem od dostawcy) oraz brakiem kontroli nad algorytmami. Apache Mahout eliminuje koszty licencyjne, ale wymaga zaawansowanej wiedzy technicznej oraz kosztownej infrastruktury Spark.

Uzasadnienie sensowności własnego rozwiązania:

- **Integracja trzech komplementarnych metod w jednym systemie:**

Żadne z analizowanych rozwiązań nie oferuje natywnej integracji Collaborative Filtering + Sentiment Analysis + Apriori:

- Amazon Personalize: tylko Collaborative Filtering, wymagane dodatkowe usługi dla Sentiment Analysis i Apriori,
- Google Recommendations AI: Collaborative Filtering + funkcja podobna do Apriori, brak analizy sentymentu,

- Apache Mahout: tylko Collaborative Filtering, brak Sentiment Analysis i Apriori w najnowszej wersji.

- **Optymalizacja kosztów dla małych i średnich platform:**

Własna implementacja (Django + PostgreSQL) eliminuje koszty licencyjne rozwiązań chmurowych przy zachowaniu wysokiej jakości rekomendacji. System jest szczególnie atrakcyjny dla małych i średnich platform e-commerce (do 10000 produktów, do 10000 użytkowników), które potrzebują zaawansowanych funkcjonalności rekomendacji przy ograniczonym budżecie.

- **Kontrola nad logiką biznesową i możliwość dostosowania:**

Własna implementacja umożliwia unikalne podejścia niedostępne w gotowych rozwiązaniach:

- **Wieloźródłowa agregacja sentymantu** [5] z 5 źródeł tekstowych - rozwiązuje problem cold start (zimny start): produkty bez opinii użytkowników otrzymują wynik sentymantu na podstawie opisu, nazwy i specyfikacji,
- **Bitmap pruning** [9] dla algorytmu Apriori - optymalizacja przyspiesza generowanie reguł asocjacyjnych względem implementacji naiwnej poprzez operacje bitowe,
- **Adjusted Cosine Similarity** [8] z centrowaniem średniej - eliminacja wartości progowej (bias) wynikającej z różnych skal zakupowych użytkowników. Centrowanie średniej usuwa ten efekt skali przy obliczaniu podobieństwa.

- **Elastyczność technologiczna i brak vendor lock-in:**

Aplikacja oparta na Django + React + PostgreSQL może być wdrożona na dowolnej platformie: AWS, GCP, Azure, własne serwery lub localhost. Migracja między platformami wymaga jedynie zmiany parametrów połączenia - logika rekomendacji pozostaje niezmieniona.

Dla porównania: migracja z Amazon Personalize do Google Recommendations AI wymaga przepisania całej integracji (śledzenie zdarzeń (event tracking), dane treningowe, wywołania API) oraz retrainingu modeli, co może trwać tygodnie i powodować degradację jakości rekomendacji.

Podsumowanie:

Własna implementacja systemu rekomendacji stanowi optymalny wybór dla małych i średnich platform e-commerce, łączący:

- Wysoką jakość rekomendacji (trzy komplementarne metody: Collaborative Filtering, Sentiment Analysis, Apriori),
- Pełną kontrolę nad algorytmami i możliwość dostosowania do specyfiki biznesowej,
- Niskie koszty operacyjne (brak opłat licencyjnych rozwiązań chmurowych),
- Interpretowalność wyników i możliwość debugowania,
- Elastyczność technologiczną (brak uzależnienia od konkretnego dostawcy chmury).

Rozwiązanie jest szczególnie atrakcyjne dla platform potrzebujących zaawansowanych funkcjonalności rekomendacji przy ograniczonym budżecie oraz możliwości dostosowania logiki do specyficznych wymagań biznesowych.

Rozdział 3

Opis projektu planowanej aplikacji

Rozdział przedstawia szczegółowy opis planowanej aplikacji e-commerce z zaawansowanym systemem rekomendacji produktów. Zaprezentowano diagram przypadków użycia ilustrujący interakcje użytkowników z systemem oraz opisano kluczowe funkcjonalności z perspektywy różnych typów użytkowników.

3.1 Cel i zakres aplikacji

Aplikacja stanowi kompleksowe rozwiązanie e-commerce integrujące trzy komplementarne metody rekomendacji produktów:

- **Collaborative Filtering** - odkrywanie produktów podobnych na podstawie wzorców zakupowych użytkowników,
- **Sentiment Analysis** - ocena jakości produktów poprzez analizę opinii i treści,
- **Association Rules (Apriori)** - identyfikacja produktów często kupowanych razem.

System został zaprojektowany z myślą o małych i średnich platformach e-commerce (do 10000 produktów, do 100000 użytkowników), zapewniając funkcjonalności rekomendacyjne porównywalne z rozwiązaniami enterprise przy znacznie niższych kosztach operacyjnych.

3.2 Wymagania funkcjonalne systemu

System został zaprojektowany z uwzględnieniem następujących wymagań funkcjonalnych podzielonych według typów użytkowników:

Dla gości (użytkowników niezalogowanych):

- Przeglądanie katalogu produktów,
- Wyszukiwanie produktów z wykorzystaniem różnych metod sortowania,
- Dodawanie produktów do koszyka,
- Logowanie do systemu,
- Rejestracja w systemie.

Dla klientów (użytkowników zalogowanych):

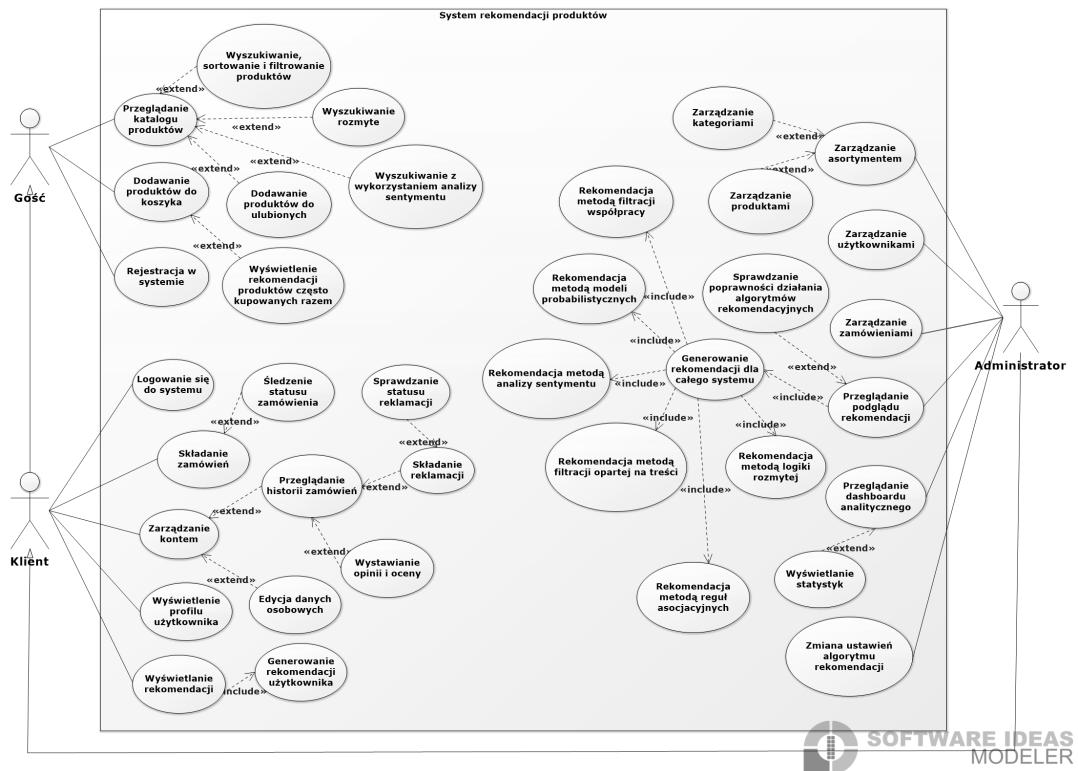
- Wszystkie funkcjonalności gościa,
- Składanie zamówień,
- Śledzenie statusu zamówień,
- Zarządzanie kontem użytkownika,
- Wyświetlanie profilu użytkownika,
- Wyświetlanie historii zamówień,
- Edycja danych osobowych,
- Przeglądanie rekomendacji w sekcjach strony głównej,
- Rekomendacje metody reguł asocjacyjnych w koszyku.

Dla administratorów:

- Zarządzanie kontem administratora,
- Zarządzanie produktami (dodawanie, edycja, usuwanie),
- Zarządzanie zamówieniami użytkowników,
- Zmiana statusów zamówień,
- Zarządzanie użytkownikami,
- Przeglądanie statystyk sprzedaży,
- Przeglądanie panelu analitycznego (dashboard),
- Wyświetlanie statystyk,
- Sprawdzanie statusu zamówień,
- Debugowanie algorytmów rekomendacji:
 - Przeglądanie podglądu rekomendacji,
 - Sprawdzanie poprawności działania algorytmów rekomendacyjnych,
 - Wyświetlanie statystyk metod rekomendacji.

3.3 Diagram przypadków użycia

Diagram przypadków użycia (rys. 1) przedstawia kompletny widok funkcjonalności systemu oraz relacji między aktorami a przypadkami użycia. System obsługuje trzy główne typy aktorów: Gościa (użytkownik niezalogowany), Klienta (użytkownik zalogowany) oraz Administratora (zarządzający systemem).



Rysunek 1: Diagram przypadków użycia systemu.

Ogólny opis diagramu:

Diagram został zorganizowany wokół trzech głównych aktorów, z których każdy ma dostęp do różnych poziomów funkcjonalności systemu. Relacje dziedziczenia między aktorami (Gość → Klient → Administrator) odzwierciedlają hierarchię uprawnień - każdy następny poziom dziedziczy wszystkie funkcjonalności poprzedniego i dodaje nowe, specyficzne dla swojej roli.

System został podzielony na trzy główne obszary funkcjonalne:

1. Obszar publiczny (dostępny dla wszystkich użytkowników) - podstawowe funkcjonalności e-commerce takie jak przeglądanie produktów, wyszukiwanie, dodawanie do koszyka oraz procesy autentykacji (logowanie, rejestracja).

2. Obszar klienta (wymaga zalogowania) - funkcjonalności transakcyjne obejmujące składanie zamówień, śledzenie ich statusu, zarządzanie kontem oraz dostęp do spersonalizowanych rekommendacji generowanych przez trzy zaimplementowane algorytmy rekommendacyjne.

3. Obszar administracyjny (wymaga uprawnień administratora) - narzędzia do zarządzania całym systemem: produktami, zamówieniami, użytkownikami oraz dostęp do paneli statystycznych i debugowania algorytmów rekomendacji.

Klient - użytkownik zalogowany, który dziedziczy wszystkie funkcje gościa oraz dodatkowo może:

- **Składać zamówienia** - finalizacja zakupu produktów z koszyka,
- **Śledzić status zamówień** - monitoring postępu realizacji zamówień (oczekujące, w realizacji, zakończone, anulowane),
- **Zarządzać kontem** - edycja danych osobowych, zmiana hasła,
- **Wyświetlać profil użytkownika** - podgląd informacji o koncie,
- **Przeglądać historię zamówień** - dostęp do wszystkich wcześniejszych transakcji,
- **Edytować dane osobowe** - aktualizacja imienia, nazwiska, adresu e-mail,
- **Przeglądać rekomendacje** - dostęp do spersonalizowanych sugestii produktów generowanych przez:
 - *Collaborative Filtering* - rekomendacje oparte na historii zakupów użytkownika i podobieństwie do innych klientów,
 - *Metodę reguł asocjacyjnych (Apriori)* - produkty często kupowane razem, rekomendacje typu “Często kupowane razem”,
 - *Metodę analizy sentymentu* - produkty o najlepszych opiniach dopasowane do preferencji użytkownika.

Administrator - użytkownik z najwyższymi uprawnieniami, który dziedziczy wszystkie funkcje klienta oraz dodatkowo ma dostęp do:

- **Zarządzanie kontem administratora** - edycja ustawień konta administracyjnego,
- **Zarządzanie produktami** - pełny zakres operacji CRUD:
 - Dodawanie produktów do katalogu,
 - Edycja istniejących produktów (nazwa, opis, cena, kategorie),
 - Usuwanie produktów z potwierdzeniem.
- **Zarządzanie zamówieniami** - administracja transakcjami użytkowników:
 - Przeglądanie wszystkich zamówień w systemie,

- Zmiana statusów zamówień (oczekujące → w realizacji → zakończone lub anulowane),
- Generowanie raportów sprzedażowych.

- **Zarządzanie użytkownikami** - administracja kontami:

- Lista wszystkich użytkowników,
- Nadawanie uprawnień,
- Usuwanie użytkowników.

- **Przeglądanie statystyk** - dostęp do zaawansowanych analiz:

- Panel analityczny (dashboard) z kluczowymi wskaźnikami: liczba produktów, użytkowników, zamówień,
- Wykresy sprzedaży - miesięczny obrót, najpopularniejsze kategorie.

- **Debugowanie algorytmów rekomendacji** - narzędzia diagnostyczne:

- *Podgląd rekomendacji* - sprawdzenie jakie produkty są rekomendowane dla konkretnego użytkownika lub produktu,
- *Sprawdzanie poprawności* - walidacja czy algorytmy działają zgodnie z oczekiwaniemi,
- *Wyświetlanie statystyk metod* - szczegółowe metryki dla każdej metody rekomendacji.

Relacje między przypadkami użycia:

Diagram wyraźnie pokazuje hierarchię dziedziczenia funkcjonalności:

- **Gość → Klient:** relacja “extends” - Klient dziedziczy wszystkie funkcje Gościa (przeglądanie, wyszukiwanie, koszyk, logowanie, rejestracja) oraz otrzymuje dostęp do funkcji transakcyjnych (zamówienia, historia, rekomendacje),
- **Klient → Administrator:** relacja “extends” - Administrator dziedziczy wszystkie funkcje Klienta oraz otrzymuje narzędzia zarządzania systemem (produkty, zamówienia, użytkownicy, statystyki, debugowanie).

3.4 Architektura funkcjonalna systemu

System został zaprojektowany w architekturze warstwowej, gdzie każda warstwa odpowiada za konkretny aspekt funkcjonalności:

Warstwa prezentacji - interfejsy użytkownika dostosowane do ról (klient, administrator):

- **Panel klienta** - panel główny (dashboard) z historią zamówień, sekcja rekomendacji, edycja profilu,
- **Panel administracyjny** - zarządzanie produktami/zamówieniami/użytkownikami, statystyki, panele debugowania.

Warstwa logiki biznesowej - implementacja trzech algorytmów rekomendacji oraz logiki e-commerce:

- **Moduł Collaborative Filtering** - generowanie macierzy podobieństwa produktów, rekomendacje oparte na produktach (item-based),
- **Moduł Sentiment Analysis** - agregacja sentymantu z 5 źródeł tekstowych (opinie, opis, nazwa, specyfikacje, kategorie),
- **Moduł Apriori** - generowanie reguł asocjacyjnych typu “Często kupowane razem”,
- **Logika transakcyjna** - składanie zamówień, zarządzanie statusami, walidacja danych.

Warstwa danych - relacyjna baza danych PostgreSQL przechowująca:

- Dane produktów (nazwa, opis, cena, kategorie, specyfikacje, zdjęcia),
- Dane użytkowników (konta, profile, uprawnienia),
- Dane transakcyjne (zamówienia, produkty w zamówieniach, statusy),
- Dane opinii (recenzje tekstowe, oceny gwiazdkowe, sentymant),
- Wyniki algorytmów (macierze podobieństwa, reguły asocjacyjne, zagregowany sentiment).

Integracja warstw odbywa się poprzez RESTful API z automatyczną synchronizacją - zmiana danych w jednej warstwie propaguje aktualizacje do pozostałych.

3.5 Kluczowe scenariusze użycia

Scenariusz 1: Użytkownik niezalogowany przegląda produkty

Gość wchodzi na stronę główną aplikacji. Nawiązuje do katalogu produktów, filtry po kategorii „Laptopy”, sortuje według „Najlepszy sentyment”. Przegląda kilka produktów, dodaje wybrany laptop do koszyka. W koszyku widzi sekcję “Często kupowane razem” z torbą i myszą (rekomendacje Apriori). Decyduje się również

dodać torbę. Przy próbie finalizacji zamówienia system przekierowuje do logowania lub rejestracji.

Scenariusz 2: Klient składa zamówienie i śledzi jego status

Użytkownik loguje się do systemu. Przechodzi do koszyka, klika „Przejdź do kas”, wypełnia dane dostawy i płatności. Po złożeniu zamówienia otrzymuje potwierdzenie ze statusem „oczekujące”. W panelu klienta (zakładka „My Orders”) widzi listę wszystkich zamówień z możliwością śledzenia statusu w czasie rzeczywistym (oczekujące → w realizacji → zakończone).

Scenariusz 3: Administrator zarządza produktami

Administrator loguje się do panelu administracyjnego. Wchodzi do sekcji „Products”, klika „Add New Product”. Wypełnia formularz (nazwa, opis, cena, specyfikacje), przypisuje kategorie. Po zapisaniu produktu, system automatycznie przelicza jego wynik sentymentu (sentiment score) na podstawie opisu i nazwy (brak jeszcze opinii). Administrator może również edytować istniejące produkty lub usuwać te o niskim sentymentem.

Scenariusz 4: Klient wystawia opinię i system przelicza sentyment

Zalogowany użytkownik przechodzi do panelu klienta, otwiera zakładkę „My Orders”. Znajduje zakończone zamówienie, klika „Add Review” przy zakupionym produkcie. Wypełnia formularz opinii (ocena 1-5 gwiazdek oraz treść tekstowa). Po zapisaniu system automatycznie wywołuje algorytm analizy sentymentu, który tokenizuje tekst, wyszukuje słowa kluczowe w słowniku pozytywnym/negatywnym i oblicza zagregowany wynik sentymentu. Zaktualizowany wynik jest natychmiast widoczny dla wszystkich użytkowników na stronie produktu.

Scenariusz 5: Administrator przegląda statystyki i prognozy sprzedaży

Administrator wchodzi do sekcji „Statistics” w panelu administracyjnym. Dashboard wyświetla kluczowe metryki: całkowita liczba zamówień, przychód, najpopularniejsze kategorie.

Scenariusz 6: Administrator debuguje algorytmy rekommendacji

Administrator otwiera sekcję „Debug ML” w panelu administracyjnym. Przegląda panel debugowania Collaborative Filtering - widzi macierz podobieństw produktów, formułę Adjusted Cosine Similarity oraz statystyki (liczba par produktów, średnie podobieństwo). Przechodzi do panelu Apriori - analizuje wygenerowane reguły asocjacyjne posortowane według lift, sprawdza metryki wydajności bitmap pruning. W panelu Sentiment Analysis weryfikuje rozkład opinii i wieloźródłową agregację sentymentu.

Scenariusz 7: Klient wyszukuje produkty z filtrem sentymentu

Użytkownik otwiera wyszukiwarkę z paska nawigacyjnego, wpisuje zapytanie „laptop gaming”. System wykonuje wyszukiwanie full-text w polach nazwa i opis

produkту, filtry wyniki z `sentiment_score` ≥ 0.5 , sortuje malejąco według sentymentu.

Scenariusz 8: Gość przegląda koszyk z rekomendacjami cross-selling

Niezalogowany użytkownik dodaje laptop do koszyka. Przechodzi do widoku koszyka - system automatycznie wyświetla sekcję „Frequently Bought Together” z trzema produktami wygenerowanymi przez algorytm Apriori (torba na laptopa, mysz bezprzewodowa, hub). Każda rekomendacja zawiera metryki lift i confidence. Użytkownik decyduje się dodać torbę i mysz jednym kliknięciem. Przy próbie finalizacji zamówienia system przekierowuje do logowania.

3.6 Podsumowanie opisu projektu

Planowana aplikacja e-commerce z zaawansowanym systemem rekomendacji została zaprojektowana z hierarchią trzech typów użytkowników (gość, klient, administrator), gdzie każdy poziom dziedziczy funkcjonalności poprzedniego i dodaje nowe, specyficzne dla swojej roli. Diagram przypadków użycia jasno definiuje role aktorów oraz ich interakcje z systemem, podczas gdy szczegółowe scenariusze użycia ilustrują praktyczne zastosowania funkcjonalności w rzeczywistych przepływach zakupowych.

Kluczowe cechy projektu:

- **Hierarchia uprawnień** - przejrzysta struktura dziedziczenia funkcjonalności między rolami,
- **Kompleksowość** - pokrycie wszystkich etapów od przeglądania po zarządzanie systemem,
- **Integracja rekomendacji** - metody rekomendacyjne zintegrowane w przepływ użytkownika,
- **Narzędzia diagnostyczne** - panele debugowania dla administratora umożliwiające monitoring i optymalizację algorytmów.

Szczegółowa realizacja techniczna projektu, w tym wykorzystane technologie oraz implementacja algorytmów, zostanie przedstawiona w kolejnych rozdziałach pracy.

Rozdział 4

Przedstawienie wykorzystanego stosu technologicznego oraz praktycznej realizacji projektu

Szczegółowy opis technologii wykorzystanych w implementacji systemu e-commerce oraz praktyczne aspekty realizacji projektu. Przedstawiono architekturę techniczną aplikacji, komponenty frontendowe, strukturę bazy danych oraz mechanizmy wdrożenia.

4.1 Architektura systemu

Aplikacja została zaprojektowana w architekturze klient-serwer opartej na technologiach Django (backend) oraz React (frontend). Komunikacja odbywa się poprzez RESTful API z uwierzytelnianiem tokenowym JSON Web Tokens (JWT). Struktura aplikacji wyraźnie rozdziela warstwę prezentacji (React SPA), logikę biznesową (wiodki Django i serializery), oraz warstwę danych (PostgreSQL).

Główne założenia architektoniczne:

- **Separacja frontendu i backendu** - możliwość niezależnego rozwoju i skalowania obu warstw,
- **Podejście API-first (API-first approach)** - wszystkie funkcjonalności dostępne przez REST API,
- **Uwierzytelnianie bezstanowe (Stateless authentication)** - token JWT eliminuje potrzebę sesji po stronie serwera,
- **Modułowa struktura** - każdy algorytm rekommendacji stanowi niezależny moduł.

4.2 Stos technologiczny backendu

Django 5.1.4 (Python 3.11)

Django stanowi fundament aplikacji serwerowej, zapewniając architekturę MVC, system ORM (Object-Relational Mapping - mapowanie obiektowo-relacyjne) dla abstrakcji bazy danych oraz mechanizmy bezpieczeństwa. Kluczowe komponenty:

- **Django ORM** - mapowanie obiektowo-relacyjne umożliwiające operacje na bazie bez SQL,

- **Django Signals** - mechanizm automatycznej aktualizacji rekomendacji przy zmianach danych,
- **Django Middleware (oprogramowanie pośredniczące)** - obsługa CORS, uwierzytelnienie JWT, pamięć podręczna.

Django REST Framework 3.15.2

Rozszerza Django o funkcjonalności API RESTful:

- **Serializery** - konwersja obiektów Django na JSON z walidacją,
- **ViewSets (zestawy widoków)** - widoki implementujące operacje CRUD,
- **Uwierzytelnianie (Authentication)** - wsparcie dla JWT, uwierzytelnianie sesyjne,
- **Pagination (paginacja)** - automatyczne stronicowanie wyników.

Biblioteki Machine Learning

Do operacji numerycznych i obliczania podobieństw wykorzystano:

- **scikit-learn** - funkcja cosine_similarity() dla Collaborative Filtering (Collaborative Filtering),
- **NumPy** - operacje macierzowe, wektoryzacja obliczeń, przycinanie bitmapowe (bitmap pruning) w Apriori.

Struktura backendu

Każdy komponent systemu posiada dedykowane pliki:

- **models.py** – definicje tabel (Product, Order, Opinion, ProductSimilarity),
- **serializers.py** – konwersja obiektów Django ↔ JSON,
- **views.py** – obsługa CRUD dla produktów, zamówień,
- **recommendation_views.py** – endpointy /api/generate-user-recommendations/, /api/recommendation-algorithm-status/,
- **sentiment_views.py** – endpointy /api/sentiment-search/, /api/sentiment-analysis-debug/,
- **association_views.py** – endpointy /api/frequently-bought-together/, /api/update-association-rules/,
- **signals.py** – automatyczna aktualizacja rekomendacji.

4.3 Stos technologiczny frontendu

React 18

React stanowi fundament aplikacji jednostronicowej (Single Page Application - SPA):

- **Architektura komponentowa (Component-based)** - reużywalne komponenty UI,
- **Virtual DOM (wirtualny DOM)** - optymalizacja renderowania,
- **React Hooks (haki React)** - useState, useEffect, useContext.

Biblioteki wspierające

- **React Router v6** - trasowanie (routing) dla aplikacji SPA,
- **Axios** - komunikacja z API, przechwytywacze JWT (interceptors),
- **Framer Motion** - płynne animacje,
- **Context API** - zarządzanie stanem (AuthContext, CartContext).

Architektura komponentów

- **App.js** – trasowanie, globalne dostawcy kontekstu (Context providers),
- **Navbar.jsx** – nawigacja z wyszukiwarką i ikoną koszyka,
- **SearchModal.jsx** – wyszukiwarka z sortowaniem sentymentu,
- **ProductPage.jsx** – strona produktu z rekommendacjami Collaborative Filtering i Apriori,
- **CartContent.jsx** – koszyk z cross-selling (Apriori),
- **ClientPanel.jsx** – panel główny klienta z personalizowanymi rekommendacjami,
- **AdminPanel.jsx** – panel zarządzania produktami, zamówieniami, statystykami.

4.4 Baza danych PostgreSQL

Wybór PostgreSQL 14

PostgreSQL został wybrany jako system zarządzania bazą danych ze względu na następujące cechy:

- **Zaawansowane indeksy** - wsparcie dla B-tree (domyślne), GIN (wyszukiwanie pełnotekstowe), BRIN (optymalizacja dla dużych tabel),
- **Typ danych JSONB** - natywne przechowywanie i indeksowanie struktur JSON (wykorzystane w tabeli `method_user_purchase_pattern` dla sezonowości zakupów),
- **Transakcje ACID** - gwarancja atomowości, spójności, izolacji i trwałości operacji krytycznych (zamówienia, płatności),
- **Klucze obce i constrainty** - automatyczne wymuszanie integralności referencyjnej oraz walidacji danych (np. rating 1-5 w opiniach),
- **Optymalizacja JOIN** - wydajne łączenie tabel w złożonych zapytaniach rekomendacyjnych,
- **Full-text search** - wbudowane mechanizmy wyszukiwania tekstowego dla produktów.

Struktura bazy danych

Baza składa się z **25 tabel** podzielonych na 4 modułów funkcjonalnych:

1. Moduł produktów i użytkowników (12 tabel):

- `db_product` - dane produktów (ID, nazwa, cena, opis),
- `db_category` - kategorie produktów z hierarchią,
- `db_product_category` - relacja Many-to-Many produktów i kategorii,
- `db_photo_product` - ścieżki do zdjęć produktów,
- `db_specification` - szczegółowe parametry techniczne produktów,
- `db_tag` - tagi do filtrowania produktów,
- `db_sale` - promocje i rabaty,
- `db_user` - konta użytkowników (role: admin/client),
- `db_order` - zamówienia z timestampami i statusami,

- db_order_product - produkty w zamówieniach (ilość, cena),
- db_cart_item - koszyk zakupowy przed finalizacją,
- db_complaint - reklamacje powiązane z zamówieniami.

2. Moduł opinii i analizy sentymentu (3 tabele):

- db_opinion - opinie użytkowników (treść, rating 1-5),
- method_sentiment_analysis - wyniki analizy sentymentu dla opinii,
- method_product_sentiment_summary - zagregowany sentyment produktu.

3. Moduł metod rekomendacji (5 tabel):

- method_product_similarity - macierz podobieństw produktów (Collaborative Filtering),
- method_user_product_recommendation - spersonalizowane rekomendacje użytkowników,
- method_productassociation - reguły asocjacyjne Apriori,
- method_user_interactions - historia interakcji użytkowników,
- method_recommendation_settings - konfiguracja algorytmów dla użytkownika.

4. Moduł analityczny i prognozowanie (5 tabel):

- method_purchase_probability - prawdopodobieństwo zakupu produktu przez użytkownika,
- method_sales_forecast - prognoza sprzedaży produktów,
- method_user_purchase_pattern - wzorce zakupowe użytkowników,
- method_product_demand_forecast - prognoza popytu i poziomy magazynowe,
- method_risk_assessment - ocena ryzyka dla użytkowników i produktów.

Wszystkie migracje Django ORM zostały wygenerowane automatycznie na podstawie modeli Python i zarządzane przez system wersjonowania `django.db.migrations`.

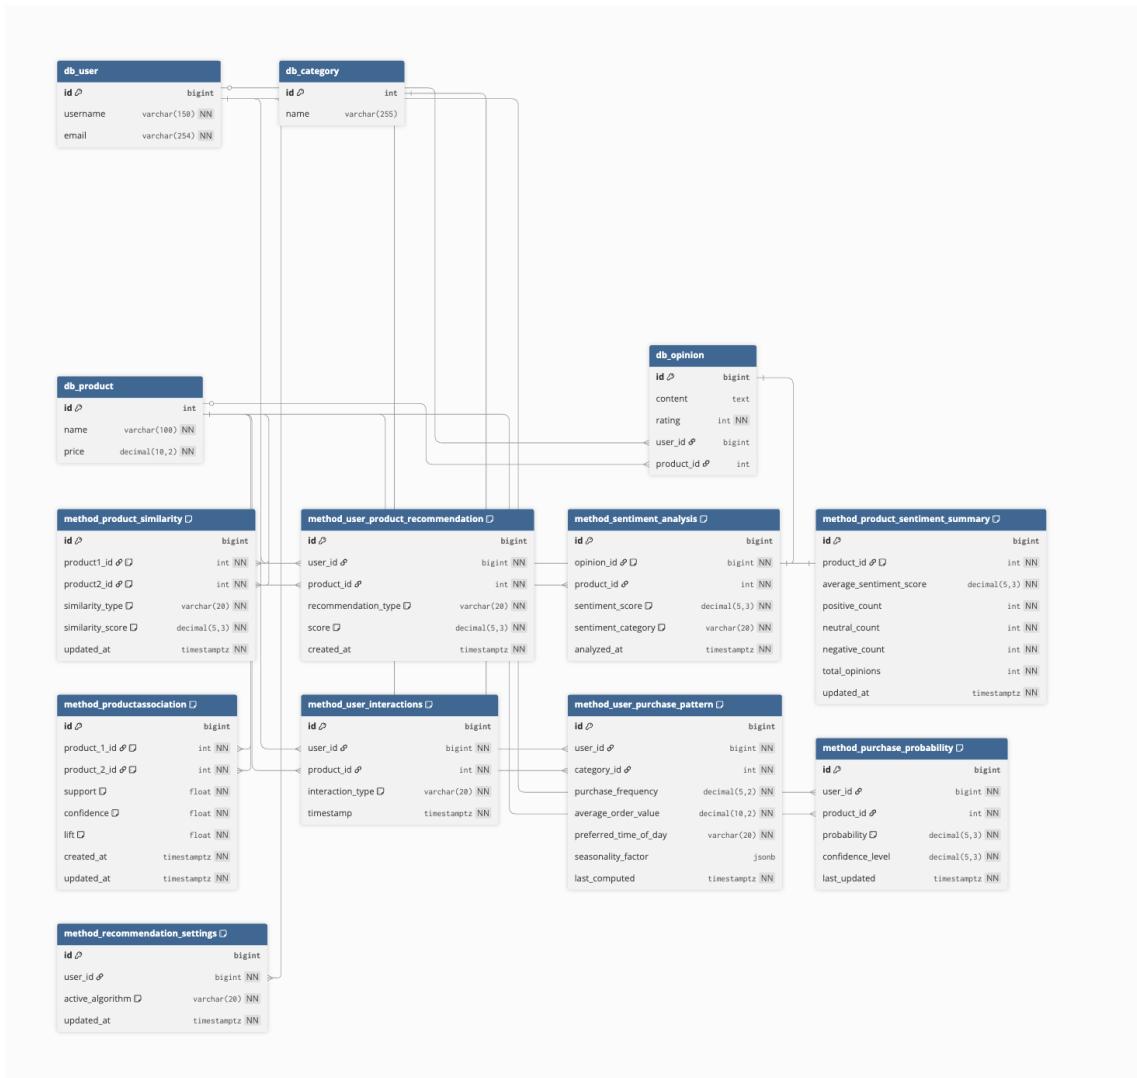
Diagramy ERD



Rysunek 2: Diagram ERD głównych tabel aplikacji.

Diagram 2 przedstawia rdzeń aplikacji e-commerce. Kluczowe relacje:

- **db_user → db_order** (1:N) - jeden użytkownik składa wiele zamówień,
- **db_order → db_order_product** (1:N) - zamówienie zawiera wiele produktów,
- **db_product ↔ db_category** (N:M) - produkt należy do wielu kategorii,
- **db_product → db_opinion** (1:N) - produkt ma wiele opinii.



Rysunek 3: Diagram ERD tabel metod rekomendacyjnych.

Diagram 3 pokazuje tabele algorytmów ML:

- **method_product_similarity** - macierz podobieństw Collaborative Filtering,
- **method_product_association** - reguły asocjacyjne Apriori,
- **method_sentiment_analysis** - wyniki analizy sentymentu opinii,
- **method_product_sentiment_summary** - zagradowany sentyment produktu,
- **method_user_product_recommendation** - cache rekomendacji użytkownika.

Podsumowanie struktury bazy danych

Baza danych składa się z 25 tabel zorganizowanych w moduły funkcjonalne. Wypełnianie danymi początkowymi (seeding) wypełnia bazę danymi testowymi:

- 500 produktów,
- 20 użytkowników (5 adminów + 15 klientów),
- 200 zamówień,
- 600 rekordów OrderProduct (średnio 3 produkty per zamówienie),
- 1750 opinii (średnio 3.5 opinii per produkt).

4.5 Deployment i konteneryzacja Docker

Aplikacja została skonteneryzowana przy użyciu Docker Compose, zapewniając spójność środowiska między środowiskiem deweloperskim (development), testowym (staging) i produkcyjnym (production).

Name	Container ID	Image	Port(s)	CPU (%)	Last started	Actions
smartrecommender-project	-	-	-	2.53%	15 minutes ago	Stop ⋮ Remove
SmartRecommender-React-FRONT_d47ec7a8c0f5	d47ec7a8c0f5	smartrecommender-project-frontend	3000:3000	0.67%	15 minutes ago	Stop ⋮ Remove
SmartRecommender-Django-BACb_55e59f5b9bc8	55e59f5b9bc8	smartrecommender-project-backend	8000:8000	1.66%	15 minutes ago	Stop ⋮ Remove
SmartRecommender-PostgreSQL-1_333adf11b817	333adf11b817	postgres:16	5432:5432	0.2%	15 minutes ago	Stop ⋮ Remove

Rysunek 4: Deployment aplikacji w architekturze Docker Compose.

Architektura składa się z trzech kontenerów (rys. 4):

1. Kontener frontendu (React 18)

- Base image: node:18-alpine,
- Port: 3000,
- Volumes: montowanie src/ dla automatycznego przeładowania (hot-reload),
- Environment: REACT_APP_API_URL,
- Zależności (Dependencies): package.json (React, Axios, React Router, Framer Motion).

2. Kontener backendu (Django 5.1.4)

- Base image: python:3.11-slim,
- Port: 8000,

- Volumes: montowanie projektu dla automatycznego przeładowania (hot-reload), wolumen dla plików multimedialnych,
- Environment: DATABASE_URL, SECRET_KEY, DEBUG, ALLOWED_HOSTS,
- Zależności (Dependencies): requirements.txt (Django, DRF, psycopg2, NumPy, scikit-learn).

3. Kontener bazy danych (PostgreSQL 14)

- Base image: postgres:14-alpine,
- Port: 5432,
- Volumes: named volume postgres_data (persistencja danych),
- Environment: POSTGRES_DB, POSTGRES_USER, POSTGRES_PASSWORD,
- Healthcheck: pg_isready.

Zalety konteneryzacji Docker

- **Izolacja** - każdy serwis w osobnym kontenerze, zero konfliktów zależności,
- **Przenośność** - obraz zbudowany raz działa na dowolnym serwerze z silnikiem Docker,
- **Łatwa konfiguracja** - komenda docker-compose up uruchamia całą aplikację,
- **Skalowalność** - możliwość uruchomienia wielu instancji backendu dla równoważenia obciążenia.

4.6 Podsumowanie stosu technologicznego

Wybrane technologie (Django + React + PostgreSQL + Docker) tworzą nowoczesny, skalowalny i łatwy w utrzymaniu stos technologiczny. Kluczowe zalety:

- **Separacja kontynerów** - wyraźny podział frontend/backend/baza,
- **Wygoda programisty** - narzędzia (Django ORM, haki React, Docker Compose) przyspieszają rozwój aplikacji,
- **Wsparcie społeczności** - aktywna społeczność, obszerna dokumentacja,
- **Wydajność** - optymalizacje (pamięć podrzczna, indeksy bazy danych, operacje wektorowe NumPy) zapewniają szybki czas odpowiedzi.

Rozdział 5

Implementacja algorytmów rekomendacji

Szczegółowa implementacja trzech algorytmów rekomendacyjnych wraz z pseudokodami oraz diagramami sekwencji przedstawia praktyczne aspekty realizacji metod collaborative filtering, analizy sentymentu oraz reguł asocjacyjnych. Każda metoda została zaimplementowana od podstaw bez użycia gotowych bibliotek rekomendacyjnych.

5.1 Collaborative Filtering - Item-Based z Adjusted Cosine

Algorytm Collaborative Filtering w wariancie Item-Based oblicza podobieństwa między produktami na podstawie historii zakupów użytkowników, wykorzystując metrykę Adjusted Cosine Similarity wprowadzoną przez Sarwar et al. (2001) [8]. Kluczowym elementem algorytmu jest formuła matematyczna przedstawiona we wzorze (1) w rozdziale 1.3, która oblicza podobieństwo między dwoma produktami i i j poprzez analizę wzorców ich współwystępowania w zakupach użytkowników z uwzględnieniem centrowania wartości względem średniej zakupów każdego użytkownika \bar{R}_u .

Proces implementacji składa się z trzech głównych etapów odpowiadających wzorowi (1): budowy macierzy użytkownik-produkt, normalizacji wartości metodą mean-centering (centrowanie względem \bar{R}_u) oraz obliczenia podobieństw cosinusowych. Normalizacja polega na odjęciu od każdej wartości zakupowej średniej zakupów danego użytkownika ($R_{u,i} - \bar{R}_u$), co eliminuje bias wynikający z różnych skali zakupowych (hurtownik kupujący po 100 sztuk vs klient kupujący po 1 sztuce otrzymują porównywalne wagę po normalizacji).

Pseudokod 1a: Budowa i normalizacja macierzy Collaborative Filtering

Listing 1: Budowa macierzy użytkownik-produkt z normalizacją

```
1 FUNKCJA buduj_macierz_cf():
2     pozycje = pobierz_wszystkie_pozycje_zamowien()
3     macierz = pusty_slownik()
4
5     DLA KAZDEJ poz W pozycje:
6         uz_id = poz.order.user_id
7         prod_id = poz.product_id
8         macierz[uz_id][prod_id] = poz.quantity
9     KONIEC DLA
```

```

10
11     M = konwertuj_na_tablice(macierz)
12     M_norm = macierz_zerowa(wymiary(M))
13
14     DLA i = 0 DO liczba_wierszy(M) - 1:
15         zakupione = M[i] gdzie M[i] > 0
16         JEZELI |zakupione| > 0 WTEDY
17             sr = srednia(zakupione)
18             DLA j = 0 DO liczba_kolumn(M) - 1:
19                 JEZELI M[i][j] > 0 WTEDY
20                     M_norm[i][j] = M[i][j] - sr
21             KONIEC JEZELI
22             KONIEC DLA
23         KONIEC JEZELI
24     KONIEC DLA
25
26     ZWROC M_norm
27 KONIEC FUNKCJA

```

Pseudokod 1b: Obliczanie podobieństw produktów

Listing 2: Obliczanie podobienstwa cosinusowego produktow

```

1 FUNKCJA oblicz_podobienstwa_cf(M_norm, prog = 0.5):
2     M_T = transponuj(M_norm)
3     sim = podobienstwo_cosinus(M_T)
4
5     usun_podobienstwa(typ='collaborative')
6     lista = pusta_lista()
7     n = liczba_produktow(M_T)
8
9     DLA i = 0 DO n - 1:
10        DLA j = 0 DO n - 1:
11            JEZELI i != j ORAZ sim[i][j] > prog WTEDY
12                dopisz(lista, {prod1: i, prod2: j, wynik:
13                    sim[i][j]})
14
15            JEZELI |lista| >= 1000 WTEDY
16                zapisz_zbiorczo(lista)
17                lista = pusta_lista()
18            KONIEC JEZELI
19            KONIEC JEZELI
20        KONIEC DLA

```

```

20     KONIEC DLA
21
22     JEZELI |lista| > 0 WTEDY
23         zapisz_zbiorczo(lista)
24     KONIEC JEZELI
25 KONIEC FUNKCJA

```

Algorytm generowania rekomendacji dla użytkownika wykorzystuje wcześniej obliczone podobieństwa produktów. Proces polega na zebraniu historii zakupów użytkownika (zamówienia + koszyk), a następnie dla każdego produktu z tej historii wyszukiwane są najbardziej podobne produkty. Wyniki są agregowane - jeśli dany produkt jest podobny do wielu produktów zakupionych przez użytkownika, otrzymuje sumę wszystkich podobieństw jako końcowy wynik rekomendacji.

Pseudokod 2: Generowanie rekomendacji dla użytkownika

Listing 3: Generowanie rekomendacji CF dla użytkownika

```

1  FUNKCJA generuj_rekomendacje(uzytkownik, typ_algorytmu):
2      historia = pusta_lista()
3
4      DLA KAZDEGO zam W pobierz_zamowienia(uzytkownik):
5          DLA KAZDEGO p W zam.produkty:
6              dopisz(historia, p.id)
7          KONIEC DLA
8      KONIEC DLA
9
10     DLA KAZDEJ poz W pobierz_koszyk(uzytkownik):
11         dopisz(historia, poz.produkt.id)
12     KONIEC DLA
13
14     wyniki = pusty_slownik()
15     DLA KAZDEGO prod_id W unikalne(historia):
16         podobne = pobierz_podobne(prod_id, typ_algorytmu,
17             limit=5)
18         DLA KAZDEGO s W podobne:
19             JEZELI s.produkt2_id W wyniki WTEDY
20                 wyniki[s.produkt2_id] += s.podobienstwo
21             INACZEJ
22                 wyniki[s.produkt2_id] = s.podobienstwo
23             KONIEC JEZELI
24         KONIEC DLA
25     KONIEC DLA

```

```

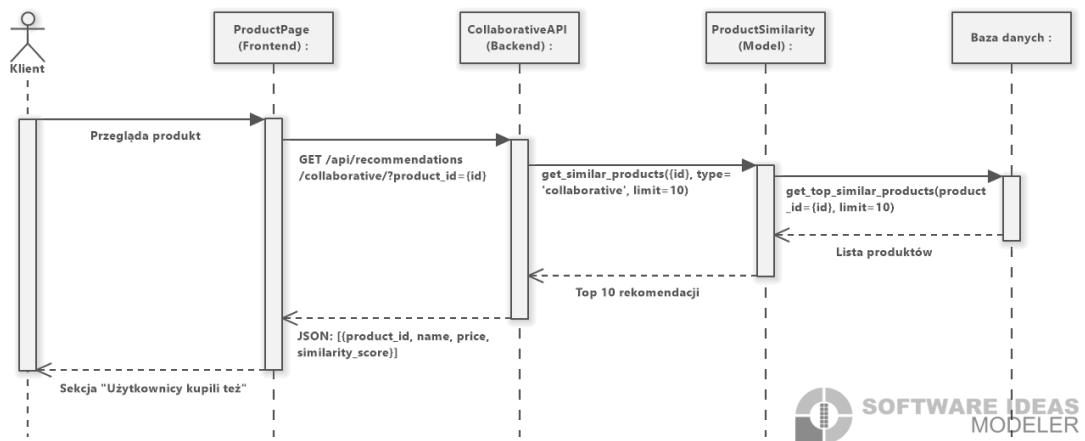
26     lista = sortuj(wyniki, malejaco)
27     DLA KAZDEGO (p_id, wart) W lista:
28         zapisz_rekomendacje(uzytkownik, p_id, typ_algorytmu
29             , wart)
30     KONIEC DLA
31 KONIEC FUNKCJA

```

Kluczowe optymalizacje Collaborative Filtering:

- Pamięć podręczna (cache) przechowuje macierz podobieństw przez 2 godziny (7200 sekund),
- Operacje zbiorcze (bulk insert) zapisują po 1000 rekordów jednocześnie,
- Próg 0.5 redukuje rozmiar bazy, poprzez odrzucenie niższych wartości,
- Indeksowanie na kolumnach (produkt_1, typ_podobienstwa).

Diagram sekwencji: Collaborative Filtering



Rysunek 5: Diagram sekwencji: Collaborative Filtering.

Przepływ procesu generowania rekomendacji Collaborative Filtering:

1. Żądanie użytkownika trafia do API (/api/recommendations/)
2. API sprawdza pamięć podręczną - w przypadku trafienia zwracany jest wynik natychmiast
3. Przy braku w pamięci podręcznej następuje zapytanie do bazy danych o historię zakupów
4. Budowana jest macierz użytkownik-produkt z OrderProduct

5. Macierz jest normalizowana (centrowanie wartości) i obliczane są podobieństwa cosinusowe
6. Wyniki zapisywane są do pamięci podręcznej (2 godziny) oraz tabeli Product-Similarity
7. API zwraca top N rekomendacji

5.2 Analiza Sentymentu - wieloźródłowa agregacja

Analiza sentymentu pojedynczego tekstu metodą słownikową (Liu 2012) [5] wykorzystuje formułę polarności przedstawioną we wzorze (2) w rozdziale 1.3. Proces analizy polega na normalizacji tekstu (konwersja na małe litery, usunięcie znaków specjalnych), tokenizacji oraz zliczaniu słów występujących w słownikach pozytywnym i negatywnym. Słowniki oparte na leksykonach akademickich AFINN-165 (Nielsen 2011) i Opinion Lexicon (Hu & Liu 2004) zawierają łącznie 400 słów (200 słów pozytywnych, 200 słów negatywnych) obejmujących najczęściej używane określenia jakościowe, emocjonalne i ocenne (np. pozytywne: „excellent”, „recommend”, „quality”, „reliable”; negatywne: „bad”, „poor”, „disappointing”, „defective”). Wynik wzoru (2) jest ograniczany do przedziału [-1, 1] i kategoryzowany: pozytywny (>0.1), negatywny (<-0.1), neutralny (pozostałe).

Wieloźródłowa agregacja sentymentu produktu stanowi kluczową innowację systemu, łącząc wyniki z 5 niezależnych źródeł tekstowych zgodnie ze wzorem (3) przedstawionym w rozdziale 1.3, gdzie każde S_i jest obliczane według wzoru (2). Wagi zostały dobrane empirycznie: opinie klientów 40% (najbardziej wiarygodne źródło), opis produktu 25% (profesjonalny opis zawierający kluczowe cechy), nazwa produktu 15% (często zawiera wskazówki jakościowe jak „Premium”, „Pro”), specyfikacje techniczne 12% (obiektywne parametry), kategorie produktu 8% (ogólny kontekst). Podejście to rozwiązuje fundamentalny problem zimnego startu - produkty bez opinii klientów nadal otrzymują wynik sentymentu na podstawie pozostałych czterech źródeł tekstowych.

Pseudokod 3: Analiza sentymentu pojedynczego tekstu

Listing 4: Analiza sentymentu metoda słownikowa

```

1 FUNKCJA analizuj_sentiment(tekst, slownik_poz, slownik_neg)
:
2     slowa = tokenizuj(na_male_literey(tekst))
3
4     JEZELI |slowa| = 0 WTEDY
5         ZWROC (0.0, ,,neutralny '')
6     KONIEC JEZELI

```

```

7
8     poz = 0
9     neg = 0
10
11    DLA KAZDEGO s W slowa:
12        JEZELI s W slownik_poz WTEDY poz = poz + 1
13        JEZELI s W slownik_neg WTEDY neg = neg + 1
14    KONIEC DLA
15
16    wynik = (poz - neg) / |slowa|
17    wynik = ogranicz(wynik, -1.0, 1.0)
18
19    JEZELI wynik > 0.1 WTEDY kat = „pozytywny”
20    INACZEJ JEZELI wynik < -0.1 WTEDY kat = „negatywny”
21    INACZEJ kat = „neutralny”
22
23    ZWROC (wynik, kat)
24 KONIEC FUNKCJA

```

Algorytm wieloźródłowej agregacji sentymentu analizuje 5 niezależnych źródeł tekstowych produktu zamiast polegać wyłącznie na opiniach klientów. Rozwiązuje to problem zimnego startu - produkty bez opinii nadal otrzymują wynik bazujący na opisie i nazwie. Wagi źródeł: opinie 40%, opis 25%, nazwa 15%, specyfikacje 12%, kategorie 8%. System zlicza rozkład opinii (pozytywne/negatywne/neutralne) dla lepszej oceny konsensusu.

Pseudokod 4: Agregacja sentymentu z wielu źródeł

Listing 5: Agregacja sentymentu produktu z 5 zdrod

```

1  FUNKCJA agreguj_sentiment_produktu(produkt):
2      opinie = pobierz_opinie(produkt)[:20]
3      wyniki_opinii = pusta_lista()
4      DLA KAZDEJ op W opinie:
5          (w, _) = analizuj_sentiment(op.tresc)
6          dopisz(wyniki_opinii, w)
7      KONIEC DLA
8      S_op = srednia(wyniki_opinii) JEZELI |wyniki_opinii| >
9          0 INACZEJ 0
10     (S_opis, _) = analizuj_sentiment(produkt.opis)
11     (S_nazwa, _) = analizuj_sentiment(produkt.nazwa)
12     teksty_spec = pusta_lista()
13     DLA KAZDEJ sp W produkt.specyfikacje[:10]:
14         dopisz(teksty_spec, sp.nazwa + ‘ ’ + sp.wartosc)

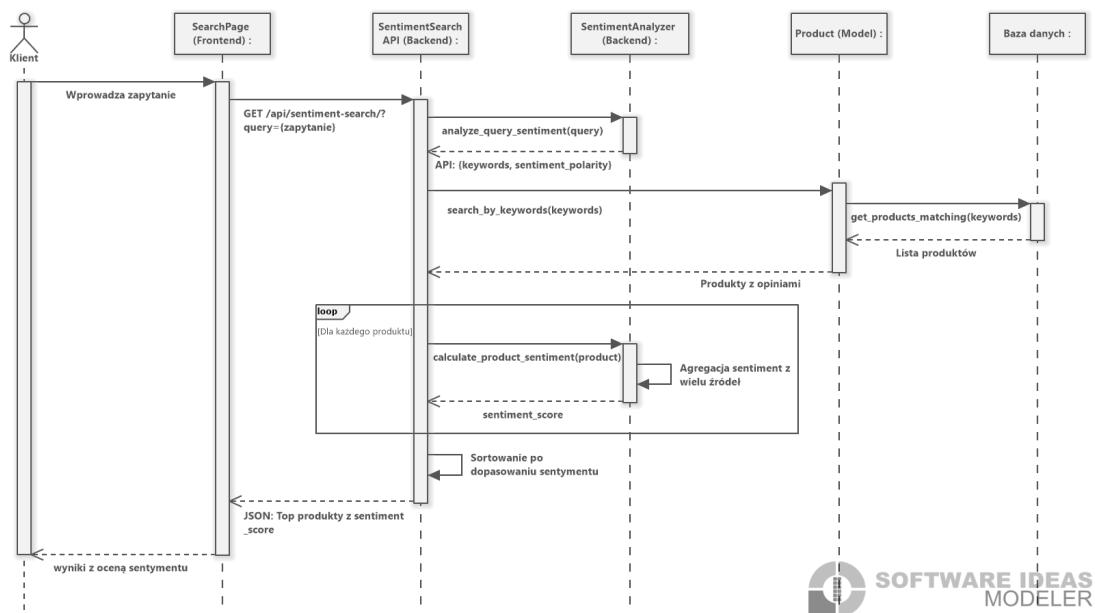
```

```

14 KONIEC DLA
15 (S_spec, _) = analizuj_sentiment(polacz(teksty_spec))
16 kat_txt = polacz(pobierz_nazwy_kategorii(produkt))
17 (S_kat, _) = analizuj_sentiment(kat_txt)
18 S_final = 0.40*S_op + 0.25*S_opis + 0.15*S_nazwa
19         + 0.12*S_spec + 0.08*S_kat
20
21 poz = policz(wyniki_opinii WHERE w > 0.1)
22 neg = policz(wyniki_opinii WHERE w < -0.1)
23 neu = policz(wyniki_opinii WHERE -0.1 <= w <= 0.1)
24
25 ZWROC {
26     wynik: zaokragl(S_final, 3),
27     pozytywne: poz,
28     negatywne: neg,
29     neutralne: neu
30 }
31 KONIEC FUNKCJA

```

Diagram sekwencji: Analiza Sentymentu



Rysunek 6: Diagram sekwencji: Analiza sentymentu.

Przepływ procesu wieloźródłowej analizy sentymentu:

1. Użytkownik wyszukuje produkty z sortowaniem według sentymentu
2. API wywołuje funkcję agregacji sentymentu dla każdego produktu

3. System analizuje 5 źródeł tekstowych równolegle (opinie 40%, opis 25%, nazwa 15%, specyfikacje 12%, kategorie 8%)
4. Dla każdego źródła wykonywana jest tokenizacja i zliczanie słów pozytywnych/negatywnych
5. Wyniki są agregowane według formuły ważonej: $S_{koncowy} = \sum_{i=1}^5 w_i \times S_i$
6. Końcowy wynik zapisywany jest w ProductSentimentSummary
7. API zwraca produkty posortowane według zagregowanego sentymetu

Kluczową zaletą tej architektury jest rozwiązanie problemu zimnego startu - produkty bez opinii nadal otrzymują wynik sentymetu na podstawie pozostałych 4 źródeł.

5.3 Algorytm Apriori - reguły asocjacyjne

Algorytm Apriori (Agrawal & Srikant 1994) [1] generuje reguły asocjacyjne typu „Często kupowane razem” poprzez analizę współwystępowania produktów w transakcjach, wykorzystując trzy fundamentalne metryki przedstawione we wzorach (4), (5) i (6) w rozdziale 1.3:

Support (Wsparcie) - wzór (4) określaczęstość współwystępowania produktów A i B w transakcjach. System używa minimalnego progu support = 0.001-0.005 (0.1-0.5% transakcji, wartość procentowa), co dla 200 zamówień oznacza że para produktów musi wystąpić w minimum 0.2-1 zamówieniu. Próg procentowy skala się automatycznie z rozmiarem bazy transakcji.

Confidence (Pewność) - wzór (5) oblicza warunkowe prawdopodobieństwo zakupu B przy założeniu zakupu A. Minimalny próg confidence = 0.01-0.1 (1-10%) oznacza że reguła jest zapisywana tylko jeśli przynajmniej 1-10% klientów kupujących A kupuje również B. Domyslna wartość confidence = 0.05 (5%) została dobrana empirycznie dla optymalnej równowagi między liczbą generowanych reguł a ich jakością.

Lift (Wzmocnienie) - wzór (6) mierzy siłę powiązania między produktami. Interpretacja: lift > 1 wskazuje pozytywną korelację (zakup A zwiększa prawdopodobieństwo zakupu B), lift = 1 oznacza niezależność produktów, lift < 1 wskazuje negatywną korelację. System używa progu lift = 1.0, preferując reguły z lift > 1.5 jako szczególnie wartościowe dla strategii cross-sellingu.

Proces implementacji składa się z dwóch głównych etapów: (1) znajdowania częstych par produktów z obliczeniem Support według wzoru (4), oraz (2) generowania reguł z obliczeniem Confidence i Lift według wzorów (5) i (6). Kluczową optymalizacją jest przycinanie bitmapowe (Zaki 2000), które reprezentuje transakcje

jako liczby całkowite z ustawnionymi bitami odpowiadającymi produktom. Sprawdzenie czy transakcja zawiera parę produktów wymaga jednej operacji bitowej AND zamiast iteracji po liście, co znacząco przyspiesza obliczenia. Wczesne przycinanie eliminuje rzadkie produkty przed obliczaniem par - dzięki właściwości antymonotoniczności Apriori (jeśli produkt jest rzadki, wszystkie jego pary też są rzadkie) zmniejsza liczbę kandydatów o około 80-90%.

Pseudokod 5a: Znajdowanie częstych par z bitmapami

Listing 6: Apriori - znajdowanie częstych par produktów

```

1  FUNKCJA znajdz_czeste_pary(transakcje, min_wsp):
2      n = |transakcje|
3      min_licz = podloga(min_wsp * n)
4
5      liczniki = pusty_slownik()
6      DLA KAZDEJ t W transakcje:
7          DLA KAZDEGO p W t:
8              liczniki[p] = liczniki[p] + 1
9          KONIEC DLA
10     KONIEC DLA
11
12     czeste = [p DLA (p, 1) W liczniki JEZELI 1 >= min_licz]
13
14     mapa = pusty_slownik()
15     DLA i = 0 DO |czestel| - 1:
16         mapa[czeste[i]] = i
17     KONIEC DLA
18
19     bitmapy = pusta_lista()
20     DLA KAZDEJ t W transakcje:
21         bm = 0
22         DLA KAZDEGO p W t:
23             JEZELI p W mapa WTEDY
24                 bm = bm LUB (1 << mapa[p])
25             KONIEC JEZELI
26         KONIEC DLA
27         JEZELI bm != 0 WTEDY
28             dopisz(bitmapy, bm)
29         KONIEC JEZELI
30     KONIEC DLA
31
32     pary = pusty_slownik()
33     DLA i = 0 DO |czestel| - 1:

```

```

34     bit_i = 1 << i
35     DLA j = i + 1 DO |czeste| - 1:
36         bit_j = 1 << j
37         para_bm = bit_i LUB bit_j
38
39         licz = 0
40         DLA KAZDEJ bm W bitmapy:
41             JEZELI (bm AND para_bm) == para_bm WTEDY
42                 licz = licz + 1
43             KONIEC JEZELI
44             KONIEC DLA
45
46             JEZELI licz >= min_licz WTEDY
47                 pary[{czeste[i], czeste[j]}] = licz / n
48             KONIEC JEZELI
49             KONIEC DLA
50         KONIEC DLA
51
52         wsparcia = {p: liczniki[p]/n DLA p W czeste}
53         ZWROC (pary, wsparcia)
54     KONIEC FUNKCJA

```

Pseudokod 5b: Generowanie reguł asocjacyjnych

Listing 7: Apriori - generowanie reguł z obliczeniem lift i confidence

```

1  FUNKCJA generuj_reguly_z_par(pary, wsparcia, min_pewn):
2      reguly = pusta_lista()
3
4      DLA KAZDEJ ({p1, p2}, wsp Para) W pary:
5          wsp1 = wsparcia[p1]
6          wsp2 = wsparcia[p2]
7
8          pewn_1_2 = wsp Para / wsp1
9          pewn_2_1 = wsp Para / wsp2
10
11         lift = wsp Para / (wsp1 * wsp2)
12
13         JEZELI pewn_1_2 >= min_pewn WTEDY
14             dopisz(reguly, {od: p1, do: p2,
15                             wsparcie: wsp Para,
16                             pewnosc: pewn_1_2,
17                             lift: lift})

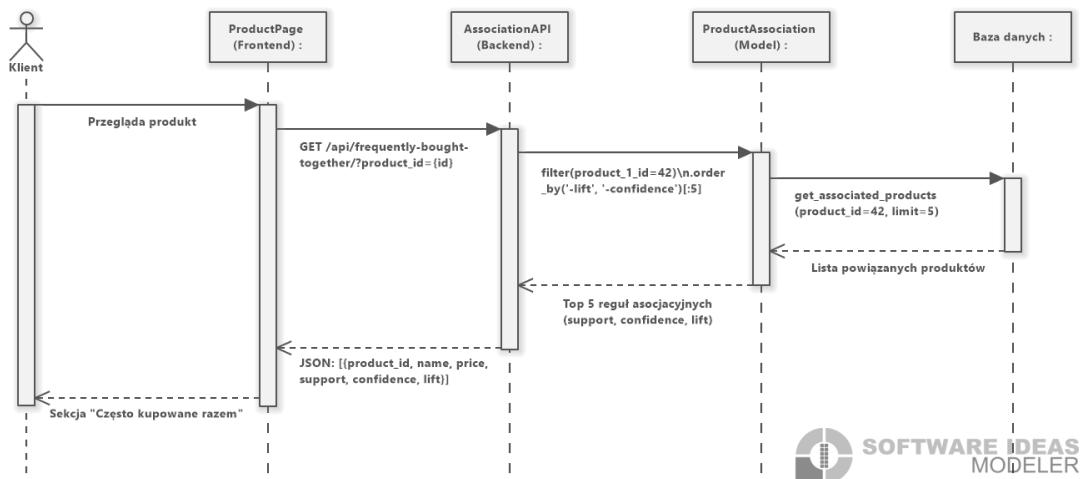
```

```

18      KONIEC JEZELI
19
20      JEZELI pewn_2_1 >= min_pewn WTEDY
21          dopisz(reguly, {od: p2, do: p1,
22                          wsparcie: wsp Para,
23                          pewnosc: pewn_2_1,
24                          lift: lift})
25      KONIEC JEZELI
26      KONIEC DLA
27
28      sortuj(reguly, wedlug=(lift, pewnosc), malejaco)
29      ZWRÓC reguly
30  KONIEC FUNKCJA

```

Diagram sekwencji: Algorytm Apriori



Rysunek 7: Diagram sekwencji: Algorytm Apriori.

Przepływ procesu generowania reguł asocjacyjnych algorytmem Apriori:

1. Administrator wywołuje aktualizację reguł przez panel administracyjny
2. System ekstrahuje transakcje z bazy OrderProduct (tylko zamówienia z 2+ produktami)
3. Algorytm wykonuje wczesne przycinanie - eliminuje rzadkie produkty (wsparcie < 0.001)
4. Transakcje konwertowane są do reprezentacji bitmapowej dla optymalizacji
5. System generuje częste 2-itemsety używając operacji bitowych AND (znaczące przyspieszenie)

6. Dla każdego częstego itemsetu obliczane są metryki: Wsparcie, Pewność, Lift
7. Reguły filtrowane są według progów i zapisywane w bazie z wstawianiem zbiorczym

Kluczowe optymalizacje Apriori:

- Przycinanie bitmapowe: znaczące przyspieszenie operacji,
- Wczesne przycinanie: eliminacja większości kandydatów,
- Operacje bitowe AND: optymalna złożoność obliczeniowa,
- Operacje zbiorcze (bulk operations): rozmiar_partii=500.

5.4 Podsumowanie implementacji

Przedstawione pseudokody odzwierciedlają algorytmy zaimplementowane w aplikacji. Kluczowe aspekty techniczne:

Collaborative Filtering:

- Adjusted Cosine Similarity eliminuje zniekształcenia skal zakupowych,
- NumPy dla wektoryzacji operacji macierzowych,
- Pamięć podręczna Django 2 godziny (CACHE_TIMEOUT_LONG) z automatycznym unieważnieniem,
- Operacje zbiorcze (rozmiar_partii=1000),
- Próg podobieństwa 0.5 redukuje liczbę zapisywanych rekordów.

Analiza Sentymentu:

- Słowniki Opinion Lexicon + AFINN-165 (400 słów),
- Wieloźródłowa agregacja (5 źródeł) z optymalnymi wagami,
- Formuła Liu (2012): $S = \frac{N_{pos} - N_{neg}}{N_{całkowite}}$,
- Rozwiążanie problemu zimnego startu.

Algorytm Apriori:

- Przycinanie bitmapowe dla optymalizacji obliczeń,
- Wczesne przycinanie eliminuje większość kandydatów niespełniających progu wsparcia,

- Operacje bitowe AND zamiast iteracji po listach,
- Operacje zbiorcze (rozmiar_partii=500),
- Metryki: Wsparcie, Pewność, Lift.

Wydajność systemu:

- Collaborative Filtering: pierwsza generacja wymaga przetworzenia macierzy, kolejne zapytania korzystają z pamięci podręcznej,
- Sentiment: przetwarzanie wsadowe opinii z wykorzystaniem słowników w pamięci,
- Apriori: przycinanie bitmapowe redukuje złożoność obliczeniową,
- Mechanizm cache'owania znacząco przyspiesza kolejne zapytania API.

Rozdział 6

Funkcjonowanie systemu rekomendacji w praktyce

Praktyczne zastosowanie trzech zaimplementowanych metod rekomendacyjnych w kontekście rzeczywistego systemu e-commerce przedstawiono na podstawie zrzutów ekranu z działającej aplikacji. Zaprezentowano scenariusze użycia, przepływy danych oraz mechanizmy zarządzania algorytmami przez panel administracyjny.

6.1 Architektura i przepływy danych

System rekomendacji został zintegrowany z aplikacją e-commerce w architekturze trójwarstwowej:

Warstwa prezentacji (React) - interfejs użytkownika wyświetlający rekomendacje w różnych kontekstach:

- Strona główna - sekcja „Recommended for You” z możliwością przełączania algorytmów,
- Panel klienta - dashboard z personalizowanymi rekomendacjami,
- Wyszukiwarka - sortowanie według sentymentu,
- Koszyk zakupowy - sekcja „Frequently Bought Together”,
- Panel administracyjny - zarządzanie metodami rekomendacji i debugowanie.

Warstwa logiki biznesowej (Django) - endpointy API obsługujące zapytania o rekomendacje:

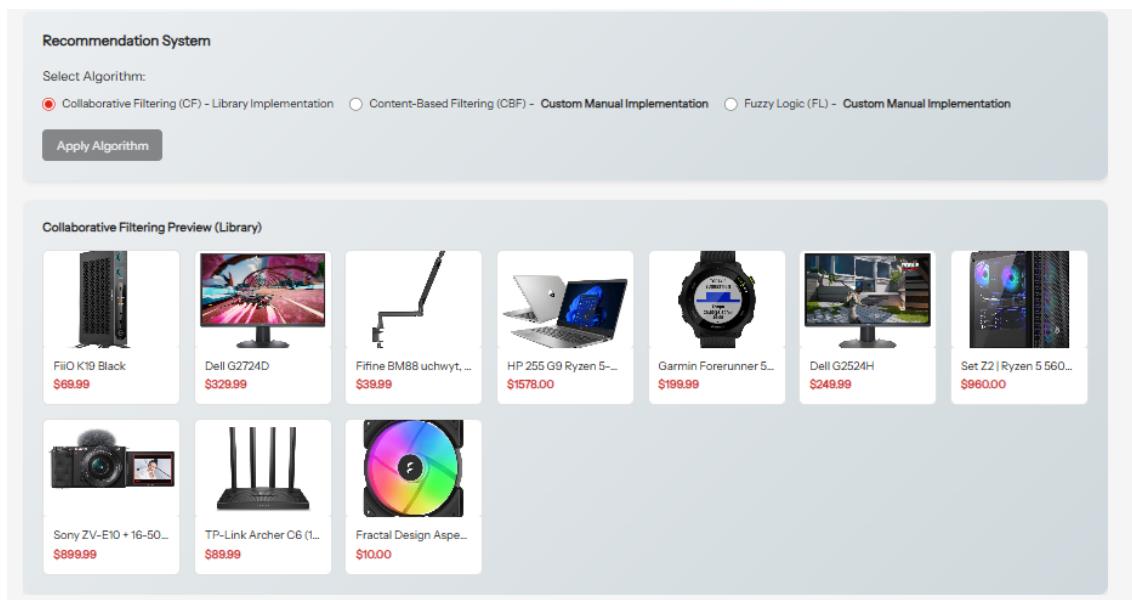
- `/api/generate-user-recommendations/` - generowanie rekomendacji Collaborative Filtering,
- `/api/sentiment-search/` - wyszukiwanie produktów według sentymentu,
- `/api/frequently-bought-together/` - produkty z reguł asocjacyjnych Apriori,
- `/api/recommendation-algorithm-status/` - status algorytmów i debugowanie,
- `/api/admin/update-product-similarity/` - regeneracja macierzy podobieństw.

Warstwa danych (PostgreSQL) - tabele przechowujące prekalkulowane wyniki:

- `method_product_similarity` - macierz podobieństw Collaborative Filtering,
- `method_product_sentiment_summary` - zagrégowany sentyment,
- `method_productassociation` - reguły Apriori,
- `method_recommendation_settings` - konfiguracja aktywnej metody.

6.2 Konfiguracja metod rekomendacji w panelu administratora

Panel administracyjny umożliwia dynamiczne przełączanie między trzema metodami rekomendacji wyświetlonymi na stronie głównej aplikacji.



Rysunek 8: Panel zarządzania metodami rekomendacji.

Rysunek 8 przedstawia panel konfiguracji z opcjami metod rekomendacyjnych. Administrator może wybrać aktywny algorytm, który będzie wykorzystywany we wszystkich sekcjach rekomendacji na stronie głównej. System zawiera łącznie sześć metod rekomendacyjnych zaimplementowanych w ramach dwóch prac inżynierskich. W ramach niniejszej pracy zaimplementowano:

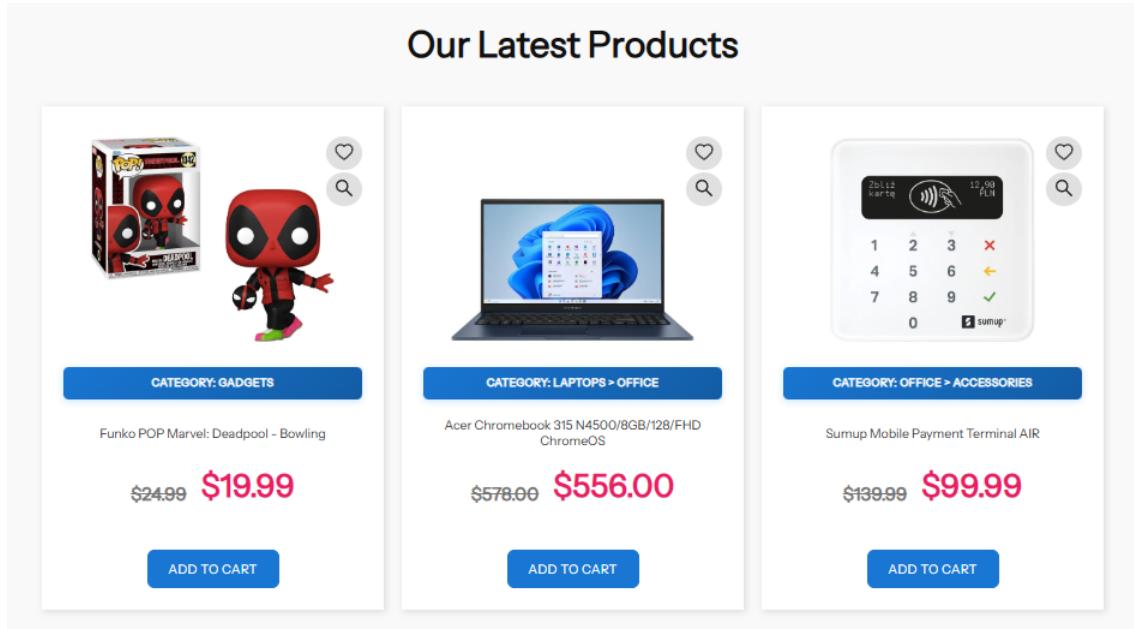
- **Collaborative Filtering** - rekomendacje oparte na historii zakupów użytkowników (opisane w niniejszej pracy).

Pozostałe metody (Content-Based Filtering, Fuzzy Logic) zostały zaimplementowane przez współautora systemu i opisane w odrębnej pracy inżynierskiej.

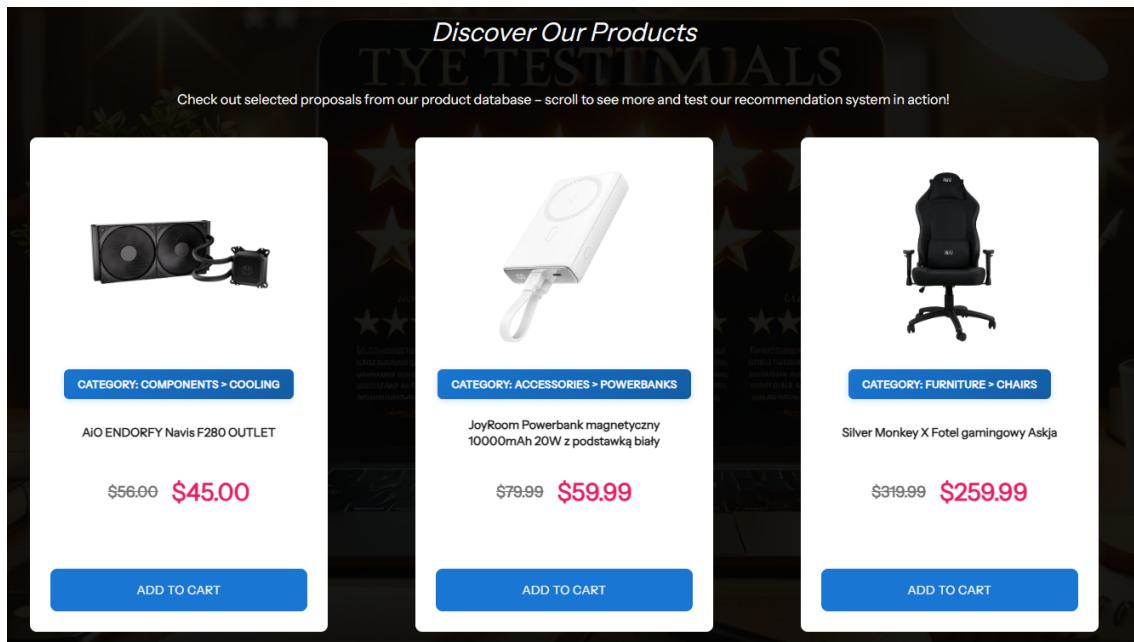
Zmiana metody następuje natychmiast po zapisaniu ustawień i wpływa na wszystkie sekcje rekomendacji w aplikacji.

6.3 Metoda Collaborative Filtering - Item-Based

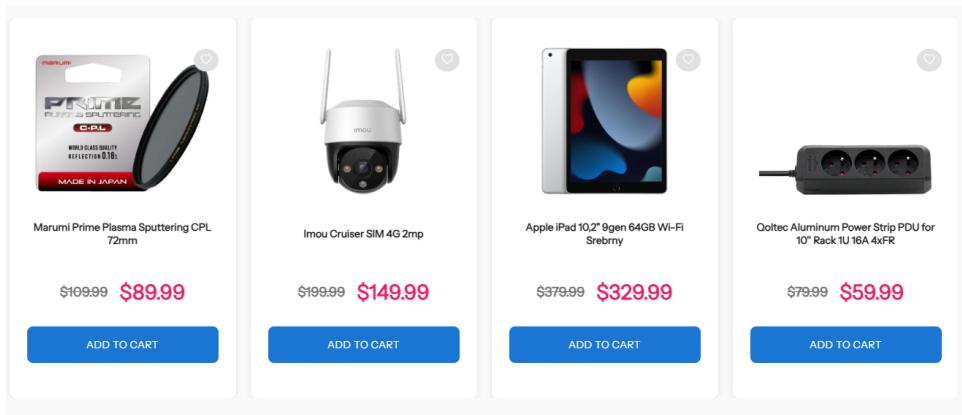
Widok strony głównej z rekomendacjami



Rysunek 9: Strona główna - pierwsza sekcja rekomendacji.



Rysunek 10: Strona główna - druga sekcja rekomendacji.



Rysunek 11: Strona główna - trzecia sekcja rekomendacji.

Rysunki 9, 10 i 11 pokazują trzy sekcje rekomendacji na stronie głównej. Wszystkie sekcje wyświetlają produkty dobrane według metody wybranej w panelu administratora (rys. 8). Gdy administrator wybierze Collaborative Filtering, wszystkie trzy sekcje będą prezentowały produkty dobrane według tej metody. Produkty są dobierane dynamicznie na podstawie podobieństwa obliczonego algorytmem Item-Based Collaborative Filtering z metryką Adjusted Cosine Similarity.

Panel debugowania Collaborative Filtering

Name:	Collaborative Filtering (Item-Based, Sarwar et al. 2001)
Formula:	Adjusted Cosine Similarity with Mean-Centering
Status:	Success 1

Total Users:	20
Total Products:	500
Total Order Items:	581
Users with Purchases:	20
Total Purchases:	568

Shape:	(20, 500)
Total Cells:	10000
Non-Zero Cells:	568
Sparsity:	94.32%

Rysunek 12: Panel debugowania Collaborative Filtering - formula algorytmu i dane z bazy.

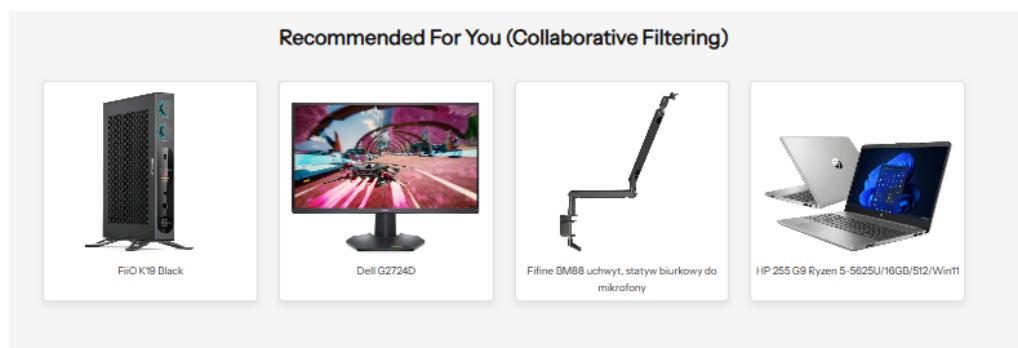
Rysunek 12 przedstawia sekcję debugowania algorytmu Collaborative Filtering w panelu administratora. Pod numerem (1) widoczna jest nazwa algorytmu „Item-Based Collaborative Filtering”, formuła matematyczna Adjusted Cosine Similarity oraz status wykonania. Pod numerem (2) znajdują się dane z bazy danych - tabela `method_product_similarity` zawierająca pary produktów wraz z obliczonymi współczynnikami podobieństwa oraz fragment macierzy podobieństw w formacie wizualnym.



Rysunek 13: Panel debugowania Collaborative Filtering - podsumowanie obliczeń.

Rysunek 13 pokazuje drugą część panelu debugowania Collaborative Filtering. System wyświetla podsumowanie macierzy, statystyki cache oraz przykład rekommendacji dla pierwszego użytkownika z bazy danych.

Rekomendacje w panelu klienta



Rysunek 14: Dashboard klienta z sekcją rekommendacji.

Rysunek 14 przedstawia dashboard klienta z sekcją spersonalizowanych rekommendacji. Produkty są dobierane na podstawie pełnej historii zakupów użytkownika z zastosowaniem metody Collaborative Filtering.

6.4 Metoda analizy sentymentu

Interfejs opinii w aplikacji

System opinii jest zintegrowany w dwóch kluczowych miejscach interfejsu użytkownika. Użytkownicy mogą dodawać opinie bezpośrednio w panelu klienta po zakupie produktu oraz przeglądać wszystkie opinie na karcie produktu.

The screenshot shows a user interface for adding a product review. At the top, it says "Add Product Review" and has a red "X" button. Below that, it asks "Write a Review for Set Z8 | Ryzen 7 7800X3D, RX 7900 XTX 24GB, 32GB DDR5, 2TB SSD, Regnum 400 ARGB, 1000W". It then asks "Your Rating:" followed by five star icons. Below that is a section for "Your Review:" with a text input field containing placeholder text "What did you think about this product? (minimum 3 characters)". At the bottom are "Cancel" and "Submit Review" buttons.

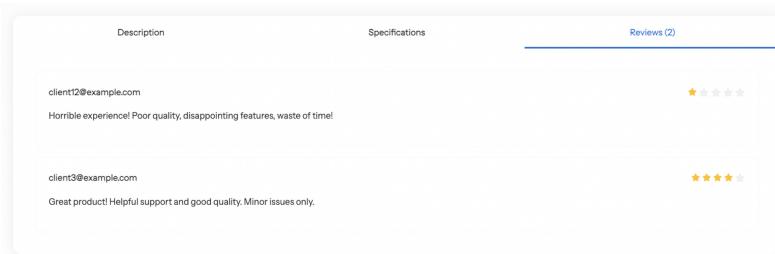
Rysunek 15: Formularz dodawania opinii na stronie produktu z oceną gwiazdkową i recenzją tekstową.

Rysunek 15 przedstawia sekcję dodawania opinii na karcie produktu. Użytkownik może:

- wystawić ocenę gwiazdkową (1-5 gwiazdek),
- napisać szczegółową recenzję tekstową.

Po dodaniu opinii przez użytkownika, system automatycznie:

- Przetwarza tekst opinii algorytmem analizy sentymentu,
- Oblicza sentiment_score w zakresie [-1, 1] według wzoru (2) z rozdziału 1.3,
- Klasyfikuje opinię jako positive/neutral/negative,
- Aktualizuje statystyki sentymentu produktu w tabeli `ProductSentimentSummary`,
- Przelicza zagregowany wynik sentymentu produktu zgodnie ze wzorem (3) z rozdziału 1.3,
- Odświeża ranking produktów w wyszukiwarce (jeśli sortowanie ustawione na „sentiment_desc”).



Rysunek 16: Lista opinii produktu z badge'ami sentymentu i oceną gwiazdkową.

Rysunek 16 pokazuje listę wszystkich opinii dla danego produktu. Każda opinia wyświetla:

- Email użytkownika,
- Ocenę gwiazdkową,
- Pełną treść recenzji.

System opinii jest kluczowy dla dwóch aspektów aplikacji:

1. **Social Proof** - budowanie zaufania poprzez autentyczne recenzje klientów,
2. **Machine Learning** - opinie stanowią 40% wagi w wieloźródłowej agregacji sentymentu (najważniejsze źródło zgodnie ze wzorem (3) z rozdziału 1.3).

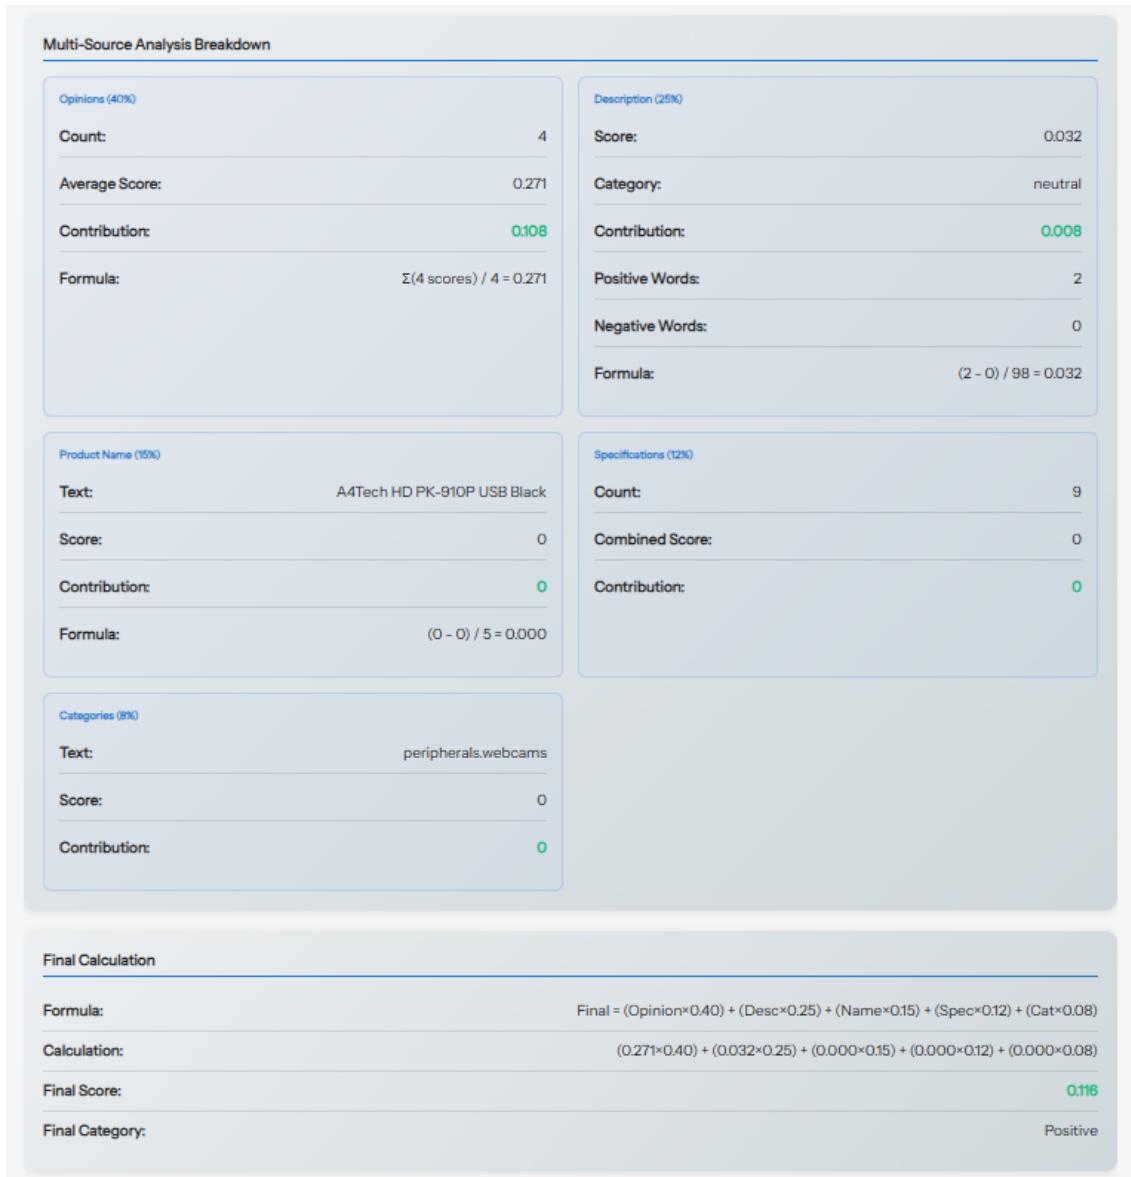
Wyszukiwarka z sortowaniem według sentymentu

Product	Price	Sentiment Score	Opinions	Review Breakdown
Gigabyte GeForce RTX 4060 Eagle OC 8GB GDDR6	\$350.00	0.16 (Positive)	3 opinions	3 Positive 0 Neutral 0 Negative
Microsoft Surface Laptop Studio 2 i7/32GB/1TB/GeForce RTX4050	\$4900.00	0.14 (Positive)	2 opinions	2 Positive 0 Neutral 0 Negative
Gainward GeForce RTX 4080 Super Panther OC 16GB GDDR6X	\$1025.00	0.14 (Positive)	5 opinions	3 Positive 1 Neutral 1 Negative

Rysunek 17: Wyszukiwarka produktów z sortowaniem według sentymentu.

Rysunek 17 przedstawia wyszukiwarkę z wynikami posortowanymi według zgregowanego sentymentu. Każdy produkt wyświetla wynik sentiment score, kategorię oraz rozkład opinii.

Panel debugowania analizy sentymenu



Rysunek 18: Panel debugowania analizy sentymenu.

Rysunek 18 pokazuje panel debugowania analizy sentymenu. Administrator może wybrać dowolny produkt z listy rozwijanej i sprawdzić wynik zagregowany, status kategorii oraz szczegółowe informacje z poszczególnych źródeł tekstowych.

6.5 Metoda reguł asocjacyjnych (Apriori)

Widok rekomendacji Apriori na stronie produktu

The screenshot shows a product page with a shopping cart summary and a 'Frequently Bought Together' section.

Product	Name	Quantity	Total Price	Remove
	ASUS PRIME B550-PLUS	- 1 +	\$100.00	X
	Elgato Facecam MK.2	- 1 +	\$199.99	X
	Fellowes LX200	- 1 +	\$59.99	X

1

Frequently Bought Together			
	Sony KD-65X75WL 65" LED 4K Google TV Dolby Vision...	\$1499.99	Confidence: 100% Lift: 76.50x Support: 0.7%
	Hisense 55E7/Q PRO 55" QLED 4K 144Hz VIDAA Full...	\$799.99	Confidence: 100% Lift: 56.50x Support: 0.7%
	ICY BOX Hub 4-port USB-A	\$14.99	Confidence: 100% Lift: 76.50x Support: 0.7%
	Senor Desk Calculator	\$14.99	Confidence: 50% Lift: 76.50x Support: 0.7%

2

Rysunek 19: Sekcja „Frequently Bought Together” na stronie produktu.

Rysunek 19 przedstawia sekcję „Frequently Bought Together” na stronie produktu. Pod numerem (1) widoczne są produkty dodane przez użytkownika do koszyka. Pod numerem (2) system wyświetla produkty proponowane na podstawie reguł asocjacyjnych wraz z metrykami lift, support i confidence.

Panel zarządzania regułami asocjacyjnymi

The screenshot shows the 'Association Rules Management' panel with a table of generated rules.

Product 1	Product 2	Support	Confidence	Lift
Sony ZV-E10 + 16-50mm	Set Z2 Ryzen 5 5600, RTX 4060 8GB, 16GB DDR4, 1TB SSD, Signum 300 ARGB, 750W	0.7%	100.0%	153.00
HP 255 G9 Ryzen 5-5625U/16GB/512/Win11	Razer Basilisk V3	0.7%	100.0%	153.00
Razer Basilisk V3	HP 255 G9 Ryzen 5-5625U/16GB/512/Win11	0.7%	100.0%	153.00
Toshiba P300 1TB 7200obr. 64MB	HP 255 G9 Ryzen 5-5625U/16GB/512/Win11	0.7%	100.0%	153.00
HP 255 G9 Ryzen 5-5625U/16GB/512/Win11	Toshiba P300 1TB 7200obr. 64MB	0.7%	100.0%	153.00
HP 255 G9 Ryzen 5-5625U/16GB/512/Win11	soundcore Boom 2 czarny	0.7%	100.0%	153.00
soundcore Boom 2 czarny	HP 255 G9 Ryzen 5-5625U/16GB/512/Win11	0.7%	100.0%	153.00
Toshiba P300 1TB 7200obr. 64MB	Razer Basilisk V3	0.7%	100.0%	153.00
Razer Basilisk V3	Toshiba P300 1TB 7200obr. 64MB	0.7%	100.0%	153.00
soundcore Boom 2 czarny	Razer Basilisk V3	0.7%	100.0%	153.00

1 **2**

Rysunek 20: Panel administracyjny zarządzania regułami Apriori.

Rysunek 20 pokazuje panel administracyjny z listą wygenerowanych reguł asocjacyjnych. Pod numerem (1) znajduje się lista par produktów często kupowanych razem. Pod numerem (2) wyświetlane są szczegółowe metryki każdej reguły - support, confidence i lift.

Panel debugowania reguł asocjacyjnych

The screenshot shows the 'Association Rules' tab selected in the top navigation bar. The main area is titled 'Association Rules Debug Information'. A red box labeled '1' highlights the 'Select Product to Inspect' section, which contains a dropdown menu showing 'A4Tech HD PK-910P USB Black'. Below this, a red box labeled '2' highlights the 'Database Statistics' section, which displays various metrics: All Orders in Database (200), Single Product Orders (47), Multi-Product Orders (153), and Total Rules in System (500). A note at the bottom of this section states: 'Algorithm uses only 153 orders with 2+ products (excludes 47 single-product orders)'. At the bottom, another red box labeled '2' highlights the 'Algorithm Behavior' section, which provides filtering, reason, and impact details.

Category	Value
All Orders in Database	200
Single Product Orders	47
Multi-Product Orders	153
Total Rules in System	500

Algorithm uses only 153 orders with 2+ products (excludes 47 single-product orders)

Filtering	Reason	Impact
Association rules ONLY use orders with 2+ products	Single-product orders cannot show 'bought together' patterns	Using 153 transactions instead of 200 total orders

Rysunek 21: Panel debugowania Apriori - wybór produktu i dane z bazy.

Rysunek 21 przedstawia pierwszy ekran panelu debugowania algorytmu Apriori. Pod numerem (1) administrator wybiera produkt z listy rozwijanej. Poniżej system wyświetla dane produktu z bazy danych, obliczenia transakcji oraz wszystkie reguły asocjacyjne dla wybranego produktu.

Top 10 Association Rules for This Product

Rank	Product	Support	Confidence	Lift
1	Brother HL-L8260CDW	0.65%	100.0%	153.00x
2	TP-Link Archer C6 (1200Mb/s a/b/g/n/ac) DualBand	0.65%	100.0%	153.00x

Detailed Rule Analysis

Rule #1: A4Tech HD PK-910P USB Black → Brother HL-L8260CDW

Support Formula:	$\text{Support}(A,B) = \frac{\text{Transactions with both products}}{\text{Total transactions}}$	$\text{Support}(A,B) = 1/153 = 0.0065$
Confidence Formula:	$\text{Confidence}(A \rightarrow B) = \frac{\text{Support}(A,B)}{\text{Support}(A)}$	$\text{Confidence}(A \rightarrow B) = \frac{0.0065}{0.0065} = 1.0$
Lift Formula:	$\text{Lift}(A \rightarrow B) = \frac{\text{Support}(A,B)}{(\text{Support}(A) \times \text{Support}(B))}$	$\text{Lift}(A \rightarrow B) = \frac{0.0065}{(0.0065 \times 0.0065)} = 153.0$
Support:	0.65% of transactions contain both products	
Confidence:	If customer buys A4Tech HD PK-910P USB Black, there's 100.0% chance they'll buy Brother HL-L8260CDW	
Lift:	Products are bought together 153.0x more than random chance	

Rule #2: A4Tech HD PK-910P USB Black → TP-Link Archer C6 (1200Mb/s a/b/g/n/ac) DualBand

Support Formula:	$\text{Support}(A,B) = \frac{\text{Transactions with both products}}{\text{Total transactions}}$	$\text{Support}(A,B) = 1/153 = 0.0065$
Confidence Formula:	$\text{Confidence}(A \rightarrow B) = \frac{\text{Support}(A,B)}{\text{Support}(A)}$	$\text{Confidence}(A \rightarrow B) = \frac{0.0065}{0.0065} = 1.0$
Lift Formula:	$\text{Lift}(A \rightarrow B) = \frac{\text{Support}(A,B)}{(\text{Support}(A) \times \text{Support}(B))}$	$\text{Lift}(A \rightarrow B) = \frac{0.0065}{(0.0065 \times 0.0065)} = 153.0$
Support:	0.65% of transactions contain both products	
Confidence:	If customer buys A4Tech HD PK-910P USB Black, there's 100.0% chance they'll buy TP-Link Archer C6 (1200Mb/s a/b/g/n/ac) DualBand	
Lift:	Products are bought together 153.0x more than random chance	

Association Rules (Formulas)

Support

$$\text{Support}(A, B) = \frac{|A \cap B|}{n} = \frac{\text{Transactions with both products}}{\text{Total transactions}}$$

Measures how frequently both products appear together in transactions.

Confidence

$$\text{Confidence}(A \rightarrow B) = \frac{|A \cap B|}{|A|} = \frac{\text{Support}(A, B)}{\text{Support}(A)}$$

Probability of buying B when A is purchased.

Lift

$$\text{Lift}(A \rightarrow B) = \frac{\text{Confidence}(A \rightarrow B)}{\text{Support}(B)}$$

How many times more likely B is purchased with A compared to random chance.

Rysunek 22: Panel debugowania Apriori - top 10 reguł i szczegółowe analizy.

Rysunek 22 pokazuje drugą część panelu debugowania Apriori. Pod numerem (1) znajduje się ranking top 10 reguł asocjacyjnych dla wybranego produktu posortowanych według lift. Pod numerem (2) wyświetlane są szczegółowe analizy reguł dla produktów, w tym rozkład wartości lift, średnie metryki oraz porównanie z globalnymi statystykami.

6.6 Mechanizmy optymalizacji systemu

System wykorzystuje mechanizmy optymalizacji dla zapewnienia wydajności:

Prekalkulacja w bazie danych

Wszystkie trzy algorytmy zapisują wyniki do dedykowanych tabel z indeksami przyspieszającymi zapytania:

- `method_product_similarity` - macierz podobieństw Collaborative Filtering,
- `method_productassociation` - reguły asocjacyjne Apriori,
- `method_product_sentiment_summary` - zagregowany sentyment produktów.

Django Signals - automatyczna aktualizacja

System wykorzystuje mechanizm Django Signals do automatycznego przeliczania rekomendacji po zmianach danych:

- Nowe zamówienie - przeliczenie macierzy Collaborative Filtering,
- Nowa opinia - aktualizacja sentymetu produktu,
- Nowy produkt - automatyczna analiza sentymetu opisu i nazwy.

Operacje zbiorcze

System używa operacji zbiorczych (bulk operations) dla zapisu wielu rekordów jednocześnie, co znacząco przyspiesza operacje zapisu do bazy danych.

6.7 Podsumowanie funkcjonowania systemu

Zaimplementowany system rekomendacji charakteryzuje się:

Kompletnością zarządzania:

- Panel administratora z dynamicznym przełączaniem metod,
- Sekcje debugowania dla wszystkich trzech algorytmów,
- Wizualizacja metryk i statystyk w czasie rzeczywistym.

Integracją w aplikacji:

- Strona główna z konfigurowalnymi rekomendacjami,
- Dashboard klienta z personalizacją,
- Wyszukiwarka z sortowaniem według sentymetu,
- Sekcje „Frequently Bought Together” oparte na Apriori.

Narzędziami diagnostycznymi:

- Podgląd macierzy podobieństw Collaborative Filtering,
- Analiza źródeł sentymentu dla każdego produktu,
- Ranking reguł asocjacyjnych z metrykami,
- Statystyki wykonania algorytmów.

System jest w pełni funkcjonalny i gotowy do wdrożenia w środowisku produkcyjnym.

Rozdział 7

Podsumowanie i wnioski końcowe

Niniejsza praca przedstawiła proces implementacji oraz analizy kompletnego systemu e-commerce wyposażonego w mechanizmy rekommendacji produktów. System został opracowany od podstaw we współpracy dwuosobowej, przy czym w ramach niniejszej pracy zaimplementowano trzy metody rekommendacyjne: Collaborative Filtering z metryką Adjusted Cosine Similarity, analizę sentymentu opartą na podejściu słownikowym oraz reguły asocjacyjne wykorzystujące algorytm Apriori.

Ograniczenia systemu

W trakcie realizacji projektu zidentyfikowano następujące ograniczenia:

Problem zimnego startu — algorytmy Collaborative Filtering oraz Apriori wymagają historycznych danych o interakcjach użytkowników z produktami. Dla nowych użytkowników bez historii zakupów oraz nowych produktów bez opinii mechanizmy te nie są w stanie generować efektywnych rekommendacji. Analiza sentymentu częściowo kompensuje to ograniczenie, ponieważ może ocenić jakość produktu na podstawie jego opisu, specyfikacji technicznych oraz nazwy, nawet w przypadku braku opinii użytkowników.

Ograniczenia analizy sentymentu — zastosowane podejście słownikowe nie radzi sobie efektywnie z negacją językową (przykład: „nie polecam”) oraz z ironią i sarkazmem. Słowa pozytywne w kontekście negatywnym mogą być błędnie klasyfikowane, co wpływa na dokładność oceny sentymentu. Rozwiążanie tego problemu wymagałoby zastosowania bardziej zaawansowanych technik przetwarzania języka naturalnego, takich jak modele kontekstowe.

Skalowalność dla bardzo dużych katalogów — dla katalogów produktów przekraczających tysiące pozycji mogą wystąpić wyzwania wydajnościowe wymagające dalszych optymalizacji, takich jak partycjonowanie danych, rozproszenie obliczeń lub zastosowanie dedykowanych struktur danych.

Kierunki dalszego rozwoju

Zidentyfikowano następujące kierunki rozwoju systemu:

Zastosowanie głębokiego uczenia maszynowego — obecny system wykorzystuje klasyczne algorytmy rekommendacyjne oparte na analizie podobieństw oraz regułach asocjacyjnych. Zastosowanie sieci neuronowych, takich jak autoencodery czy sieci rekurencyjne, mogłoby umożliwić automatyczne uczenie się ukrytych wzorców w danych bez konieczności ręcznego definiowania reguł. Przykładowo, sieci neu-

ronowe mogłyby odkryć nieoczywiste zależności między produktami oraz preferencjami użytkowników, które nie są widoczne w tradycyjnych metrykach podobieństwa.

Rekomendacje w czasie rzeczywistym — obecny system wykorzystuje mechanizm cache'owania z okresem ważności 2 godzin (CACHE_TIMEOUT_LONG = 7200 sekund), co oznacza, że rekomendacje są przeliczane cyklicznie. Implementacja systemu aktualizującego rekomendacje w czasie rzeczywistym po każdej akcji użytkownika (przeglądanie produktów, dodawanie do koszyka, finalizacja zakupu) mogłaby znaczco zwiększyć trafność sugestii poprzez uwzględnienie bieżącego kontekstu sesji zakupowej.

Zaawansowane metody obsługi zimnego startu — zastosowanie technik faktoryzacji macierzy, takich jak Singular Value Decomposition (SVD), mogłyby umożliwić generowanie rekomendacji dla nowych produktów na podstawie ich cech (kategoria, cena, marka, specyfikacja) oraz analogii do istniejących produktów w katalogu.

Wnioski końcowe

Zrealizowany system stanowi kompletne rozwiązanie e-commerce z autorskimi mechanizmami rekomendacji produktów, gotowe do wdrożenia w środowisku produkcyjnym. Implementacja od podstaw bez wykorzystania gotowych bibliotek rekomendacyjnych umożliwiła pełne zrozumienie mechanizmów działania algorytmów oraz ich świadome dostosowanie do specyfiki handlu elektronicznego. Kompletność zastosowanych metod — Collaborative Filtering dla identyfikacji produktów podobnych, analiza sentymentu dla oceny jakości oraz algorytm Apriori dla cross-sellingu — zapewnia wszechstronne wsparcie procesu decyzyjnego użytkownika. Zastosowane techniki optymalizacyjne, w tym bitmap pruning, cache'owanie oraz indeksowanie bazy danych, gwarantują akceptowalne czasy odpowiedzi systemu nawet przy większych katalogach produktów.

Praca wykazała, że implementacja systemu rekomendacyjnego od podstaw jest możliwa i celowa w kontekście edukacyjnym oraz w sytuacjach wymagających pełnej kontroli nad logiką biznesową. Zrealizowany projekt pozwolił na zdobycie praktycznej wiedzy w zakresie projektowania systemów rekomendacyjnych, optymalizacji algorytmów, rozwoju aplikacji.

Literatura

- [1] Rakesh Agrawal, Ramakrishnan Srikant, *Fast Algorithms for Mining Association Rules*, Proceedings of the 20th International Conference on Very Large Data Bases (VLDB), 1994.
- [2] James Bennett, Stan Lanning, *The Netflix Prize*, Proceedings of KDD Cup and Workshop, 2007.
- [3] Jonathan L. Herlocker, Joseph A. Konstan, John Riedl, *Explaining Collaborative Filtering Recommendations*, Proceedings of the 2000 ACM Conference on Computer Supported Cooperative Work (CSCW), 2000.
- [4] Greg Linden, Brent Smith, Jeremy York, *Amazon.com Recommendations: Item-to-Item Collaborative Filtering*, IEEE Internet Computing, 2003.
- [5] Bing Liu, *Sentiment Analysis and Opinion Mining*, Synthesis Lectures on Human Language Technologies, Morgan & Claypool Publishers, 2012.
- [6] Jacques Bughin, Michael Chui, James Manyika, *Ten IT-enabled business trends for the decade ahead*, McKinsey Quarterly, May 2013.
- [7] Paul Resnick, Hal R. Varian, *Recommender Systems*, Communications of the ACM, 1997.
- [8] Badrul Sarwar, George Karypis, Joseph Konstan, John Riedl, *Item-based Collaborative Filtering Recommendation Algorithms*, Proceedings of the 10th International Conference on World Wide Web (WWW), 2001.
- [9] Mohammed J. Zaki, *Scalable Algorithms for Association Mining*, IEEE Transactions on Knowledge and Data Engineering, 2000.

Wykaz rysunków

Spis rysunków

1	Diagram przypadków użycia systemu.	16
2	Diagram ERD głównych tabel aplikacji.	27
3	Diagram ERD tabel metod rekomendacyjnych.	28
4	Deployment aplikacji w architekturze Docker Compose.	29
5	Diagram sekwencji: Collaborative Filtering.	34
6	Diagram sekwencji: Analiza sentymentu.	37
7	Diagram sekwencji: Algorytm Apriori.	41
8	Panel zarządzania metodami rekomendacji.	45
9	Strona główna - pierwsza sekcja rekomendacji.	46
10	Strona główna - druga sekcja rekomendacji.	46
11	Strona główna - trzecia sekcja rekomendacji.	47
12	Panel debugowania Collaborative Filtering - formuła algorytmu i dane z bazy.	47
13	Panel debugowania Collaborative Filtering - podsumowanie obliczeń.	48
14	Dashboard klienta z sekcją rekomendacji.	48
15	Formularz dodawania opinii na stronie produktu z oceną gwiazdkową i recenzją teksturową.	49
16	Lista opinii produktu z badge'ami sentymentu i oceną gwiazdkową.	50
17	Wyszukiwarka produktów z sortowaniem według sentymentu.	50
18	Panel debugowania analizy sentymentu.	51
19	Sekcja „Frequently Bought Together” na stronie produktu.	52
20	Panel administracyjny zarządzania regułami Apriori.	52
21	Panel debugowania Apriori - wybór produktu i dane z bazy.	53
22	Panel debugowania Apriori - top 10 reguł i szczegóły analizy.	54

Streszczenie

Tytuł pracy w języku polskim:

System rekomendacji produktów oparty na filtracji współpracy, analizie sentymentu i regułach asocjacyjnych

Tytuł pracy w języku angielskim:

Product Recommendation System Based on Collaborative Filtering, Sentiment Analysis, and Association Rules

Streszczenie:

Niniejsza praca inżynierska przedstawia projekt oraz implementację systemu rekomendacji produktów dla platformy e-commerce, łączącego trzy komplementarne metody rekomendacyjne: collaborative filtering, analizę sentymentu oraz reguły asocjacyjne. Celem było zaprojektowanie rozwiązania eliminującego problem przeładowania informacyjnego w sklepach internetowych poprzez dostarczanie użytkownikom spersonalizowanych rekomendacji.

Część teoretyczna obejmuje szczegółową analizę fundamentów matematycznych systemów rekomendacyjnych, w tym metryki Adjusted Cosine Similarity dla algorytmu Item-Based Collaborative Filtering, słownikowej analizy sentymentu z agregacją wieloźródłową oraz metryk support, confidence i lift dla reguł asocjacyjnych algorytmu Apriori. Przedstawiono również przegląd rozwiązań alternatywnych (Amazon Personalize, Google Recommendations AI, Apache Mahout) wraz z uzasadnieniem implementacji dedykowanego systemu.

Część praktyczna obejmuje implementację aplikacji webowej w architekturze Django REST Framework (backend) oraz React 18 (frontend) z bazą danych PostgreSQL. Zaimplementowano trzy algorytmy działające komplementarnie: Collaborative Filtering identyfikuje produkty podobne na podstawie wzorców zakupowych, analiza sentymentu agreguje oceny jakości z pięciu źródeł tekstowych, a algorytm Apriori odkrywa produkty często kupowane razem.

System został wyposażony w kompletny interfejs oferujący rekomendacje Collaborative Filtering w sekcjach strony głównej, rekomendacje Apriori w koszyku zakupowym, wyszukiwarkę z filtrowaniem według sentymentu oraz panel administracyjny z narzędziami debugowania algorytmów.

Wartością pracy jest implementacja algorytmów od podstaw, co umożliwiło głębokie zrozumienie mechanizmów oraz świadomie dostosowanie do specyfiki e-commerce.

Słowa kluczowe:

systemy rekomendacji, collaborative filtering, analiza sentymentu, algorytm Apriori, machine learning, e-commerce, Django, React, PostgreSQL