



Dawid Olko
nr albumu: 125148
Kierunek: Informatyka

System rekomendacji produktów oparty na filtracji współpracy, analizie sentymentu i regułach asocjacyjnych

Praca inżynierska

Praca wykonana pod kierunkiem
dr inż. Piotra Grochowskiego

Rzeszów, 2026

Spis treści

Wstęp	3
Rozdział 1: Teoretyczne podstawy systemów rekomendacyjnych	5
Rozdział 2: Weryfikacja i analiza rozwiązań alternatywnych	7
Rozdział 3: Opis projektu planowanej aplikacji	12
3.1 Cel i zakres aplikacji	12
3.2 Typy użytkowników systemu	12
3.3 Wymagania funkcjonalne systemu	13
3.4 Diagram przypadków użycia	16
3.5 Architektura funkcjonalna systemu	17
3.6 Struktura bazy danych	18
Rozdział 4: Przedstawienie wykorzystanego stosu technologicznego oraz praktycznej realizacji projektu	22
4.1 Architektura systemu	22
4.2 Stos technologiczny backendu	22
4.3 Stos technologiczny frontendu	23
4.4 Baza danych PostgreSQL	24
4.5 Projekt techniczny systemu	24
4.5 Deployment i konteneryzacja Docker	25
4.7 Architektura i przepływ danych systemu rekomendacji	26
Rozdział 5: Implementacja algorytmów rekomendacji	29
5.1 Collaborative Filtering - Item-Based z Adjusted Cosine	30
5.2 Analiza Sentymentu - wieloźródłowa agregacja	33
5.3 Algorytm Apriori - reguły asocjacyjne	36
Rozdział 6: Funkcjonowanie systemu rekomendacji w praktyce	41
6.1 Metoda Collaborative Filtering - Item-Based	41
6.2 Metoda analizy sentymentu	45
6.3 Metoda reguł asocjacyjnych (Apriori)	48
6.4 Konfiguracja metod rekomendacji w panelu administratora	51
Rozdział 7: Porównanie i ewaluacja metod rekomendacyjnych	53
Rozdział 8: Podsumowanie i wnioski końcowe	59
Literatura	61
Streszczenie	63
Załącznik A: Szczegółowe scenariusze użycia	64

Wstęp

Nowoczesne platformy e-commerce oferują tysiące lub dziesiątki tysięcy produktów, co stanowi istotne wyzwanie zarówno dla klientów, jak i właścicieli sklepów internetowych. Użytkownik poszukujący smartfona staje przed wyborem setek modeli, w przypadku laptopów sytuacja wygląda podobnie. Bez wsparcia inteligentnych systemów rekomendacyjnych proces zakupowy staje się czasochłonny i frustrujący, co często prowadzi do rezygnacji z zakupu. Z perspektywy biznesowej oznacza to utratę potencjalnych klientów oraz sytuacje, w których nabywcy nie odkrywają produktów optymalnie dopasowanych do ich potrzeb.

Systemy rekomendacyjne stanowią rozwiązanie tego problemu poprzez automatyczną analizę historii zakupów, opinii oraz zachowań użytkowników w celu proponowania produktów o najwyższej wartości dla konkretnego klienta.

Cel pracy

Celem niniejszej pracy jest zaprojektowanie, implementacja oraz analiza kompletnego systemu e-commerce wyposażonego w mechanizmy rekomendacji produktów. Aplikacja została opracowana od podstaw we współpracy dwuosobowej, w ramach której części frontendu, backendu oraz bazy danych zostały zrealizowane wspólnie, natomiast metody rekomendacyjne były implementowane przez każdego z osobna. Zaimplementowano łącznie sześć różnych metod rekomendacyjnych, niniejsza praca koncentruje się na trzech spośród nich: Collaborative Filtering, analizie sentymentu oraz regułach asociacyjnych. Mechanizmy rekomendacyjne zostały zaprojektowane i zaimplementowane samodzielnie na podstawie literatury naukowej, bez wykorzystania gotowych bibliotek rekomendacyjnych, co umożliwiło pełną kontrolę nad logiką algorytmów oraz ich świadomego dostosowanie do specyfiki branży handlu elektronicznego.

Zakres pracy

Zakres funkcjonalny systemu obejmuje:

Implementację trzech metod rekomendacyjnych:

- Collaborative Filtering w wariancie Item-Based z metryką Adjusted Cosine Similarity [8] — metoda analizuje wzorce zakupowe użytkowników w celu identyfikacji produktów podobnych do wcześniej nabytych,
- Analizę sentymentu opartą na podejściu słownikowym [5] — metoda agreguje ocenę jakości produktu z pięciu źródeł tekstowych (opinie, opis, nazwa, specyfikacje, kategorie), rozwiązując problem zimnego startu dla produktów bez historii opinii,

- Reguły asocjacyjne wykorzystujące algorytm Apriori [1] — metoda odkrywa wzorce współwystępowania produktów w koszyku zakupowym, wspierając strategie cross-sellingu.

Opracowanie kompletnej aplikacji webowej:

- Backend oparty na Django REST Framework zapewniający API dla wszystkich funkcjonalności systemu,
- Frontend w technologii React 18 oferujący responsywny interfejs użytkownika,
- Baza danych PostgreSQL z odpowiednio zaprojektowanym schematem przechowującym dane produktów, użytkowników, zamówień oraz wyniki algorytmów rekommendacyjnych.

Rozdział 1

Teoretyczne podstawy systemów rekomendacyjnych

Historia i ewolucja systemów rekomendacyjnych

Systemy rekomendacyjne powstały jako odpowiedź na problem wyboru spośród tysięcy produktów w sklepach internetowych. Rozwój tej dziedziny rozpoczął się w latach 90. XX wieku wraz z pojawiением się pierwszych platform e-commerce. Wczesne zastosowania komercyjne systemów rekomendacji obejmowały m.in. mechanizm „klienci którzy kupili ten produkt, kupili również” zastosowany przez Amazon.com, który analizował historię zakupów w celu sugerowania powiązanych produktów, co skutkowało znaczącym wzrostem sprzedaży krzyżowej (cross-selling) oraz poprawą doświadczenia użytkowników [4]. Istotnym przełomem była również publikacja wprowadzająca metodę Item-Based Collaborative Filtering z metryką Adjusted Cosine Similarity [8], która zyskała szerokie zastosowanie w praktyce przemysłowej, szczególnie w platformach e-commerce o dużej liczbie produktów. Konkursy i inicjatywy badawcze, takie jak Netflix Prize w latach 2006-2009, w którym fundusz nagród wynosił około miliona dolarów dla zwycięzcy, znacząco przyspieszyły rozwój zaawansowanych technik rekomendacji [2], przyciągając uwagę zarówno środowiska akademickiego, jak i przemysłowego. Obecnie systemy rekomendacyjne stanowią kluczowy element wiodących platform e-commerce (handlu elektronicznego) oraz serwisów VOD (Video on Demand - video na żądanie).

Klasyfikacja metod rekomendacyjnych

Istnieją trzy główne kategorie systemów rekomendacyjnych:

Collaborative Filtering — jedna z najpopularniejszych metod w systemach komercyjnych. Zakłada, że użytkownicy o podobnych preferencjach będą mieli podobne wybory w przyszłości. Istnieją dwa warianty: oparty na użytkownikach (User-Based, porównuje użytkowników) oraz oparty na produktach (Item-Based, porównuje produkty). Zalety: odkrywa nieoczywiste powiązania między produktami. Wady: problem zimnego startu (ang. cold start) dla nowych użytkowników i produktów, macierz danych jest zazwyczaj rzadka (stopień wypełnienia zależy od liczby produktów, użytkowników oraz częstotliwości transakcji).

Content-Based Filtering — analizuje cechy produktów i dopasowuje je do profilu użytkownika. Zalety: brak problemu zimnego startu dla nowych produktów. Wady: rekomenduje tylko podobne produkty, co może prowadzić do zjawiska tzw. filter bubble (bańki filtrującej).

Metody Hybrydowe — łączą różne podejścia rekomendacyjne w celu wykorzysta-

nia zalet poszczególnych metod oraz kompensacji ich wad. Przykładem może być połączenie Collaborative Filtering z analizą metadanych produktów oraz analizą treści tekstowych.

Systemy rekomendacyjne w e-commerce wykorzystują różne strategie sprzedaży. Poniżej znajdują się kluczowe terminy stosowane w branży:

Cross-selling (sprzedaż krzyżowa) — strategia polegająca na proponowaniu produktów komplementarnych, czyli dopełniających zakup główny. Przykład: klient kupuje laptop, system proponuje mysz, torbę na laptop, podkładkę pod mysz. Celem jest zwiększenie wartości koszyka poprzez dodanie produktów powiązanych funkcjonalnie.

Up-selling (sprzedaż wyższej wartości) — strategia zachęcania klienta do zakupu droższego wariantu produktu lub wersji premium. Przykład: klient przegląda telefon za 2000 zł, system proponuje model za 2500 zł z lepszymi parametrami. Celem jest zwiększenie wartości pojedynczego zakupu, przy czym skuteczność tej strategii zależy od indywidualnych preferencji i możliwości finansowych użytkownika.

Personalizacja — dostosowanie treści i rekomendacji do indywidualnego profilu użytkownika na podstawie jego historii zakupów, przeglądanych produktów i zachowań. Przykład: dwóch użytkowników widzi różne zestawy produktów na stronie głównej. Celem jest zwiększenie trafności rekomendacji i konwersji.

Cold start problem (problem zimnego startu) — sytuacja występująca gdy nowy użytkownik lub produkt nie ma historii interakcji. Przykład: nowy użytkownik nie ma zamówień, więc Collaborative Filtering nie może efektywnie generować rekomendacji. Nowy produkt nie ma opinii, co utrudnia ocenę jego jakości. Rozwiązaniem tego problemu może być wykorzystanie metod opartych na analizie treści produktu, takich jak analiza sentimentu opisów, nazw i specyfikacji technicznych.

Frequently Bought Together (często kupowane razem) — rodzaj rekomendacji prezentujący produkty, które klienci regularnie kupują w tym samym koszyku. Przykład: laptop + mysz + podkładka pod mysz. Celem jest uproszczenie procesu zakupów i zwiększenie wartości koszyka.

Rozdział 2

Weryfikacja i analiza rozwiązań alternatywnych

W celu uzasadnienia sensowności tworzenia dedykowanego systemu rekomendacji przeprowadzono analizę trzech reprezentatywnych rozwiązań rynkowych. Celem weryfikacji było zidentyfikowanie ograniczeń istniejących narzędzi oraz określenie wymagań dla planowanej aplikacji e-commerce wykorzystującej trzy metody: Collaborative Filtering [8], analizę sentymetu [5] oraz reguły asocjacyjne [1].

Amazon Personalize

Amazon Personalize to zarządzana usługa AWS oferująca systemy rekomendacji oparte na algorytmach stosowanych w Amazon.com [4]. System wykorzystuje deep learning (głębokie uczenie - wielowarstwowe sieci neuronowe) oraz collaborative filtering, oferując trzy typy rekomendacji: User Personalization (personalizacja użytkownika), Similar Items (podobne produkty) oraz Personalized Ranking (spersonalizowane rankowanie).

Możliwości systemu: Amazon Personalize oferuje automatyczne skalowanie infrastruktury dostosowujące się do obciążenia, co pozwala obsługiwać zarówno małe sklepy internetowe, jak i platformy o skali Amazon.com. System automatycznie przetwarza dane użytkowników (kliknięcia, zakupy, wyświetlenia produktów) i generuje modele predykcyjne bez konieczności ręcznej optymalizacji hiperparametrów. Platforma zapewnia integrację z pozostałymi usługami AWS poprzez SDK dostępne w językach Python, Java, JavaScript oraz .NET, co umożliwia szybkie wdrożenie w istniejących aplikacjach. System automatycznie aktualizuje modele w czasie rzeczywistym na podstawie nowych interakcji użytkowników, zapewniając aktualność rekomendacji.

Kluczowe ograniczenia w kontekście planowanego rozwiązania:

- **Wysokie koszty operacyjne** - rozwiązania chmurowe wiążą się z regularnymi opłatami licencyjnymi, które mogą być znaczące dla małych i średnich platform e-commerce. Dla porównania, własna implementacja eliminuje te koszty przy zachowaniu kontroli nad funkcjonalnościami,
- **Brak natywnej analizy sentymetu** - Amazon Personalize koncentruje się wyłącznie na collaborative filtering i nie oferuje analizy opinii produktów. Wieloźródłowa agregacja sentymetu (opinie + opis + nazwa + specyfikacje + kategorie) zastosowana w niniejszej pracy wymaga integracji z AWS lub samodzielnej implementacji,
- **Uzależnienie od dostawcy** (ang. vendor lock-in) - głęboka integracja z ekosystemem AWS (S3, Lambda, EventBridge) oznacza, że migracja do innej platformy wymaga przepisania całej architektury systemu,

- **Brak kontroli nad algorytmami** - system działa jako „czarna skrzynka” (black box), uniemożliwiając dostosowanie logiki rekomendacji. Przykład: niemożliwe jest zaimplementowanie Adjusted Cosine Similarity z centrowaniem średniej dla eliminacji wartości progowej (bias) wynikającej z różnych skali zakupowych użytkowników (hurtownik vs konsument indywidualny),
- **Wymóg dużych zbiorów danych** - według dokumentacji AWS, system wymaga minimum 25000 interakcji dla zapewnienia wysokiej jakości rekomendacji. Dla nowych platform (cold start - problem zimnego startu) jakość jest ograniczona w początkowym okresie działania.

Google Recommendations AI (Vertex AI)

Google Recommendations AI to platforma GCP wykorzystująca deep learning oraz algorytmy wieloramiennych bandytów kontekstowych (ang. multi-armed contextual bandits). Algorytmy te dynamicznie balansują eksplorację (testowanie nowych produktów w celu poznania ich wartości) z eksploatacją (rekommendowanie produktów o udowodnionej skuteczności), co pozwala systemowi optymalizować rekomendacje w czasie rzeczywistym na podstawie feedbacku użytkowników. System oferuje zaawansowane rekommendacje dla e-commerce, VOD (Video on Demand - wideo na żądanie) oraz platform newsowych, z automatycznym wykrywaniem trendów i sezonowości.

Możliwości systemu: Platforma zapewnia automatyczne wykrywanie trendów sezonowych oraz reagowanie na zmiany w zachowaniach użytkowników bez konieczności ręcznej rekonfiguracji. System oferuje funkcję „Frequently Bought Together” (często kupowane razem), która analizuje koszyki zakupowe w sposób podobny do algorytmu Apriori. Google Recommendations AI automatycznie optymalizuje parametry modeli poprzez mechanizmy AutoML, co eliminuje potrzebę ręcznego dostrajania hiperparametrów. Platforma oferuje zaawansowane możliwości personalizacji rekommendacji z uwzględnieniem kontekstu sesji użytkownika (urządzenie, lokalizacja, pora dnia), co może zwiększać współczynnik konwersji.

Kluczowe ograniczenia w kontekście planowanego rozwiązania:

- **Model cenowy oparty na liczbie predykcji** - system rozlicza się według liczby wygenerowanych rekommendacji oraz ilości przetworzonych danych katalogowych, co może generować rosnące koszty wraz ze wzrostem ruchu użytkowników,
- **Brak wieloźródłowej agregacji sentymenu** - system nie wspiera agregacji sentymenu z wielu źródeł tekstowych (opinie, opis produktu, nazwa, specyfikacje, kategorie) jak w planowanym rozwiązaniu,
- **Wymóg bardzo dużych zbiorów danych** - rozwiązanie zaprojektowane dla platform

o skali YouTube, co czyni je nadmiarowo złożonym dla małych sklepów interneto-wych,

- **Brak interpretowalności** - głęboka „black box”, gdzie nawet administratorzy z dostępem do Vertex AI nie mogą zobaczyć wag embeddings (reprezentacji wektorowych) ani logiki sieci neuronowej, co uniemożliwia debugowanie i optymalizację.

Apache Mahout

Apache Mahout to otwartoźródłowy framework (ang. open-source framework) implementujący klasyczne algorytmy collaborative filtering [8] oraz faktoryzację macierzy (ang. matrix factorization - technika dekompozycji macierzy user-item) - ALS (Alternating Least Squares - metoda najmniejszych kwadratów na przemian), SVD (Singular Value Decomposition - rozkład według wartości osobliwych). Projekt powstał w 2008 roku, obecnie koncentruje się na algorytmach rozproszonych opartych na Apache Spark (ang. Spark-based distributed algorithms).

Możliwości systemu: Apache Mahout oferuje pełną kontrolę nad implementacją algorytmów rekomendacyjnych oraz możliwość dostosowania ich do specyficznych wymagań biznesowych. Framework eliminuje koszty licencyjne charakterystyczne dla rozwiązań komercyjnych, co czyni go atrakcyjnym dla organizacji o ograniczonym budżecie. System wykorzystuje Apache Spark do przetwarzania rozproszonych obliczeń, co umożliwia skalowanie do bardzo dużych zbiorów danych (miliony użytkowników, miliony produktów). Mahout oferuje implementacje zaawansowanych algorytmów faktoryzacji macierzy (ALS, SVD), które mogą osiągać wysoką jakość rekomendacji przy odpowiedniej konfiguracji. Jako projekt otwartoźródłowy, Mahout nie wiąże się z uzależnieniem od konkretnego dostawcy chmurowego.

Kluczowe ograniczenia w kontekście planowanego rozwiązania:

- **Wymóg zaawansowanej wiedzy technicznej** - konieczność konfiguracji klastra Apache Spark (środowisko przetwarzania rozprozonego), YARN resource manager (zarządcą zasobów), oraz monitoringu. Według Stack Overflow Developer Survey 2023, bardzo mała część programistów ma doświadczenie z Apache Spark,
- **Koszty infrastruktury** - utrzymanie klastra Spark wymaga dedykowanych zasobów serwerowych oraz czasu na implementację integracji (REST API, baza danych, cache, frontend), co generuje znaczące koszty operacyjne,
- **Brak analizy sentymentu** - Apache Mahout nie oferuje sentiment analysis. Wymagana jest integracja z zewnętrznymi bibliotekami (np. Stanford CoreNLP) lub samodzielna implementacja słownikowej analizy sentymentu,

- **Wolniejszy rozwój projektu** - według danych z lat 2023-2024, aktywność projektu spadła (2-3 commity miesięcznie vs 20-30 commitów w latach 2012-2014), co skutkuje ograniczoną dokumentacją dla nowszych wersji.

Analiza i uzasadnienie własnego rozwiązania

Analiza rozwiązań alternatywnych ujawniła fundamentalny kompromis: **zaawansowanie technologiczne vs koszty i elastyczność**. Rozwiązania chmurowe od Amazona oraz Google oferują wysoką jakość rekomendacji dzięki algorytmom deep learning, ale wiążą się z wysokimi kosztami operacyjnymi, uzależnieniem od dostawcy oraz brakiem kontroli nad algorytmami. Apache Mahout eliminuje koszty licencyjne, ale wymaga zaawansowanej wiedzy technicznej oraz kosztownej infrastruktury Spark.

Uzasadnienie sensowności własnego rozwiązania:

- **Integracja trzech komplementarnych metod w jednym systemie:**

Każde z analizowanych rozwiązań wymaga dodatkowej integracji lub samodzielnej implementacji co najmniej jednej z trzech wybranych metod (Collaborative Filtering, Analiza Sentymentu, Reguły Asocjacyjne):

- Amazon Personalize: oferuje Collaborative Filtering, wymagane dodatkowe usługi AWS (Amazon Comprehend dla analizy sentymentu) lub samodzielna implementacja reguł asocjacyjnych,
- Google Recommendations AI: oferuje Collaborative Filtering oraz funkcję „Frequently Bought Together” (podobną do reguł asocjacyjnych), wymaga samodzielnej implementacji analizy sentymentu,
- Apache Mahout: oferuje tylko Collaborative Filtering, wymaga samodzielnej implementacji analizy sentymentu oraz reguł asocjacyjnych.

Własna implementacja pozwala na spójną integrację wszystkich trzech metod w ramach jednej architektury systemowej oraz umożliwia dostosowanie logiki każdej metody do specyfiki branży e-commerce.

- **Optymalizacja kosztów dla małych i średnich platform:**

Własna implementacja (Django + PostgreSQL) eliminuje koszty licencyjne rozwiązań chmurowych przy zachowaniu wysokiej jakości rekomendacji. System jest szczególnie atrakcyjny dla małych i średnich platform e-commerce (do 10000 produktów, do 10000 użytkowników), które potrzebują zaawansowanych funkcjonalności rekomendacji przy ograniczonym budżecie.

- **Kontrola nad logiką biznesową i możliwość dostosowania:**

Własna implementacja umożliwia unikalne podejścia niedostępne w gotowych rozwiązańach:

- **Wieloźródłowa agregacja sentymentu** [5] z 5 źródeł tekstowych - rozwiązuje problem cold start (zimny start): produkty bez opinii użytkowników otrzymują wynik sentymentu na podstawie opisu, nazwy i specyfikacji,
- **Bitmap pruning** [9] dla algorytmu Apriori - optymalizacja przyspiesza generowanie reguł asocjacyjnych względem implementacji naiwnej poprzez operacje bitowe,
- **Adjusted Cosine Similarity** [8] z centrowaniem średniej - eliminacja wartości progowej (bias) wynikającej z różnych skali zakupowych użytkowników. Centrowanie średniej usuwa ten efekt skali przy obliczaniu podobieństwa.

- **Elastyczność technologiczna i brak uzależnienia od dostawcy:**

Aplikacja oparta na Django + React + PostgreSQL może być wdrożona na dowolnej platformie: AWS, GCP, Azure, własne serwery lub localhost. Migracja między platformami wymaga jedynie zmiany parametrów połączenia - logika rekomendacji pozostaje niezmieniona.

Dla porównania: migracja z Amazon Personalize do Google Recommendations AI wymaga przepisania całej integracji (śledzenie zdarzeń, dane treningowe, wywołania API) oraz ponownego trenowania modeli, co może trwać tygodnie i powodować degradację jakości rekomendacji.

Własna implementacja systemu rekomendacji stanowi optymalny wybór dla małych i średnich platform e-commerce, łączący:

- Wysoką jakość rekomendacji (trzy komplementarne metody: Collaborative Filtering, Sentiment Analysis, Apriori),
- Pełną kontrolę nad algorytmami i możliwość dostosowania do specyfiki biznesowej,
- Niskie koszty operacyjne (brak opłat licencyjnych rozwiązań chmurowych),
- Interpretowalność wyników i możliwość debugowania,
- Elastyczność technologiczną (brak uzależnienia od konkretnego dostawcy chmury).

Rozwiązanie jest szczególnie atrakcyjne dla platform potrzebujących zaawansowanych funkcjonalności rekomendacji przy ograniczonym budżecie oraz możliwości dostosowania logiki do specyficznych wymagań biznesowych.

Rozdział 3

Opis projektu planowanej aplikacji

Rozdział przedstawia szczegółowy opis planowanej aplikacji e-commerce z zaawansowanym systemem rekomendacji produktów. Zaprezentowano diagram przypadków użycia ilustrujący interakcje użytkowników z systemem oraz opisano kluczowe funkcjonalności z perspektywy różnych typów użytkowników.

3.1 Cel i zakres aplikacji

Aplikacja stanowi kompleksowe rozwiązanie e-commerce integrujące trzy komplementarne metody rekomendacji produktów:

- **Collaborative Filtering** - odkrywanie produktów podobnych na podstawie wzorców zakupowych użytkowników,
- **Sentiment Analysis** - ocena jakości produktów poprzez analizę opinii i treści,
- **Association Rules (Apriori)** - identyfikacja produktów często kupowanych razem.

System został zaprojektowany z myślą o małych i średnich platformach e-commerce (do 10000 produktów, do 100000 użytkowników), zapewniając funkcjonalności rekomendacyjne porównywalne z rozwiązaniami enterprise przy znacznie niższych kosztach operacyjnych.

3.2 Typy użytkowników systemu

System obsługuje trzech typów użytkowników, z których każdy posiada dostęp do różnych poziomów funkcjonalności. Struktura uprawnień opiera się na hierarchii dziedziczenia, gdzie każdy wyższy poziom dziedziczy wszystkie funkcjonalności poziomów niższych.

Gość - użytkownik niezalogowany, posiadający dostęp do podstawowych funkcji sklepu internetowego. Może przeglądać produkty, wyszukiwać i dodawać je do koszyka, jednakże nie może złożyć zamówienia bez utworzenia konta.

Klient - użytkownik zalogowany, który dziedziczy wszystkie funkcje gościa oraz dodatkowo ma dostęp do funkcjonalności transakcyjnych i personalizacji. Może składać zamówienia, śledzić ich status, zarządzać swoim kontem oraz korzystać ze spersonalizowanych rekomendacji generowanych przez zaimplementowane algorytmy.

Administrator - użytkownik z najwyższymi uprawnieniami, który dziedziczy wszystkie funkcje klienta oraz dodatkowo ma dostęp do narzędzi administracyjnych. Może za-

rządzać całym systemem: produktami, zamówieniami, użytkownikami oraz ma dostęp do panelów statystycznych i debugowania algorytmów rekomendacji.

Taki podział użytkowników według ról i uprawnień wpływa bezpośrednio na podział systemu na trzy główne obszary funkcjonalne: obszar publiczny (dostępny dla wszystkich), obszar klienta (wymaga zalogowania) oraz obszar administracyjny (wymaga uprawnień administratora).

3.3 Wymagania funkcjonalne systemu

System został zaprojektowany z uwzględnieniem następujących wymagań funkcjonalnych pogrupowanych według obszarów:

Autentykacja i autoryzacja:

- Rejestracja nowego użytkownika w systemie,
- Logowanie do systemu z walidacją danych,
- Wylogowanie i zarządzanie sesją (token JWT).

Obsługa koszyka zakupowego:

- Dodawanie produktów do koszyka,
- Wyświetlanie zawartości koszyka z sumą całkowitą,
- Modyfikacja ilości produktów w koszyku,
- Usuwanie produktów z koszyka,
- Wyświetlanie rekomendacji Apriori („Często kupowane razem”).

Obsługa zamówień (tylko użytkownicy zalogowani):

- Składanie zamówień z danymi dostawy i płatności,
- Wyświetlanie historii zamówień użytkownika,
- Śledzenie statusu zamówienia (oczekujące, w realizacji, zakończone, anulowane),
- Wyświetlanie szczegółów zamkniętych zamówień.

Zarządzanie kontem użytkownika:

- Wyświetlanie profilu użytkownika,
- Edycja danych osobowych (imię, nazwisko, adres e-mail),
- Zmiana hasła.

System rekomendacji:

- Wyświetlanie rekomendacji Collaborative Filtering na stronie głównej,
- Wyświetlanie produktów podobnych na stronie szczegółów produktu,
- Wyświetlanie rekomendacji opartych na sentymencie (produkty o najlepszych opiniah),
- Wyświetlanie rekomendacji Apriori w koszyku zakupowym.

Opinie i recenzje:

- Wyświetlanie opinii innych użytkowników na stronie produktu,
- Dodawanie opinii do zakupionych produktów (ocena gwiazdkowa i treść tekstowa),
- Automatyczne przeliczanie sentymentu po dodaniu opinii.

Funkcje administracyjne - zarządzanie produktami:

- Dodawanie nowych produktów do katalogu,
- Edycja istniejących produktów (nazwa, opis, cena, kategorie, specyfikacje),
- Usuwanie produktów z potwierdzeniem,
- Zarządzanie kategoriami produktów.

Funkcje administracyjne - zarządzanie zamówieniami:

- Przeglądanie wszystkich zamówień w systemie,
- Zmiana statusów zamówień,
- Wyświetlanie szczegółów zamówienia.

Funkcje administracyjne - zarządzanie użytkownikami:

- Lista wszystkich użytkowników w systemie,
- Nadawanie uprawnień administratora,
- Usuwanie kont użytkowników.

Funkcje administracyjne - statystyki i analityka:

- Panel analityczny (dashboard) z kluczowymi wskaźnikami,
- Wykresy sprzedaży (miesięczny obrót, najpopularniejsze kategorie),

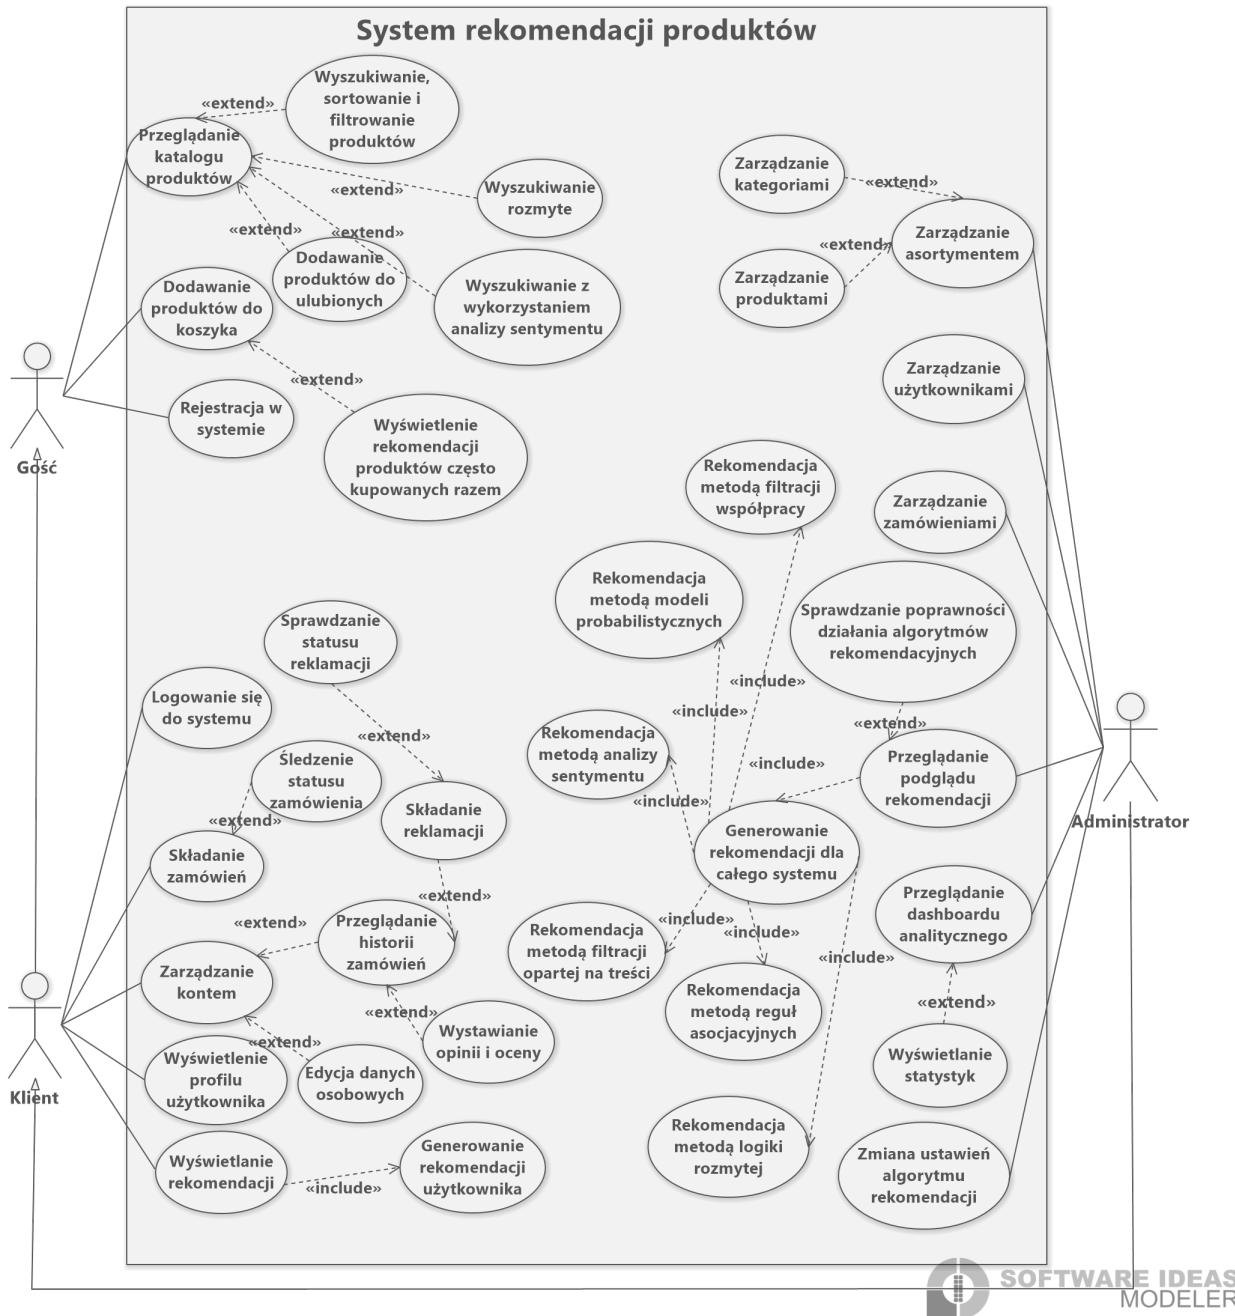
- Statystyki użytkowników (nowe rejestracje, aktywni użytkownicy),
- Statystyki produktów (najczęściej kupowane, najlepsze opinie).

Funkcje administracyjne - debugowanie algorytmów rekomendacji:

- Podgląd macierzy podobieństw Collaborative Filtering,
- Przeglądanie reguł asocjacyjnych Apriori z metrykami,
- Walidacja poprawności działania algorytmów,
- Wyświetlanie statystyk wydajności metod rekomendacji.

3.4 Diagram przypadków użycia

Diagram przypadków użycia (rys. 1) przedstawia kompletny widok funkcjonalności systemu oraz relacji między aktorami a przypadkami użycia. System obsługuje trzy główne typy aktorów: Gościa (użytkownik niezalogowany), Klienta (użytkownik zalogowany) oraz Administratora (zarządzający systemem).



Rysunek 1: Diagram przypadków użycia systemu.

Ogólny opis diagramu:

Diagram został zorganizowany wokół trzech głównych aktorów, z których każdy ma dostęp do różnych poziomów funkcjonalności systemu. Relacje dziedziczenia między ak-

torami (Gość → Klient → Administrator) odzwierciedlają hierarchię uprawnień - każdy następny poziom dziedziczy wszystkie funkcjonalności poprzedniego i dodaje nowe, specyficzne dla swojej roli.

3.5 Architektura funkcjonalna systemu

System został zaprojektowany w architekturze warstwowej, gdzie każda warstwa odpowiada za konkretny aspekt funkcjonalności:

Warstwa prezentacji - interfejsy użytkownika dostosowane do ról (klient, administrator):

- **Panel klienta** - panel główny (dashboard) z historią zamówień, sekcja rekomendacji, edycja profilu,
- **Panel administracyjny** - zarządzanie produktami/zamówieniami/użytkownikami, statystyki, panele debugowania.

Warstwa logiki biznesowej - implementacja trzech algorytmów rekomendacji oraz logiki e-commerce:

- **Moduł Collaborative Filtering** - generowanie macierzy podobieństwa produktów, rekomendacje oparte na produktach (item-based),
- **Moduł Sentiment Analysis** - agregacja sentymentu z 5 źródeł tekstowych (opinie, opis, nazwa, specyfikacje, kategorie),
- **Moduł Apriori** - generowanie reguł asocjacyjnych typu "Często kupowane razem",
- **Logika transakcyjna** - składanie zamówień, zarządzanie statusami, validacja danych.

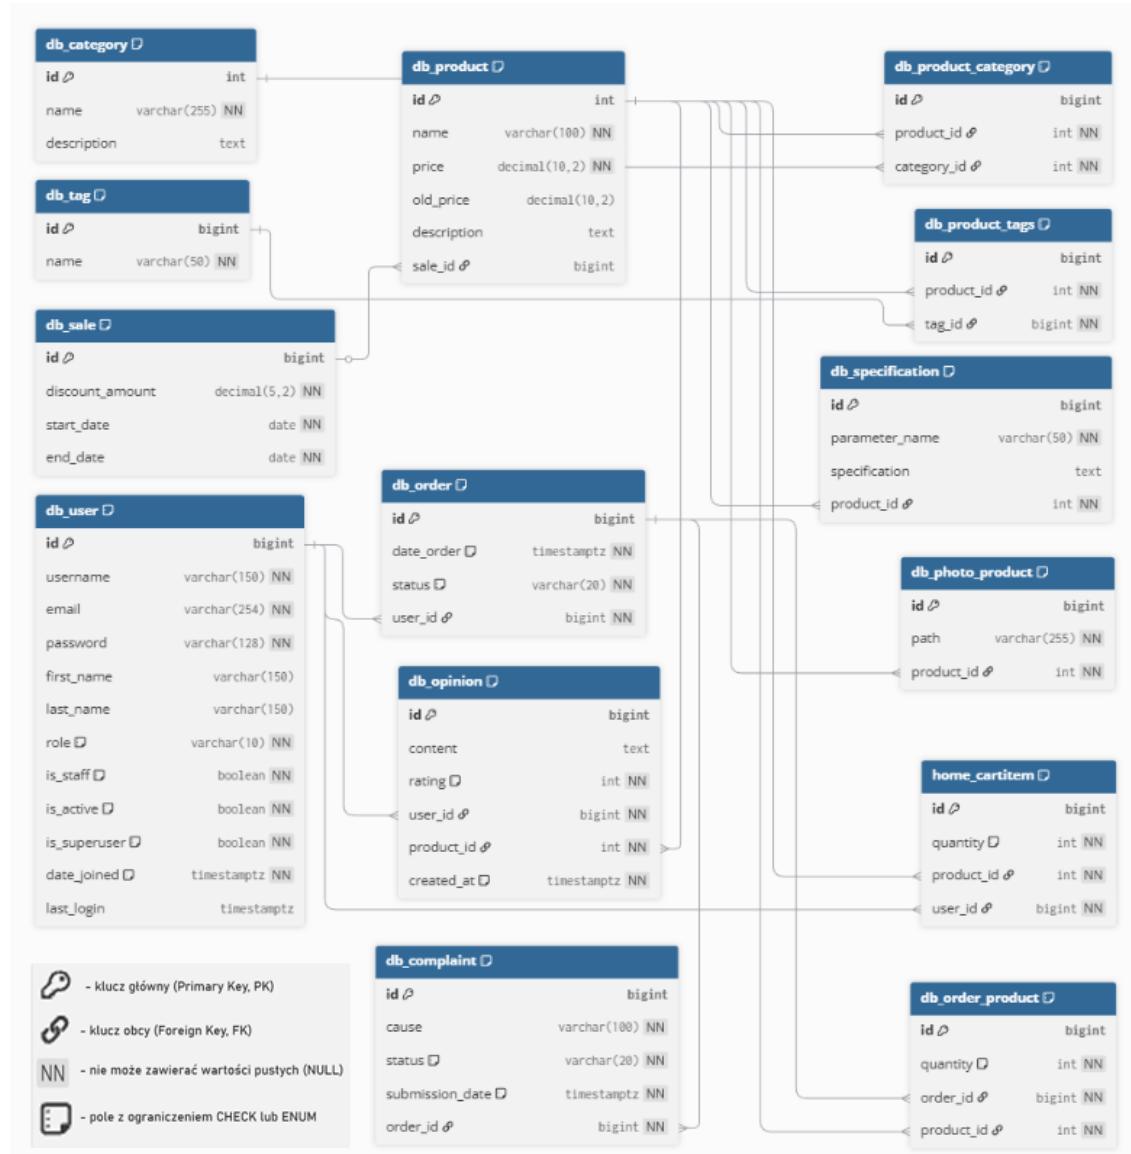
Warstwa danych - relacyjna baza danych PostgreSQL przechowująca:

- Dane produktów (nazwa, opis, cena, kategorie, specyfikacje, zdjęcia),
- Dane użytkowników (konta, profile, uprawnienia),
- Dane transakcyjne (zamówienia, produkty w zamówieniach, statusy),
- Dane opinii (recenzje tekstowe, oceny gwiazdkowe, sentyment),
- Wyniki algorytmów (macierze podobieństwa, reguły asocjacyjne, zagregowana ocena sentymentu).

Integracja warstw odbywa się poprzez RESTful API z automatyczną synchronizacją - zmiana danych w jednej warstwie propaguje aktualizacje do pozostałych.

3.6 Struktura bazy danych

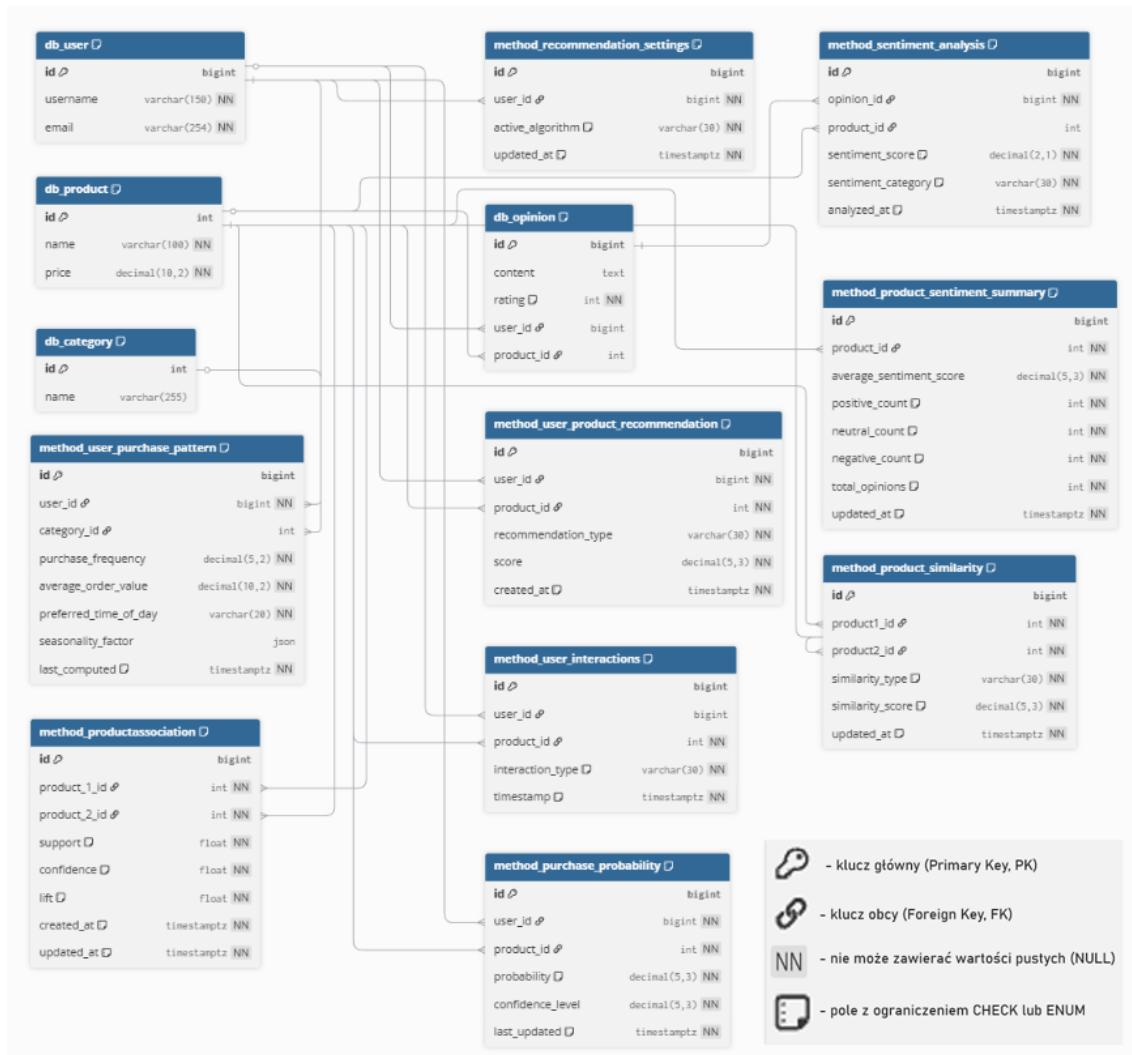
Baza danych systemu składa się z 25 tabel zorganizowanych w cztery moduły funkcjonalne. Poniższe diagramy ERD (Entity-Relationship Diagram) przedstawiają strukturę relacyjną bazy danych wraz z kluczowymi powiązaniami między tabelami.



Rysunek 2: Diagram ERD głównych tabel aplikacji.

Diagram 2 przedstawia rdzeń aplikacji e-commerce. Kluczowe relacje:

- **db_user ↔ db_order (1:N)** - jeden użytkownik może złożyć wiele zamówień,
- **db_order → db_order_product (1:N)** - zamówienie zawiera wiele produktów,
- **db_product ↔ db_category (N:M)** - produkt należy do wielu kategorii,
- **db_product → db_opinion (1:N)** - produkt ma wiele opinii.



Rysunek 3: Diagram ERD tabel metod rekomendacyjnych.

Diagram 3 pokazuje tabele algorytmów ML:

- **method_product_similarity** - macierz podobieństw Collaborative Filtering,
- **method_productassociation** - reguły asocjacyjne Apriori,
- **method_sentiment_analysis** - wyniki analizy sentymantu opinii,
- **method_product_sentiment_summary** - zagregowany sentymen produktu,
- **method_user_product_recommendation** - cache rekomendacji użytkownika.

Charakterystyka tabel bazy danych

Baza składa się z **25 głównych modeli** podzielonych na 4 moduły funkcjonalne:

1. Moduł produktów i użytkowników (12 tabel):

- db_product - dane produktów (ID, nazwa, cena, opis),

- db_category - kategorie produktów z hierarchią,
- db_product_category - relacja Many-to-Many produktów i kategorii,
- db_photo_product - ścieżki do zdjęć produktów,
- db_specification - szczegółowe parametry techniczne produktów,
- db_tag - tagi do filtrowania produktów,
- db_sale - promocje i rabaty,
- db_user - konta użytkowników (role: admin/client),
- db_order - zamówienia z timestampami i statusami,
- db_order_product - produkty w zamówieniach (ilość, cena),
- db_cart_item - koszyk zakupowy przed finalizacją,
- db_complaint - reklamacje powiązane z zamówieniami.

2. Moduł opinii i analizy sentymentu (3 tabele):

- db_opinion - opinie użytkowników (treść, rating 1-5),
- method_sentiment_analysis - wyniki analizy sentymentu dla opinii,
- method_product_sentiment_summary - zagregowany sentyment produktu.

3. Moduł metod rekomendacji (5 tabel):

- method_product_similarity - macierz podobieństw produktów (Collaborative Filtering),
- method_user_product_recommendation - spersonalizowane rekomendacje użytkowników,
- method_product_association - reguły asocjacyjne Apriori,
- method_user_interactions - historia interakcji użytkowników,
- method_recommendation_settings - konfiguracja algorytmów dla użytkownika.

4. Moduł analityczny i prognozowanie (5 tabel):

- method_purchase_probability - prawdopodobieństwo zakupu produktu przez użytkownika,

- `method_sales_forecast` - prognoza sprzedaży produktów,
- `method_user_purchase_pattern` - wzorce zakupowe użytkowników,
- `method_product_demand_forecast` - prognoza popytu i poziomy magazynowe,
- `method_risk_assessment` - ocena ryzyka dla użytkowników i produktów.

Wszystkie migracje Django ORM zostały wygenerowane automatycznie na podstawie modeli Python i zarządzane przez system wersjonowania `django.db.migrations`.

Wypełnianie bazy danych początkowymi (seeding)

W celu umożliwienia testowania systemu oraz walidacji algorytmów rekomendacyjnych zaimplementowano mechanizm automatycznego wypełniania bazy danych testowymi danymi (ang. database seeding). Proces seedingów generuje: 500 produktów z opisami, cenami i specyfikacjami technicznymi, 20 użytkowników (5 administratorów + 15 klientów) z wypełnionymi profilami, 200 zamówień z realistycznymi timestampami, około 600 rekordów `OrderProduct` (przeciętnie 3 produkty na zamówienie), oraz przybliżnie 1750 opinii (średnio 3.5 opinii na produkt) z ocenami gwiazdkowymi i treściami tekstowymi. Dane testowe zostały zaprojektowane w taki sposób, aby odzwierciedlać realistyczne wzorce zachowań użytkowników w sklepie internetowym, co pozwala na efektywną walidację jakości generowanych rekomendacji przez algorytmy Collaborative Filtering, analizę sentymentu oraz reguły asocjacyjne.

Rozdział 4

Przedstawienie wykorzystanego stosu technologicznego oraz praktycznej realizacji projektu

Rozdział przedstawia techniczne aspekty implementacji systemu e-commerce wyposażonego w mechanizmy rekomendacji produktów. Omówiono stos technologiczny wykorzystany w projekcie, strukturę bazy danych oraz sposób wdrożenia aplikacji z wykorzystaniem konteneryzacji Docker.

4.1 Architektura systemu

Aplikacja została zaprojektowana w architekturze klient-serwer opartej na technologiach Django (backend) oraz React (frontend). Komunikacja odbywa się poprzez RESTful API z uwierzytelnianiem tokenowym JSON Web Tokens (JWT). Struktura aplikacji wyraźnie rozdziela warstwę prezentacji (React SPA), logikę biznesową (widoki Django i serializery), oraz warstwę danych (PostgreSQL).

Główne założenia architektoniczne:

- **Separacja frontendu i backendu** - możliwość niezależnego rozwoju i skalowania obu warstw,
- **Podejście API-first (API-first approach)** - wszystkie funkcjonalności dostępne przez REST API,
- **Uwierzytelnianie bezstanowe (Stateless authentication)** - token JWT eliminuje potrzebę sesji po stronie serwera,
- **Modułowa struktura** - każdy algorytm rekomendacji stanowi niezależny moduł.

4.2 Stos technologiczny backendu

Django 5.1.4 (Python 3.11) - stanowi fundament aplikacji serwerowej, zapewniając architekturę MVC, system ORM (Object-Relational Mapping - mapowanie obiektowo-relacyjne) dla abstrakcji bazy danych oraz mechanizmy bezpieczeństwa. Kluczowe komponenty:

- **Django ORM** - mapowanie obiektowo-relacyjne umożliwiające operacje na bazie bez SQL,
- **Django Signals** - mechanizm automatycznej aktualizacji rekomendacji przy zmianach danych,

- **Django Middleware (oprogramowanie pośredniczące)** - obsługa CORS, uwierzytelnienie JWT, pamięć podręczna.

Django REST Framework 3.15.2

Rozszerza Django o funkcjonalności API RESTful:

- **Serializery** - konwersja obiektów Django na JSON z walidacją,
- **ViewSets (zestawy widoków)** - widoki implementujące operacje CRUD,
- **Uwierzytelnianie (Authentication)** - wsparcie dla JWT, uwierzytelnianie sesyjne,
- **Pagination (paginacja)** - automatyczne stronicowanie wyników.

Biblioteki Machine Learning

Do operacji numerycznych i obliczania podobieństw wykorzystano:

- **scikit-learn** - funkcja cosine_similarity() dla Collaborative Filtering (Collaborative Filtering),
- **NumPy** - operacje macierzowe, wektoryzacja obliczeń, przycinanie bitmapowe (bitmap pruning) w Apriori.

4.3 Stos technologiczny frontendu

React 18 - stanowi fundament aplikacji jednostronicowej (Single Page Application - SPA):

- **Architektura komponentowa (Component-based)** - reużywalne komponenty UI,
- **Virtual DOM (wirtualny DOM)** - optymalizacja renderowania,
- **React Hooks (haki React)** - useState, useEffect, useContext.

Biblioteki wspierające

- **React Router v6** - trasowanie (routing) dla aplikacji SPA,
- **Axios** - komunikacja z API, przechwytywacze JWT (interceptors),
- **Framer Motion** - płynne animacje,
- **Context API** - zarządzanie stanem (AuthContext, CartContext).

4.4 Baza danych PostgreSQL

Wybór PostgreSQL 14 - został wybrany jako system zarządzania bazą danych ze względu na następujące cechy:

- **Zaawansowane indeksy** - wsparcie dla B-tree (domyślne), GIN (wyszukiwanie pełnotekstowe), BRIN (optymalizacja dla dużych tabel),
- **Typ danych JSONB** - natywne przechowywanie i indeksowanie struktur JSON (wykorzystane w tabeli `method_user_purchase_pattern` dla sezonowości zakupów),
- **Transakcje ACID** - gwarancja atomowości, spójności, izolacji i trwałości operacji krytycznych (zamówienia, płatności),
- **Klucze obce i constrainty** - automatyczne wymuszanie integralności referencyjnej oraz walidacji danych (np. rating 1-5 w opiniach),
- **Optymalizacja JOIN** - wydajne łączenie tabel w złożonych zapytaniach rekomendacyjnych,
- **Full-text search** - wbudowane mechanizmy wyszukiwania tekstowego dla produktów.

4.5 Projekt techniczny systemu

Po przedstawieniu stosu technologicznego oraz struktury bazy danych, niniejsza sekcja charakteryzuje projekt techniczny systemu, ze szczególnym uwzględnieniem architektury komponentów backendu i frontendu.

Struktura backendu

Każdy komponent systemu backendowego posiada dedykowane pliki odpowiedzialne za różne aspekty funkcjonalności:

- **models.py** – definicje tabel (Product, Order, Opinion, ProductSimilarity),
- **serializers.py** – konwersja obiektów Django ↔ JSON,
- **views.py** – obsługa CRUD dla produktów, zamówień,
- **recommendation_views.py** – endpointy /api/generate-user-recommendations/, /api/recommendation-algorithm-status/,
- **sentiment_views.py** – endpointy /api/sentiment-search/, /api/sentiment-analysis-debug/,
- **association_views.py** – endpointy /api/frequently-bought-together/, /api/update-association-rules/,

- **signals.py** – automatyczna aktualizacja rekomendacji.

Architektura komponentów frontendu

- **App.js** – trasowanie, globalne dostawcy kontekstu (Context providers),
- **Navbar.jsx** – nawigacja z wyszukiwarką i ikoną koszyka,
- **SearchModal.jsx** – wyszukiwarka z sortowaniem sentymentu,
- **ProductPage.jsx** – strona produktu z rekomendacjami Collaborative Filtering i Apriori,
- **CartContent.jsx** – koszyk z cross-selling (Apriori),
- **ClientPanel.jsx** – panel główny klienta z personalizowanymi rekomendacjami,
- **AdminPanel.jsx** – panel zarządzania produktami, zamówieniami, statystykami.

4.6 Deployment i konteneryzacja Docker

Aplikacja została skonteneryzowana przy użyciu Docker Compose, zapewniając spójność środowiska między środowiskiem deweloperskim (development), testowym (staging) i produkcyjnym (production).

	Name	Image	Port(s)	Last started	Actions
□	smartrecommender-project	-	-	3 minutes ago	⋮ ⚡
□	SmartRecommender-React-FRONTEND	smartrecommender-project-frontend	3000:3000	3 minutes ago	⋮ ⚡ 1
□	SmartRecommender-Django-BACKEND	smartrecommender-project-backend	8000:8000	3 minutes ago	⋮ ⚡ 2
□	SmartRecommender-PostgreSQL-DB	postgres:16	5432:5432	3 minutes ago	⋮ ⚡ 3

Rysunek 4: Architektura deweloperska aplikacji w Docker Compose z mechanizmem hot-reload.

Architektura składa się z trzech kontenerów (rys. 4):

1. Kontener frontendu (React 18)

- Base image: node:18-alpine,
- Port: 3000,
- Volumes: montowanie src/ dla automatycznego przeładowania (hot-reload),
- Environment: REACT_APP_API_URL,
- Zależności (Dependencies): package.json (React, Axios, React Router, Framer Motion).

2. Kontener backendu (Django 5.1.4)

- Base image: python:3.11-slim,
- Port: 8000,
- Volumes: montowanie projektu dla automatycznego przeładowania (hot-reload), wolumen dla plików multimedialnych,
- Environment: DATABASE_URL, SECRET_KEY, DEBUG, ALLOWED_HOSTS,
- Zależności (Dependencies): requirements.txt (Django, DRF, psycopg2, NumPy, scikit-learn).

3. Kontener bazy danych (PostgreSQL 14)

- Base image: postgres:14-alpine,
- Port: 5432,
- Volumes: named volume postgres_data (persistencja danych),
- Environment: POSTGRES_DB, POSTGRES_USER, POSTGRES_PASSWORD,
- Healthcheck: pg_isready.

Konteneryzacja Docker zapewnia kilka kluczowych korzyści dla projektu. Izolacja każdego serwisu w osobnym kontenerze eliminuje konflikty zależności, co jest szczególnie istotne przy różnych wersjach bibliotek między backendem (Python 3.11) a frontendem (Node 18). Przenośność obrazów Docker umożliwia uruchomienie aplikacji na dowolnym serwerze z silnikiem Docker bez konieczności ręcznej konfiguracji środowiska. Proces uruchomienia został uproszczony do pojedynczej komendy docker-compose up, która automatycznie inicjalizuje wszystkie trzy kontenery z odpowiednimi zależnościami i połączeniami sieciowymi. Dodatkowo architektura umożliwia łatwą skalowalność - w przypadku wzrostu ruchu możliwe jest uruchomienie wielu instancji kontenera backendu z zastosowaniem mechanizmów równoważenia obciążenia (load balancing).

4.7 Architektura i przepływ danych systemu rekomendacji

System rekomendacji został zintegrowany z aplikacją e-commerce w architekturze trójwarstwowej:

Warstwa prezentacji (React) - interfejs użytkownika wyświetlający rekomendacje w różnych kontekstach:

- Strona główna - sekcja „Recommended for You” z możliwością przełączania algorytmów,

- Panel klienta - dashboard z personalizowanymi rekommendacjami,
- Wyszukiwarka - sortowanie według sentymantu,
- Koszyk zakupowy - sekcja „Frequently Bought Together”,
- Panel administracyjny - zarządzanie metodami rekommendacji i debugowanie.

Warstwa logiki biznesowej (Django) - endpointy API obsługujące zapytania o rekommendacje:

- /api/generate-user-recommendations/ - generowanie rekommendacji Collaborative Filtering,
- /api/sentiment-search/ - wyszukiwanie produktów według sentymantu,
- /api/frequently-bought-together/ - produkty z reguł asocjacyjnych Apriori,
- /api/recommendation-algorithm-status/ - status algorytmów i debugowanie,
- /api/admin/update-product-similarity/ - regeneracja macierzy podobieństw.

Warstwa danych (PostgreSQL) - tabele przechowujące prekalkulowane wyniki:

- method_product_similarity - macierz podobieństw Collaborative Filtering,
- method_product_sentiment_summary - zagregowany sentymant,
- method_productassociation - reguły Apriori,
- method_recommendation_settings - konfiguracja aktywnej metody.

Charakterystyka funkcjonowania systemu

Zaimplementowany system rekommendacji cechuje się:

Kompletnością zarządzania:

- Panel administratora z dynamicznym przełączaniem metod,
- Sekcje debugowania dla wszystkich trzech algorytmów,
- Wizualizacja metryk i statystyk w czasie rzeczywistym.

Integracją w aplikacji:

- Strona główna z konfigurowalnymi rekommendacjami,
- Dashboard klienta z personalizacją,

- Wyszukiwarka z sortowaniem według sentymentu,
- Sekcje „Frequently Bought Together” oparte na Apriori.

Narzędziami diagnostycznymi:

- Podgląd macierzy podobieństw Collaborative Filtering,
- Analiza źródeł sentymentu dla każdego produktu,
- Ranking reguł asocjacyjnych z metrykami,
- Statystyki wykonania algorytmów.

System jest w pełni funkcjonalny i gotowy do wdrożenia w środowisku produkcyjnym.

Rozdział 5

Implementacja algorytmów rekommendacji

Szczegółowa implementacja trzech algorytmów rekommendacyjnych wraz z pseudokodami oraz diagramami sekwencji przedstawia praktyczne aspekty realizacji metod collaborative filtering, analizy sentymentu oraz reguł asocjacyjnych.

5.1 Podstawy matematyczne wykorzystanych algorytmów

Implementowane algorytmy opierają się na następujących formułach matematycznych, które stanowią fundament dla realizacji poszczególnych metod rekommendacyjnych.

Adjusted Cosine Similarity dla Item-Based Collaborative Filtering (Sarwar et al. 2001) [8] stanowi kluczową metrykę podobieństwa wykorzystywana w systemie. Wzór ten oblicza podobieństwo między dwoma produktami i i j poprzez analizę wzorców ich współwystępowania w zakupach użytkowników:

$$\text{sim}(i, j) = \frac{\sum_{u \in U} (R_{u,i} - \bar{R}_u)(R_{u,j} - \bar{R}_u)}{\sqrt{\sum_{u \in U} (R_{u,i} - \bar{R}_u)^2} \cdot \sqrt{\sum_{u \in U} (R_{u,j} - \bar{R}_u)^2}} \quad (1)$$

gdzie $R_{u,i}$ to ilość zakupu użytkownika u dla produktu i , \bar{R}_u to średnia użytkownika u , a U to użytkownicy, którzy kupili oba produkty. Centrowanie średniej ($R_{u,i} - \bar{R}_u$) eliminuje bias (wartość progową) dla użytkowników kupujących systematycznie więcej.

Analiza sentymentu (Liu 2012) [5] używa formuły polarności tekstu:

$$S(\text{text}) = \frac{N_{pos} - N_{neg}}{N_{total}} \quad (2)$$

gdzie N_{pos} to liczba słów pozytywnych, N_{neg} negatywnych, N_{total} to całkowita liczba wszystkich słów w analizowanym tekście (nie tylko słów sentymentalnych). Wynik: $[-1, 1]$ (dodatnie = pozytywny, ujemne = negatywny).

Reguły asocjacyjne (Agrawal & Srikant 1994) [1] używają trzech metryk, gdzie A i B oznaczają zbiory produktów (np. $A = \{\text{laptop}\}$, $B = \{\text{mysz}\}$):

Wsparcie (Support) (Agrawal & Srikant 1994) [1] - jaka jest częstość współwystępowania:

$$\text{Support}(A, B) = \frac{\text{transakcje z } A \text{ i } B}{\text{wszystkie transakcje}} \quad (3)$$

Pewność (Confidence) (Agrawal & Srikant 1994) [1] - jakie jest prawdopodobieństwo warunkowe:

$$\text{Confidence}(A \rightarrow B) = \frac{\text{Support}(A, B)}{\text{Support}(A)} \quad (4)$$

Wzrost (Lift) (Agrawal & Srikant 1994) [1] - ile razy bardziej jest prawdopodobny zakup:

$$\text{Lift}(A \rightarrow B) = \frac{\text{Support}(A, B)}{\text{Support}(A) \cdot \text{Support}(B)} \quad (5)$$

$\text{Wzrost}(\text{Lift}) > 1$: pozytywna korelacja, $\text{Wzrost} = 1$: niezależność, $\text{Wzrost} < 1$: negatywna korelacja. Algorytm Apriori przyspiesza obliczenia dzięki własności: jeśli zbiór nie spełnia minimalnego wsparcia (Support), jego nadzbiór też nie.

5.2 Collaborative Filtering - Item-Based z Adjusted Cosine

Algorytm Collaborative Filtering w wariancie Item-Based oblicza podobieństwa między produktami na podstawie historii zakupów użytkowników, wykorzystując metrykę Adjusted Cosine Similarity wprowadzoną przez Sarwar et al. (2001) [8]. Kluczowym elementem algorytmu jest formuła matematyczna przedstawiona we wzorze (1) w sekcji 5.1, która oblicza podobieństwo między dwoma produktami i i j poprzez analizę wzorców ich współwystępowania w zakupach użytkowników z uwzględnieniem centrowania wartości względem średniej zakupów każdego użytkownika \bar{R}_u .

Proces implementacji składa się z trzech głównych etapów odpowiadających wzorowi (1): budowy macierzy użytkownik-produkt (algorytm 1), normalizacji wartości metodą mean-centering centrowanie względem \bar{R}_u (algorytm 1) oraz obliczenia podobieństw cosinusowych (algorytm 2). Normalizacja polega na odjęciu od każdej wartości zakupowej średniej zakupów danego użytkownika ($R_{u,i} - \bar{R}_u$), co eliminuje bias (wartości progowe) wynikające z różnych skali zakupowych - hurtownik kupujący po 100 sztuk oraz klient kupujący po 1 sztuce otrzymują porównywalne wagę po normalizacji, dzięki czemu algorytm wykrywa rzeczywiste preferencje niezależnie od skali transakcji.

Algorytm 1 przedstawia budowę macierzy użytkownik-produkt oraz jej normalizację. Algorytm iteruje przez wszystkie pozycje zamówień (linie 2-8), budując macierz gdzie wiersze reprezentują użytkowników, kolumny produkty, a wartości ilości zakupione. Następnie dla każdego użytkownika obliczana jest średnia jego zakupów (linia 16) i od każdej niezerowej wartości odejmowana jest ta średnia (linie 17-19), realizując centrowanie względem \bar{R}_u ze wzoru (1).

Algorytm 1: Budowa macierzy użytkownik-produkt z normalizacją

```

1 function buduj_macierz_cf():
2     pozycje = pobierz_wszystkie_pozycje_zamowien()
3     macierz = pusty_slownik()

```

```

4
5     for poz in pozycje:
6         uz_id = poz.order.user_id
7         prod_id = poz.product_id
8         macierz[uz_id][prod_id] = poz.quantity
9
10    M = konwertuj_na_tablice(macierz)
11    M_norm = macierz_zerowa(wymiary(M))
12
13    for i = 0 to liczba_wierszy(M) - 1:
14        zakupione = M[i] where M[i] > 0
15        if |zakupione| > 0 then
16            sr = srednia(zakupione)
17            for j = 0 to liczba_kolumn(M) - 1:
18                if M[i][j] > 0 then
19                    M_norm[i][j] = M[i][j] - sr
20
21    return M_norm

```

Algorytm 2 przedstawia obliczanie podobieństw cosinusowych między produktami. Macierz znormalizowana jest transponowana (linia 2), aby wiersze reprezentowały produkty, a następnie obliczane są podobieństwa cosinusowe (linia 3), które realizują licznik i mianownik wzoru (1). Algorytm stosuje próg podobieństwa zdefiniowany jako parametr funkcji (linia 1, domyślnie prog = 0.5), który jest używany w warunku (linia 11) - zapisywane są tylko pary produktów o podobieństwie powyżej progu, co redukuje rozmiar bazy danych o przybliżenie 60-80% przy zachowaniu najważniejszych relacji, ponieważ słabe podobieństwa (np. 0.1-0.3) mają niewielką wartość predykcyjną dla rekomendacji. Operacje zbiorcze bulk insert (linie 14-16) zapisują po 1000 rekordów jednocześnie, co znacznie przyspiesza zapis do bazy danych.

Algorytm 2: Obliczanie podobieństwa cosinusowego produktów

```

1  function oblicz_podobienstwa_cf(M_norm, prog = 0.5):
2      M_T = transponuj(M_norm)
3      sim = podobienstwo_cosinus(M_T)
4
5      usun_podobienstwa(typ='collaborative')
6      lista = pusta_lista()
7      n = liczba_produktow(M_T)
8
9      for i = 0 to n - 1:
10          for j = 0 to n - 1:
11              if i != j and sim[i][j] > prog then

```

```

12         dopisz(lista, {prod1: i, prod2: j, wynik:
13                         sim[i][j]})

14         if |lista| >= 1000 then
15             zapisz_zbiorczo(lista)
16             lista = pusta_lista()
17
18     if |lista| > 0 then
19         zapisz_zbiorczo(lista)

```

Algorytm 3 przedstawia generowanie rekomendacji dla konkretnego użytkownika na podstawie wcześniejszych obliczonych podobieństw produktów. Algorytm zbiera historię zakupów użytkownika z zamówień oraz koszyka (linie 2-9), a następnie dla każdego zakupionego produktu wyszukuje najbardziej podobne produkty (linia 13). Wyniki są agregowane (linie 14-18) - jeśli dany produkt jest podobny do wielu produktów zakupionych przez użytkownika, otrzymuje sumę wszystkich podobieństw jako końcowy wynik rekomendacji, co wzmacnia rekomendacje produktów spójnych z ogólną historią preferencji użytkownika.

Algorytm 3: Generowanie rekomendacji CF dla użytkownika

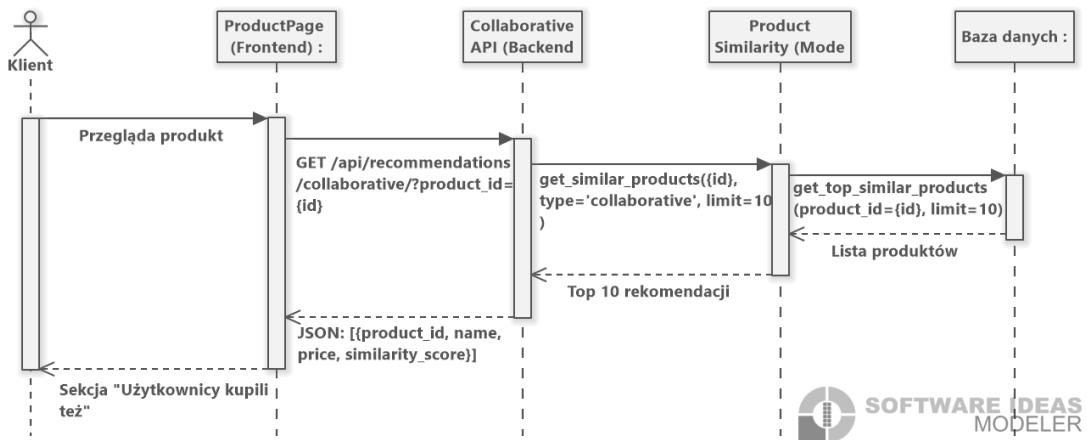
```

1 function generuj_rekomendacje(uzytkownik, typ_algorytmu):
2     historia = pusta_lista()
3
4     for zam in pobierz_zamowienia(uzytkownik):
5         for p in zam.produkty:
6             dopisz(historia, p.id)
7
8     for poz in pobierz_koszyk(uzytkownik):
9         dopisz(historia, poz.produkt.id)
10
11    wyniki = pusty_slownik()
12    for prod_id in unikalne(historia):
13        podobne = pobierz_podobne(prod_id, typ_algorytmu,
14                                  limit=5)
15        for s in podobne:
16            if s.produkt2_id in wyniki then
17                wyniki[s.produkt2_id] += s.podobienstwo
18            else
19                wyniki[s.produkt2_id] = s.podobienstwo
20
21    lista = sortuj(wyniki, malejaco)
22    for (p_id, wart) in lista:

```

```
zapisz_rekomendacje(uzytkownik, p_id, typ_algorytmu
, wart)
```

Diagram sekwencji: Collaborative Filtering



Rysunek 5: Diagram sekwencji: Collaborative Filtering.

Diagram 5 przedstawia przepływ procesu generowania rekomendacji Collaborative Filtering. Żądanie użytkownika trafia do API (/api/generate-user-recommendations/), które jako pierwszy krok sprawdza pamięć podręczną - w przypadku trafienia zwracany jest wynik natychmiast, co znacznie przyspiesza odpowiedź systemu. Przy braku w pamięci podręcznej następuje zapytanie do bazy danych o historię zakupów użytkownika, na podstawie której budowana jest macierz użytkownik-produkt z OrderProduct (algorytm 1). Macierz jest normalizowana poprzez centrowanie wartości względem średniej każdego użytkownika, co eliminuje systematyczne zwiększałce, po czym obliczane są podobieństwa cosinusowe między produktami zgodnie ze wzorem (1) - algorytm 2. Wyniki są zapisywane do pamięci podręcznej z czasem wygaśnięcia 2 godziny oraz tabeli ProductSimilarity z zachowaniem tylko podobieństw powyżej progu 0.5, po czym API zwraca top N rekomendacji (algorytm 3). Zaimplementowane optymalizacje obejmują pamięć podręczną przechowującą macierz podobieństw przez 2 godziny (7200 sekund), operacje zbiorcze bulk insert zapisujące po 1000 rekordów jednocześnie, próg 0.5 redukujący rozmiar bazy poprzez odrzucenie niższych wartości, oraz indeksowanie na kolumnach produkt_1 i typ_podobieństwa dla szybszego wyszukiwania.

5.3 Analiza Sentymentu - wieloźródłowa agregacja

Analiza sentymentu pojedynczego tekstu metodą słownikową [5] wykorzystuje formułę polarności przedstawioną we wzorze (2) w sekcji 5.1. Proces analizy polega na normalizacji tekstu (konwersja na małe litery, usunięcie znaków specjalnych), tokenizacji oraz liczeniu słów występujących w słownikach pozytywnym i negatywnym. Słowniki oparte

na leksykonach akademickich AFINN-165 (Nielsen 2011) i Opinion Lexicon (Hu & Liu 2004) zawierają łącznie 400 słów (200 słów pozytywnych, 200 słów negatywnych) obejmujących najczęściej używane określenia jakościowe, emocjonalne i ocenne (np. pozytywne: „excellent”, „recommend”, „quality”, „reliable”; negatywne: „bad”, „poor”, „disappointing”, „defective”). Wynik wzoru (2) jest ograniczany do przedziału [-1, 1] i kategoryzowany: pozytywny (>0.1), negatywny (<-0.1), neutralny (pozostałe).

Wieloźródłowa agregacja sentymentu produktu stanowi kluczową innowację systemu, łącząc wyniki z 5 niezależnych źródeł tekstowych, gdzie każde S_i jest obliczane według wzoru (2). Wagi zostały dobrane empirycznie: opinie klientów 40% (najbardziej wiarygodne źródło), opis produktu 25% (profesjonalny opis zawierający kluczowe cechy), nazwa produktu 15% (często zawiera wskazówki jakościowe jak „Premium”, „Pro”), specyfikacje techniczne 12% (obiektywne parametry), kategorie produktu 8% (ogólny kontekst). Podejście to rozwiązuje fundamentalny problem zimnego startu - produkty bez opinii klientów nadal otrzymują wynik sentymentu na podstawie pozostałych czterech źródeł tekstowych.

Uwaga techniczna: System opinii opisany w rozdziale 6 stanowi jeden z pięciu źródeł tekstowych wykorzystywanych przez algorytm analizy sentymentu. Każda opinia dodana przez użytkownika jest automatycznie przetwarzana przez algorytm sentiment analysis i włączana do agregacji produktu z wagą 40%, co czyni opinie najważniejszym źródłem danych w ocenie jakości produktów.

Algorytm 4: Analiza sentymentu metoda słownikowa

```
1 function analizuj_sentiment(tekst, slownik_poz, slownik_neg
2     ):
3
4         slowa = tokenizuj(na_male_litery(tekst))
5
6
7         if |slowa| = 0 then
8             return (0.0, ,,neutralny '')
9         end if
10
11        poz = 0
12        neg = 0
13
14        for s in slowa:
15            if s in slownik_poz then poz = poz + 1
16            if s in slownik_neg then neg = neg + 1
17        end for
18
19        wynik = (poz - neg) / |slowa|
20        wynik = ogranicz(wynik, -1.0, 1.0)
```

```

19     if wynik > 0.1 then kat = „pozytywny”
20     else if wynik < -0.1 then kat = „negatywny”
21     else kat = „neutralny”
22
23     return (wynik, kat)
24 end function

```

Algorytm wieloźródłowej agregacji sentymentu analizuje 5 niezależnych źródeł tekstowych produktu zamiast polegać wyłącznie na opiniach klientów. Rozwiązuje to problem zimnego startu - produkty bez opinii nadal otrzymują wynik bazujący na opisie i nazwie. Wagi źródeł: opinie 40%, opis 25%, nazwa 15%, specyfikacje 12%, kategorie 8%. System zlicza rozkład opinii (pozytywne/negatywne/neutralne) dla lepszej oceny konsensusu.

Algorytm 5: Agregacja sentymentu produktu z 5 zdrodów

```

1 function agreguj_sentyment_produktu(produkt):
2     opinie = pobierz_opinie(produkt)[:20]
3     wyniki_opinii = pusta_lista()
4     for op in opinie:
5         (w, _) = analizuj_sentyment(op.tresc)
6         dopisz(wyniki_opinii, w)
7     end for
8     S_op = srednia(wyniki_opinii) if |wyniki_opinii| > 0
9     else 0
10    (S_opis, _) = analizuj_sentyment(produkt.opis)
11    (S_nazwa, _) = analizuj_sentyment(produkt.nazwa)
12    teksty_spec = pusta_lista()
13    for sp in produkt.specyfikacje[:10]:
14        dopisz(teksty_spec, sp.nazwa + ‘ ’ + sp.wartosc)
15    end for
16    (S_spec, _) = analizuj_sentyment(polacz(teksty_spec))
17    kat_txt = polacz(pobierz_nazwy_kategorii(produkt))
18    (S_kat, _) = analizuj_sentyment(kat_txt)
19    S_final = 0.40*S_op + 0.25*S_opis + 0.15*S_nazwa
20        + 0.12*S_spec + 0.08*S_kat
21
22    poz = policz(wyniki_opinii WHERE w > 0.1)
23    neg = policz(wyniki_opinii WHERE w < -0.1)
24    neu = policz(wyniki_opinii WHERE -0.1 <= w <= 0.1)
25
26    return {
27        wynik: zaokragl(S_final, 3),

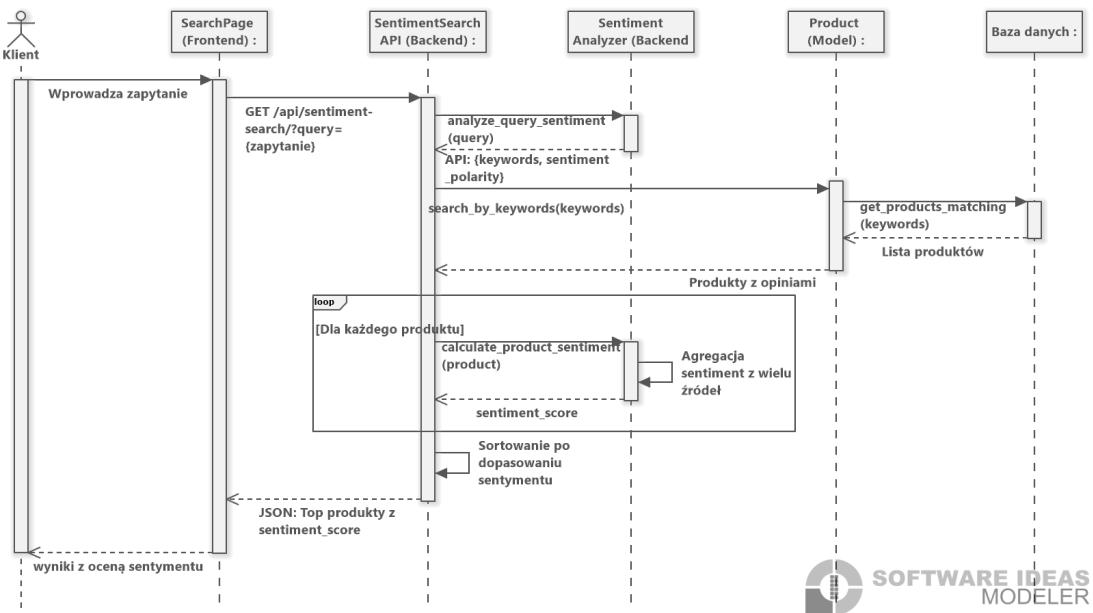
```

```

27     poztywne: poz ,
28     negatywne: neg ,
29     neutralne: neu
30   }
31 end function

```

Diagram sekwencji: Analiza Sentymentu



Rysunek 6: Diagram sekwencji: Analiza sentymentu.

Diagram 6 przedstawia przepływ procesu wieloźródłowej analizy sentymentu. Użytkownik wyszukuje produkty z sortowaniem według sentymentu, co inicjuje wywołanie funkcji agregacji sentymentu dla każdego produktu przez API. System analizuje 5 źródeł tekstowych równolegle z przypisanymi wagami: opinie 40%, opis 25%, nazwa 15%, specyfikacje 12%, kategorie 8%. Dla każdego źródła wykonywana jest tokenizacja i zliczanie słów pozytywnych oraz negatywnych przy użyciu słowników AFINN-165 i Opinion Lexicon. Wyniki są agregowane według formuły ważonej $S_{koncowy} = \sum_{i=1}^5 w_i \times S_i$, po czym końcowy wynik zapisywany jest w tabeli ProductSentimentSummary. API zwraca produkty posortowane według zagregowanego sentymentu. Kluczową zaletą tej architektury jest rozwiązywanie problemu zimnego startu - produkty bez opinii nadal otrzymują wynik sentymentu na podstawie pozostałych 4 źródeł tekstowych, co umożliwia sortowanie wszystkich produktów w katalogu niezależnie od ilości recenzji.

5.4 Algorytm Apriori - reguły asocjacyjne

Algorytm Apriori (Agrawal & Srikant 1994) [1] generuje reguły asocjacyjne typu „Często kupowane razem” poprzez analizę współwystępowania produktów

w transakcjach, wykorzystując trzy fundamentalne metryki przedstawione we wzorach (3), (4) i (5) w sekcji 5.1:

Support (Wsparcie) - wzór (3) określaczęstość współwystępowania produktów A i B w transakcjach. System używa minimalnego progu support = 0.001-0.005 (0.1-0.5% transakcji, wartość procentowa), co dla 200 zamówień oznacza że para produktów musi wystąpić w minimum 0.2-1 zamówieniu. Próg procentowy skala się automatycznie z rozmiarem bazy transakcji.

Confidence (Pewność) - wzór (4) oblicza warunkowe prawdopodobieństwo zakupu B przy założeniu zakupu A. Minimalny próg confidence = 0.01-0.1 (1-10%) oznacza że reguła jest zapisywana tylko jeśli przynajmniej 1-10% klientów kupujących A kupuje również B. Domyślna wartość confidence = 0.05 (5%) została dobrana empirycznie dla optymalnej równowagi między liczbą generowanych reguł a ich jakością.

Lift (Wzmocnienie) - wzór (5) mierzy siłę powiązania między produktami. Interpretacja: lift > 1 wskazuje pozytywną korelację (zakup A zwiększa prawdopodobieństwo zakupu B), lift = 1 oznacza niezależność produktów, lift < 1 wskazuje negatywną korelację. System używa progu lift = 1.0, preferując reguły z lift > 1.5 jako szczególnie wartościowe dla strategii cross-sellingu.

Proces implementacji składa się z dwóch głównych etapów: (1) znajdowania częstych par produktów z obliczeniem Support według wzoru (3), oraz (2) generowania reguł z obliczeniem Confidence i Lift według wzorów (4) i (5). Kluczową optymalizacją jest przycinanie bitmapowe (Zaki 2000), które reprezentuje transakcje jako liczby całkowite z ustawionymi bitami odpowiadającymi produktom. Sprawdzenie czy transakcja zawiera parę produktów wymaga operacji bitowej AND o stałej złożoności zamiast iteracji po liście, co znaczco przyspiesza obliczenia. Wczesne przycinanie eliminuje rzadkie produkty przed obliczaniem par - dzięki właściwości antymonotoniczności Apriori (jeśli produkt jest rzadki, wszystkie jego pary też są rzadkie) zmniejsza liczbę kandydatów o około 80-90%.

Algorytm 6: Apriori - znajdowanie częstych par produktów

```
1  function znajdz_czeste_pary(transakcje, min_wsp):
2      n = |transakcje|
3      min_licz = podloga(min_wsp * n)
4
5      liczniki = pusty_slownik()
6      for t in transakcje:
7          for p in t:
8              liczniki[p] = liczniki[p] + 1
9          end for
10     end for
11
12     czeste = [p for (p, l) in liczniki if l >= min_licz]
```

```

13
14     mapa = pusty_slownik()
15     for i = 0 to |czeste| - 1:
16         mapa[czeste[i]] = i
17     end for
18
19     bitmapy = pusta_lista()
20     for t in transakcje:
21         bm = 0
22         for p in t:
23             if p in mapa then
24                 bm = bm LUB (1 << mapa[p])
25             end if
26         end for
27         if bm != 0 then
28             dopisz(bitmapy, bm)
29         end if
30     end for
31
32     par_y = pusty_slownik()
33     for i = 0 to |czeste| - 1:
34         bit_i = 1 << i
35         for j = i + 1 to |czeste| - 1:
36             bit_j = 1 << j
37             para_bm = bit_i LUB bit_j
38
39             licz = 0
40             for bm in bitmapy:
41                 if (bm AND para_bm) == para_bm then
42                     licz = licz + 1
43                 end if
44             end for
45
46             if licz >= min_licz then
47                 par_y[{czeste[i], czeste[j]}] = licz / n
48             end if
49         end for
50     end for
51
52     wsparcia = {p: liczniki[p]/n for p in czeste}
53     return (par_y, wsparcia)

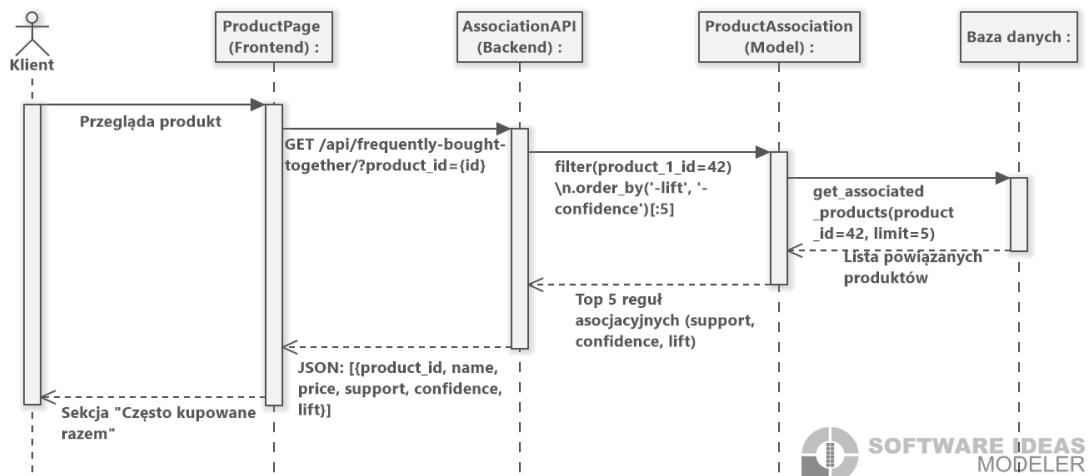
```

```
54 end function
```

Algorytm 7: Apriori - generowanie reguł z obliczeniem lift i confidence

```
1 function generuj_reguly_z_par(pary, wsparcia, min_pewn):
2     reguly = pusta_lista()
3
4     for ({p1, p2}, wsp Para) in pary:
5         wsp1 = wsparcia[p1]
6         wsp2 = wsparcia[p2]
7
8         pewn_1_2 = wsp Para / wsp1
9         pewn_2_1 = wsp Para / wsp2
10
11        lift = wsp Para / (wsp1 * wsp2)
12
13        if pewn_1_2 >= min_pewn then
14            dopisz(reguly, {od: p1, do: p2,
15                           wsparcie: wsp Para,
16                           pewnosc: pewn_1_2,
17                           lift: lift})
18        end if
19
20        if pewn_2_1 >= min_pewn then
21            dopisz(reguly, {od: p2, do: p1,
22                           wsparcie: wsp Para,
23                           pewnosc: pewn_2_1,
24                           lift: lift})
25        end if
26    end for
27
28    sortuj(reguly, wedlug=(lift, pewnosc), malejaco)
29    return reguly
30 end function
```

Diagram sekwencji: Algorytm Apriori



Rysunek 7: Diagram sekwencji: Algorytm Apriori.

Diagram 7 przedstawia przepływ procesu generowania reguł asocjacyjnych algorytmem Apriori. Administrator wywołuje aktualizację reguł przez panel administracyjny, co inicjuje ekstrakcję transakcji z bazy OrderProduct - system wybiera tylko zamówienia zawierające 2 lub więcej produktów, ponieważ pojedyncze zakupy nie tworzą asocjacji. Algorytm wykonuje wczesne przycinanie, eliminując rzadkie produkty o wsparciu poniżej 1% transakcji, co znacznie redukuje przestrzeń obliczeniową - dzięki właściwości antymonotoniczności Apriori (jeśli produkt jest rzadki, wszystkie jego pary też są rzadkie) eliminuje się około 80-90% kandydatów. Transakcje konwertowane są do reprezentacji bitmapowej, gdzie każda transakcja to liczba całkowita z ustawionymi bitami odpowiadającymi produktom - pozwala to wykonywać sprawdzenia przynależności jedną operacją bitową AND zamiast iteracji po liście. System generuje częste 2-itemsety (pary produktów) używając operacji bitowych, po czym dla każdego częstego itemsetu obliczane są trzy metryki: Support według wzoru (3), Confidence według wzoru (4) i Lift według wzoru (5). Reguły filtrowane są według progów ($\min_support \geq 0.01$, $\min_confidence \geq 0.1$, $lift \geq 1.0$) i zapisywane w bazie danych tabelą AssociationRule poprzez operacje zbiorcze bulk insert z rozmiarem partii 500 rekordów, co znacznie przyspiesza zapis. Zaimplementowane optymalizacje obejmują przycinanie bitmapowe dla szybkich operacji, wczesne przycinanie eliminujące większość kandydatów, operacje bitowe AND o optymalnej złożoności obliczeniowej, oraz operacje zbiorcze minimalizujące liczbę transakcji bazodanowych.

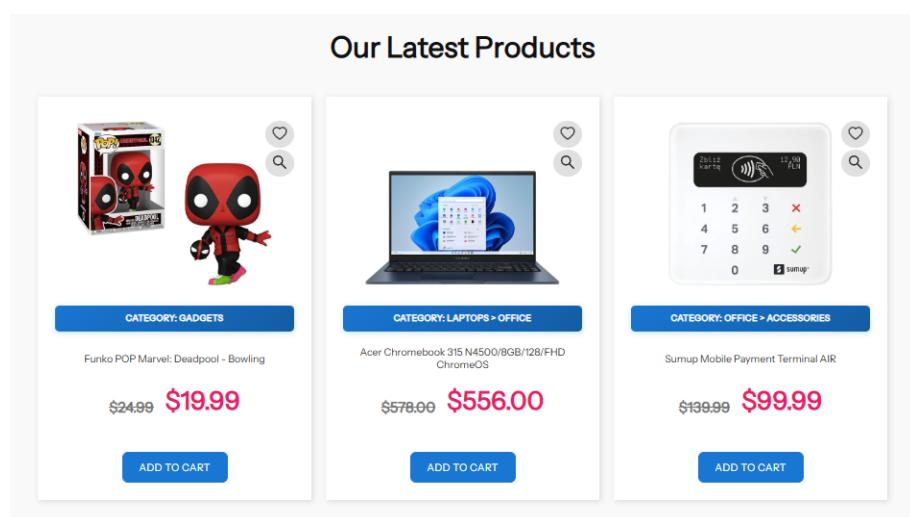
Rozdział 6

Funkcjonowanie systemu rekomendacji w praktyce

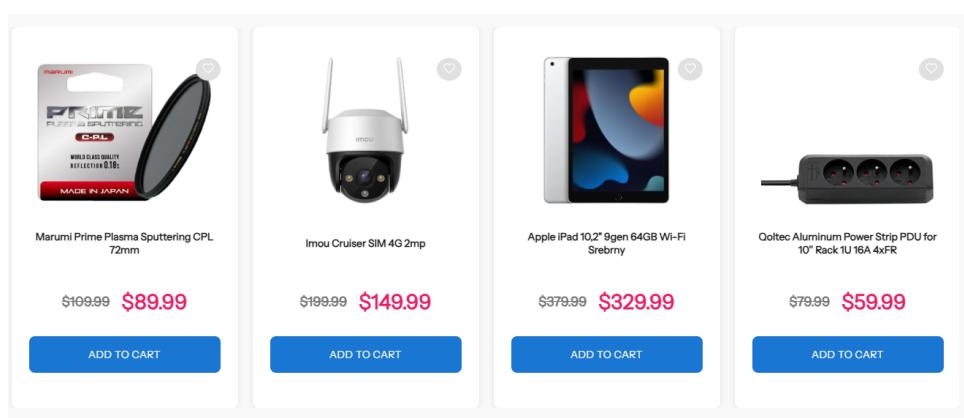
Rozdział przedstawia funkcjonowanie zaimplementowanych metod rekomendacyjnych w działającym systemie e-commerce. Omówiono perspektywę użytkownika końcowego korzystającego z rekomendacji produktów oraz narzędzia diagnostyczne służące do weryfikacji poprawności działania algorytmów. Struktura rozdziału została zaprojektowana zgodnie z naturalną kolejnością zapoznawania się z systemem - najpierw prezentacja funkcjonalności z perspektywy użytkownika końcowego, następnie panel konfiguracji dla administratora.

6.1 Metoda Collaborative Filtering - Item-Based

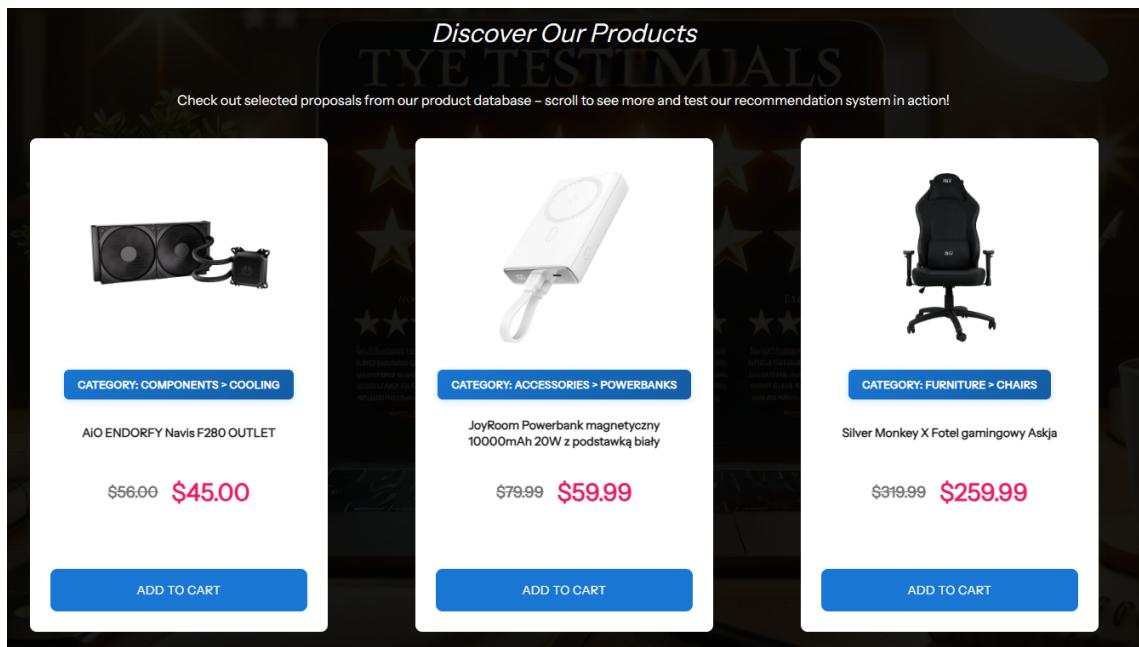
Widok strony głównej z rekomendacjami



Rysunek 8: Strona główna - pierwsza sekcja rekomendacji.



Rysunek 9: Strona główna - druga sekcja rekomendacji.



Rysunek 10: Strona główna - trzecia sekcja rekomendacji.

Rysunki 8, 9 i 10 przedstawiają trzy sekcje rekomendacji na stronie głównej aplikacji. Sekcje te są identyczne pod względem funkcjonalności i prezentują produkty w formie interaktywnych sliderów umożliwiających przewijanie oferty. Różnica między sekcjami polega wyłącznie na kolejności wyświetlania produktów - każda sekcja losuje inny podzbiór z pełnej listy rekomendacji, co zwiększa różnorodność prezentowanych ofert i minimalizuje efekt monotonii. Wszystkie trzy sekcje dynamicznie dostosowują wyświetlane produkty w zależności od metody rekomendacyjnej wybranej przez administratora w panelu zarządzania (rys. 22). Gdy aktywny jest algorytm Collaborative Filtering, wszystkie sekcje prezentują produkty dobrane na podstawie podobieństwa obliczonego metryką Adjusted Cosine Similarity zgodnie ze wzorem (1) z sekcji 5.1.

Panel debugowania Collaborative Filtering

Panel debugowania Collaborative Filtering znajduje się w sekcji administracyjnej systemu i służy do weryfikacji poprawności działania algorytmu oraz analizy wygenerowanych rekomendacji. Narzędzie to jest przeznaczone dla administratorów systemu oraz programistów przeprowadzających testy działania algorytmu. Panel umożliwia podgląd macierzy podobieństw produktów, sprawdzenie statusu wykonania obliczeń, analizę przykładowych rekomendacji oraz weryfikację zgodności wyników z oczekiwaniemi biznesowymi. Dzięki temu administratorzy mogą szybko zdiagnozować ewentualne problemy w działaniu algorytmu, takie jak brak rekomendacji dla niektórych produktów, nieprawidłowe wartości podobieństwa czy błędy w strukturze danych.

The screenshot shows a user interface for inspecting machine learning methods. At the top, there's a header with a back arrow and the title 'Debug Tools - ML Methods Inspector'. Below it, a sub-header says 'Inspect internal workings of all 7 machine learning methods used in SmartRecommender.' A navigation bar at the top has tabs for 'Collaborative Filtering' (selected), 'Sentiment Analysis', 'Association Rules', 'Content-Based', 'Fuzzy Logic', and 'Probabilistic'. The main content area is divided into sections:

- Collaborative Filtering Debug Information**:
 - Algorithm**:

Name:	Collaborative Filtering (Item-Based, Sarwar et al. 2001)
Formula:	Adjusted Cosine Similarity with Mean-Centering
Status:	success 1
 - Database Statistics**:

Total Users:	20
Total Products:	500
Total Order Items:	581
Users with Purchases:	20
Total Purchases:	568
 - User-Product Matrix**:

Shape:	(20, 500)
Total Cells:	10000
Non-Zero Cells:	568
Sparsity:	94.32%

Rysunek 11: Panel debugowania Collaborative Filtering - formuła algorytmu i dane z bazy.

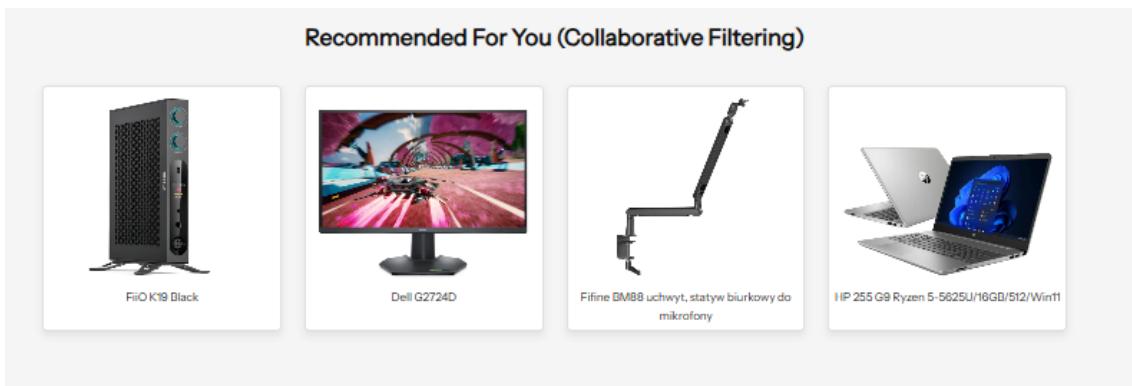
Rysunek 11 przedstawia sekcję debugowania algorytmu Collaborative Filtering w panelu administratora. Pod numerem (1) widoczna jest nazwa algorytmu „Item-Based Collaborative Filtering”, formuła matematyczna Adjusted Cosine Similarity oraz status wykonania. Pod numerem (2) znajdują się dane z bazy danych - tabela `method_product_similarity` zawierająca pary produktów wraz z obliczonymi współczynnikami podobieństwa oraz fragment macierzy podobieństw w formacie wizualnym.

Similarity Matrix	
Expected Shape:	(500, 500)
Total Possible Pairs:	249500
Saved Similarities:	0
Percentage Saved:	0%
Threshold:	0.3
Cache	
Status:	MISS (no data)
Cached Value:	
Timeout:	7200 seconds (2 hours)
Sample User Vector (User #1)	
Total Purchases:	34
Vector Length:	500

Rysunek 12: Panel debugowania Collaborative Filtering - podsumowanie obliczeń.

Rysunek 12 pokazuje drugą część panelu debugowania Collaborative Filtering. System wyświetla podsumowanie macierzy, statystyki cache oraz przykład rekomendacji dla pierwszego użytkownika z bazy danych.

Rekomendacje w panelu klienta



Rysunek 13: Dashboard klienta z sekcją rekomendacji.

Rysunek 13 przedstawia dashboard klienta z sekcją spersonalizowanych rekomendacji. Produkty są dobierane na podstawie pełnej historii zakupów użytkownika z zastosowaniem metody Collaborative Filtering.

6.2 Metoda analizy sentymenu

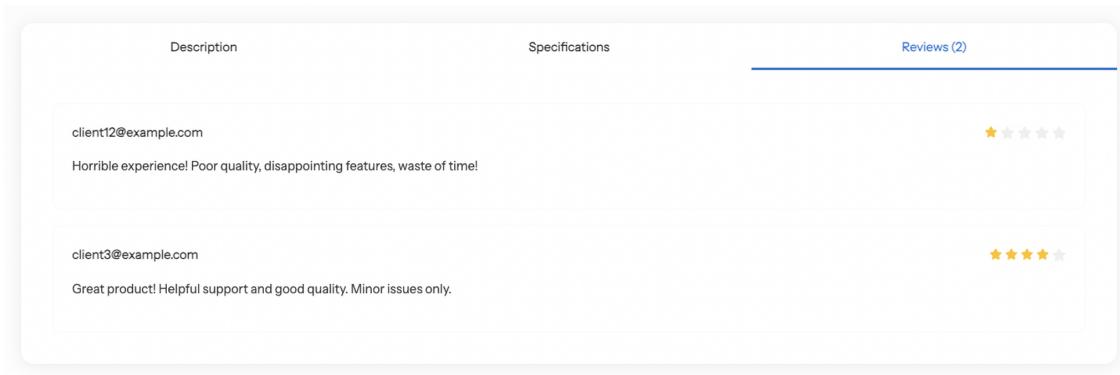
Interfejs opinii w aplikacji

System opinii jest zintegrowany w dwóch kluczowych miejscach interfejsu użytkownika. Użytkownicy mogą dodawać opinie bezpośrednio w panelu klienta po zakupie produktu oraz przeglądać wszystkie opinie na karcie produktu.

The screenshot shows a user interface for adding a product review. At the top, it says "Add Product Review" and has a red "X" button. Below that, it asks "Write a Review for Set Z8 | Ryzen 7 7800X3D, RX 7900 XTX 24GB, 32GB DDR5, 2TB SSD, Regnum 400 ARGB, 1000W". It then asks "Your Rating:" followed by five empty star icons. Below that is a section for "Your Review:" with a text input field containing placeholder text "What did you think about this product? (minimum 3 characters)". At the bottom are two buttons: "Cancel" and "Submit Review".

Rysunek 14: Formularz dodawania opinii na stronie produktu z oceną gwiazdkową i recenzją tekstoną.

Rysunek 14 przedstawia sekcję dodawania opinii na karcie produktu. Użytkownik może wystawić ocenę gwiazdkową w skali 1-5 gwiazdek oraz napisać szczegółową recenzję tekstoną opisującą swoje doświadczenia z produktem. Po dodaniu opinii przez użytkownika system automatycznie przetwarza tekst opinii algorytmem analizy sentymenu, oblicza wartość sentiment score w zakresie [-1, 1] według wzoru (2) z sekcji 5.1, klasyfikuje opinię jako pozytywną, neutralną lub negatywną, aktualizuje statystyki sentymenu produktu w tabeli ProductSentimentSummary, przelicza zagregowany wynik sentymenu produktu łączący pięć źródeł tekstowych zgodnie z wagami opisanymi w sekcji 5.3, oraz odświeża ranking produktów w wyszukiwarce jeśli użytkownik ma ustawione sortowanie według sentymenu.



Rysunek 15: Lista opinii produktu z badge'ami sentymentu i oceną gwiazdkową.

Rysunek 15 pokazuje listę wszystkich opinii dla danego produktu. Każda opinia wyświetla email użytkownika, ocenę gwiazdkową oraz pełną treść recenzji tekstuowej. System opinii pełni kluczową rolę w dwóch aspektach aplikacji. Po pierwsze, realizuje mechanizm social proof budujący zaufanie do produktów poprzez autentyczne recenzje od rzeczywistych klientów - potencjalni kupujący mogą zapoznać się z doświadczeniami innych użytkowników przed podjęciem decyzji zakupowej. Po drugie, opinie są automatycznie przetwarzane przez algorytm analizy sentymentu jako jedno z pięciu źródeł tekstowych (z wagą 40% w wieloźródłowej agregacji opisanej w sekcji 5.3), co czyni je najważniejszym elementem systemu oceny jakości produktów.

Wyszukiwarka z sortowaniem według sentymentu

The screenshot shows a search results page for 'rtx' products. At the top is a search bar with 'Search Products' placeholder text and a 'Fuzzy Search' button. The search term 'rtx' is entered. Below the search bar are three product cards, each with a thumbnail, name, price, sentiment score, and opinion count.

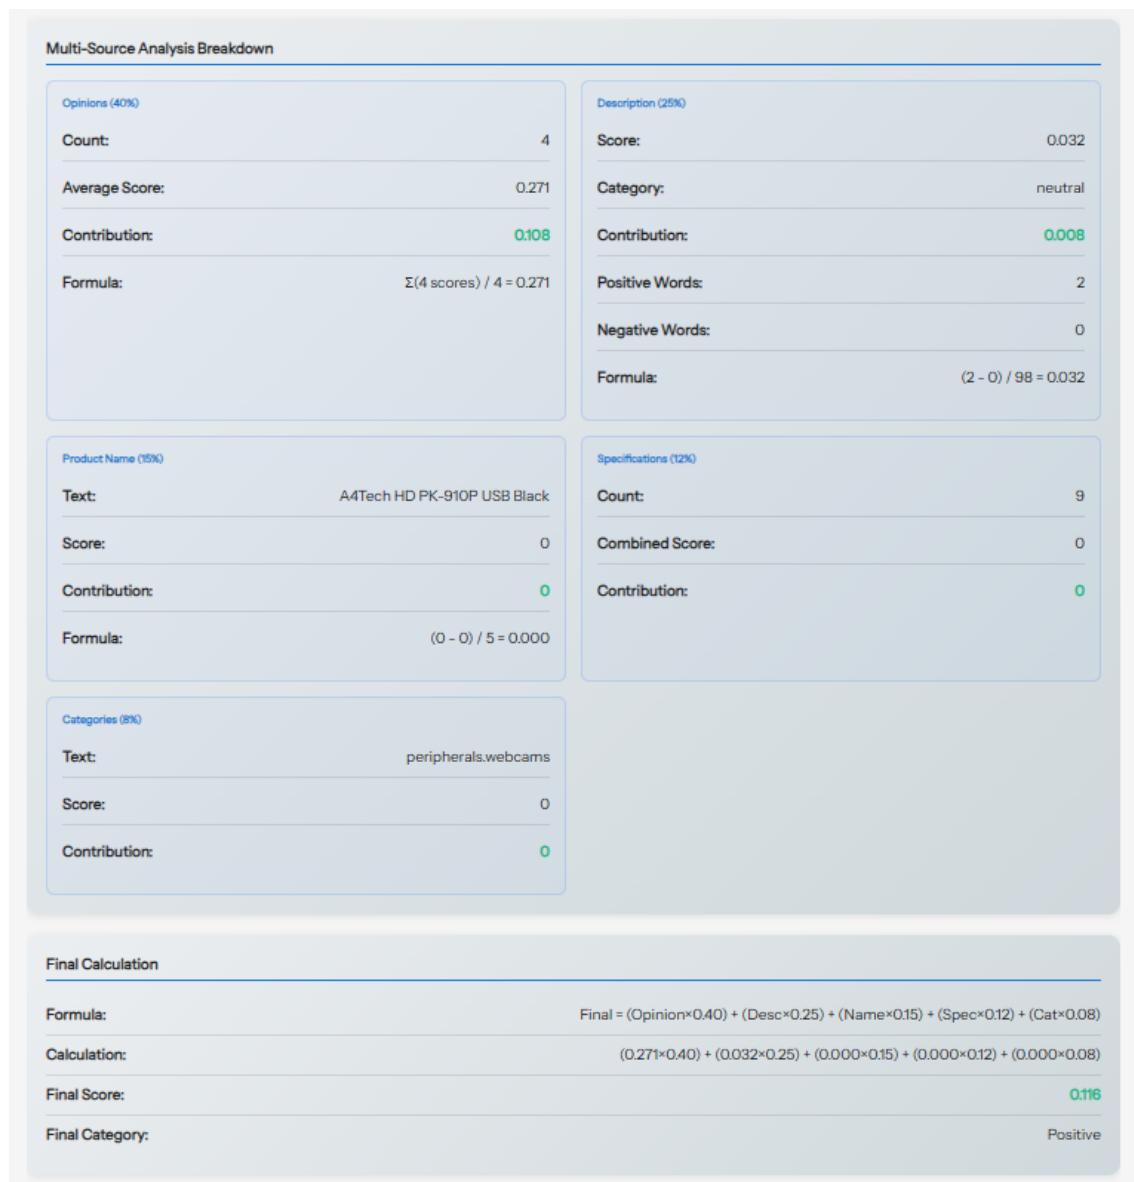
Product	Price	Sentiment Score	Opinions
Gigabyte GeForce RTX 4060 Eagle OC 8GB GDDR6	\$350.00	0.16 (Positive)	3 3 0 0
Microsoft Surface Laptop Studio 2 i7/32GB/1TB/GeForce RTX4050	\$4900.00	0.14 (Positive)	2 2 0 0
Gainward GeForce RTX 4080 Super Panther OC 16GB GDDR6X	\$1025.00	0.14 (Positive)	5 3 1 1

Rysunek 16: Wyszukiwarka produktów z sortowaniem według sentymentu.

Rysunek 16 przedstawia wyszukiwarkę z wynikami posortowanymi według zagręgowanego sentymentu. Każdy produkt wyświetla wynik sentiment score, kategorię oraz rozkład opinii.

Panel debugowania analizy sentymenu

Panel debugowania analizy sentymenu znajduje się w sekcji administracyjnej systemu i służy do weryfikacji poprawności działania algorytmu oraz analizy zagregowanych wyników sentymenu produktów. Narzędzie to jest przeznaczone dla administratorów systemu oraz programistów przeprowadzających testy działania algorytmu. Panel umożliwia podgląd wyników z źródeł tekstowych (opinie, opis, nazwa, specyfikacje, kategorie) wraz z przypisanymi wagami, sprawdzenie statusu kategorii sentymenu oraz analizę rozkładu opinii pozytywnych, neutralnych i negatywnych.



Rysunek 17: Panel debugowania analizy sentymenu.

Rysunek 17 pokazuje panel debugowania analizy sentymenu. Administrator może wybrać dowolny produkt z listy rozwijanej i sprawdzić wynik zagregowany, status kategorii oraz szczegółowe informacje z poszczególnych źródeł tekstowych.

6.3 Metoda reguł asocjacyjnych (Apriori)

Widok rekomendacji Apriori na stronie produktu

The screenshot shows a product page with a shopping cart summary and a 'Frequently Bought Together' section.

Shopping Cart Summary:

Product	Name	Quantity	Total Price	Remove
	ASUS PRIME B550-PLUS	1	\$100.00	X
	Elgato Facecam MK.2	1	\$199.99	X
	Fellowes LX200	1	\$59.99	X

Frequently Bought Together:

1. **Sony KD-65X75WL 65" LED 4K Google TV Dolby Vision...** (\$1499.99) - Confidence: 100%, Lift: 76.50x, Support: 0.7% - ADD TO CART

2. **Hisense 55E7NQ PRO 55" QLED 4K 144Hz VIDAA Full...** (\$799.99) - Confidence: 100%, Lift: 76.50x, Support: 0.7% - ADD TO CART

3. **ICY BOX Hub 4-port USB-A** (\$14.99) - Confidence: 100%, Lift: 76.50x, Support: 0.7% - ADD TO CART

4. **Sencor Desk Calculator** (\$14.99) - Confidence: 50%, Lift: 76.50x, Support: 0.7% - ADD TO CART

Rysunek 18: Sekcja „Frequently Bought Together” na stronie produktu.

Rysunek 18 przedstawia sekcję „Frequently Bought Together” na stronie produktu. Pod numerem (1) widoczne są produkty dodane przez użytkownika do koszyka. Pod numerem (2) system wyświetla produkty proponowane na podstawie reguł asocjacyjnych wraz z metrykami lift, support i confidence.

Panel zarządzania regułami asocjacyjnymi

The screenshot shows the 'Association Rules Management' panel.

Header: Association Rules Management (Custom Apriori), Show All Rules, Update Rules

Description: Association rules help identify products frequently bought together. These rules power the "Frequently Bought Together" recommendations in the shopping cart. Using custom manual Apriori algorithm implementation with real formulas from scientific literature (Agrawal & Srikant 1994).

Table of Rules:

Product 1	Product 2	Support	Confidence	Lift
Sony ZV-E10 + 16-50mm	Set Z2 Ryzen 5 5600, RTX 4060 8GB, 16GB DDR4, 1TB SSD, Signum 300 ARGB, 750W	0.7%	100.0%	153.00
HP 255 G9 Ryzen 5-5625U/16GB/512/Win11	Razer Basilisk V3	0.7%	100.0%	153.00
Razer Basilisk V3	HP 255 G9 Ryzen 5-5625U/16GB/512/Win11	0.7%	100.0%	153.00
Toshiba P300 1TB 7200obr. 64MB	HP 255 G9 Ryzen 5-5625U/16GB/512/Win11	0.7%	100.0%	153.00
HP 255 G9 Ryzen 5-5625U/16GB/512/Win11	Toshiba P300 1TB 7200obr. 64MB	0.7%	100.0%	153.00
HP 255 G9 Ryzen 5-5625U/16GB/512/Win11	soundcore Boom 2 czarny	0.7%	100.0%	153.00
soundcore Boom 2 czarny	HP 255 G9 Ryzen 5-5625U/16GB/512/Win11	0.7%	100.0%	153.00
Toshiba P300 1TB 7200obr. 64MB	Razer Basilisk V3	0.7%	100.0%	153.00
Razer Basilisk V3	Toshiba P300 1TB 7200obr. 64MB	0.7%	100.0%	153.00
soundcore Boom 2 czarny	Razer Basilisk V3	0.7%	100.0%	153.00

Rysunek 19: Panel administracyjny zarządzania regułami Apriori.

Rysunek 19 pokazuje panel administracyjny z listą wygenerowanych reguł asocjacyjnych. Pod numerem (1) znajduje się lista par produktów często kupowanych razem. Pod numerem (2) wyświetlane są szczegółowe metryki każdej reguły - support, confidence i lift.

Panel debugowania reguł asocjacyjnych

Panel debugowania reguł asocjacyjnych znajduje się w sekcji administracyjnej systemu i służy do weryfikacji poprawności działania wygenerowanych reguł. Panel umożliwia wybór dowolnego produktu z listy rozwijanej, podgląd wszystkich reguł asocjacyjnych dla wybranego produktu wraz z metrykami (support, confidence, lift), analizę top 10 najsielniejszych reguł posortowanych według wartości lift oraz sprawdzenie rozkładu wartości lift i porównanie ze średnimi globalnymi.

Association Rules Debug Information

Select Product to Inspect

A4Tech HD PK-910P USB Black	1
-----------------------------	---

Product: A4Tech HD PK-910P USB Black

Product ID:	295
Product Support:	0.65%
Transactions with This Product:	1
Rules for This Product:	2

Database Statistics

All Orders in Database:	200
Single Product Orders:	47
Multi-Product Orders:	153
Total Rules in System:	500

Algorithm uses only 153 orders with 2+ products (excludes 47 single-product orders)

Algorithm Behavior	2
--------------------	---

Filtering: Association rules ONLY use orders with 2+ products

Reason: Single-product orders cannot show 'bought together' patterns

Impact: Using 153 transactions instead of 200 total orders

Rysunek 20: Panel debugowania Apriori - wybór produktu i dane z bazy.

Rysunek 20 przedstawia pierwszy ekran panelu debugowania algorytmu Apriori. Pod numerem (1) administrator wybiera produkt z listy rozwijanej. Poniżej system wyświetla dane produktu z bazy danych, obliczenia transakcji oraz wszystkie reguły asocjacyjne dla wybranego produktu.

Top 10 Association Rules for This Product

Rank	Product	Support	Confidence	Lift
1	Brother HL-L8260CDW	0.65%	100.0%	153.00x
2	TP-Link Archer C6 (1200Mb/s a/b/g/n/ac) DualBand	0.65%	100.0%	153.00x

1

Detailed Rule Analysis

Rule #1: A4Tech HD PK-910P USB Black → Brother HL-L8260CDW

Support Formula: $\text{Support}(A,B) = 1/153 = 0.0065$

Confidence Formula: $\text{Confidence}(A \rightarrow B) = \text{Support}(A,B)/\text{Support}(A) = 0.0065/0.0065 = 1.0$

Lift Formula: $\text{Lift}(A \rightarrow B) = \text{Support}(A,B)/(\text{Support}(A) \times \text{Support}(B)) = 0.0065/(0.0065 \times 0.0065) = 153.0$

Support:	0.65% of transactions contain both products
Confidence:	If customer buys A4Tech HD PK-910P USB Black, there's 100.0% chance they'll buy Brother HL-L8260CDW
Lift:	Products are bought together 153.0x more than random chance

Rule #2: A4Tech HD PK-910P USB Black → TP-Link Archer C6 (1200Mb/s a/b/g/n/ac) DualBand

Support Formula: $\text{Support}(A,B) = 1/153 = 0.0065$

Confidence Formula: $\text{Confidence}(A \rightarrow B) = \text{Support}(A,B)/\text{Support}(A) = 0.0065/0.0065 = 1.0$

Lift Formula: $\text{Lift}(A \rightarrow B) = \text{Support}(A,B)/(\text{Support}(A) \times \text{Support}(B)) = 0.0065/(0.0065 \times 0.0065) = 153.0$

Support:	0.65% of transactions contain both products
Confidence:	If customer buys A4Tech HD PK-910P USB Black, there's 100.0% chance they'll buy TP-Link Archer C6 (1200Mb/s a/b/g/n/ac) DualBand
Lift:	Products are bought together 153.0x more than random chance

2

Association Rules (Formulas)

Support

$$\text{Support}(A, B) = \frac{|A \cap B|}{n} = \frac{\text{transactions with both}}{\text{total transactions}}$$

Measures how frequently both products appear together in transactions.

Confidence

$$\text{Confidence}(A \rightarrow B) = \frac{|B|}{|A|} = \frac{n(A \cap B)}{n(A)} = \frac{\text{Support}(A, B)}{\text{Support}(A)}$$

Probability of buying B when A is purchased.

Lift

$$\text{lift}(A \rightarrow B) = \frac{\text{Confidence}(A \rightarrow B)}{\text{Support}(B)}$$

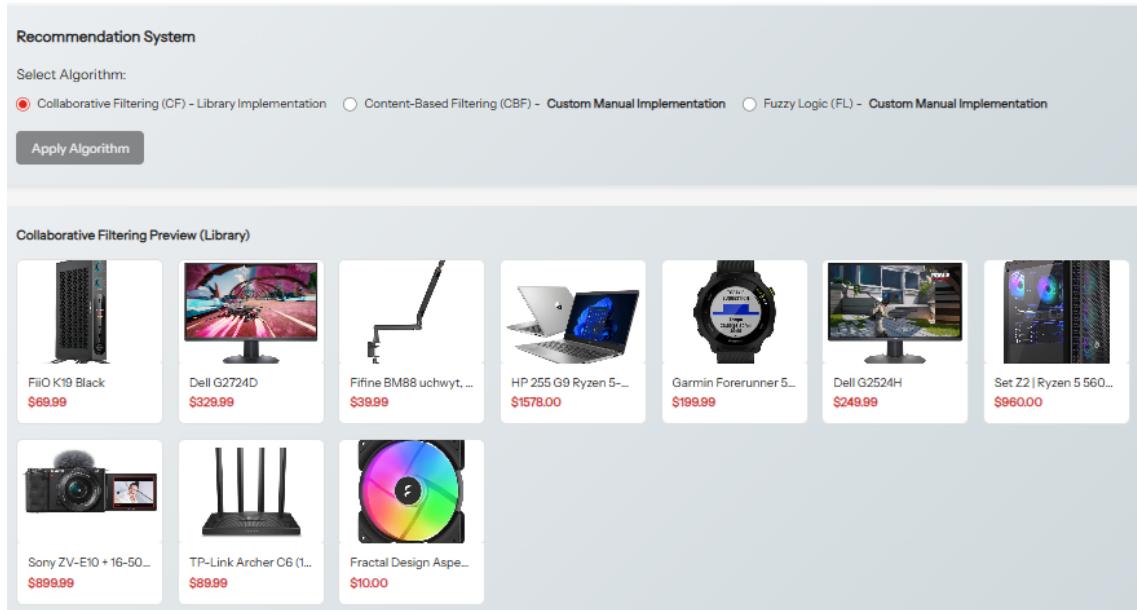
How many times more likely B is purchased with A compared to random chance.

Rysunek 21: Panel debugowania Apriori - top 10 reguł i szczegóły analizy.

Rysunek 21 pokazuje drugą część panelu debugowania Apriori. Pod numerem (1) znajduje się ranking top 10 reguł asocjacyjnych dla wybranego produktu posortowanych według lift. Pod numerem (2) wyświetlane są szczegółowe analizy reguł dla produktów, w tym rozkład wartości lift, średnie metryki oraz porównanie z globalnymi statystykami.

6.4 Konfiguracja metod rekomendacji w panelu administratora

Panel administracyjny umożliwia dynamiczne przełączanie między trzema metodami rekomendacji wyświetlonymi na stronie głównej aplikacji.



Rysunek 22: Panel zarządzania metodami rekomendacji.

Rysunek 22 przedstawia panel konfiguracji z opcjami metod rekomendacyjnych. Administrator może wybrać aktywny algorytm, który będzie wykorzystywany we wszystkich sekcjach rekomendacji na stronie głównej. System zawiera łącznie sześć metod rekomendacyjnych zaimplementowanych w ramach dwóch prac inżynierskich. W ramach niniejszej pracy zaimplementowano:

- **Collaborative Filtering** - rekomendacje oparte na historii zakupów użytkowników (opisane w niniejszej pracy).

Pozostałe metody (Content-Based Filtering, Fuzzy Logic) zostały zaimplementowane przez współautora systemu i opisane w odrębnej pracy inżynierskiej.

Zmiana metody następuje natychmiast po zapisaniu ustawień i wpływa na wszystkie sekcje rekomendacji w aplikacji.

Mechanizmy optymalizacji systemu

System wykorzystuje mechanizmy optymalizacji dla zapewnienia wydajności:

Prekalkulacja w bazie danych

Wszystkie trzy algorytmy zapisują wyniki do dedykowanych tabel z indeksami przyspieszającymi zapytania:

- `method_product_similarity` - macierz podobieństw Collaborative Filtering,
- `method_productassociation` - reguły asocjacyjne Apriori,
- `method_product_sentiment_summary` - zagregowany sentyment produktów.

Django Signals - automatyczna aktualizacja

System wykorzystuje mechanizm Django Signals do automatycznego przeliczania rekomendacji po zmianach danych:

- Nowe zamówienie - przeliczenie macierzy Collaborative Filtering,
- Nowa opinia - aktualizacja sentymetu produktu,
- Nowy produkt - automatyczna analiza sentymetu opisu i nazwy.

Operacje zbiorcze

System używa operacji zbiorczych (bulk operations) dla zapisu wielu rekordów jednocześnie, co znacząco przyspiesza operacje zapisu do bazy danych.

Rozdział 7

Porównanie i ewaluacja metod rekomendacyjnych

Rozdział przedstawia praktyczne porównanie sześciu metod rekomendacyjnych za-implementowanych w aplikacji we współpracy dwuosobowej. Ewaluacja koncentruje się na trzech parach metod o komplementarnym charakterze: Collaborative Filtering vs Content-Based Filtering (podejście behawioralne vs atrybutowe), Sentiment Analysis vs Fuzzy Logic (uniwersalne vs spersonalizowane), oraz Apriori vs Markov Chain (współzakupy vs sekwencje czasowe).

Krótką charakterystyka metod współautora projektu

Content-Based Filtering (CBF) analizuje cechy produktów i znajduje podobieństwa między nimi. System sprawdza kategorie produktu, jego tagi, przedział cenowy oraz słowa kluczowe z opisu. Każda z tych cech ma przypisaną wagę - kategorie są najważniejsze (40%), następnie tagi (30%), cena (20%) i słowa kluczowe (10%). Dzięki temu laptop jest podobny do innego laptopa przez wspólne cechy, nie przez to że użytkownicy kupowali je razem. Wyniki podobieństw są zapisywane w modelu ProductSimilarity z oznaczeniem typu content_based. Zaletą tej metody jest natychmiastowe działanie dla nowych produktów - wystarczą same cechy z formularza dodawania produktu. Algorytm ekstrahuje słowa kluczowe z opisów, co pozwala uwzględnić nawet szczegółowe specyfikacje techniczne. W praktyce metoda najlepiej sprawdza się w katalogach z dobrze opisanymi produktami o jasno zdefiniowanych cechach.

Fuzzy Logic personalizuje rekomendacje według profilu cenowego użytkownika. System używa sześciu reguł typu „jeśli-to” (IF-THEN), które oceniają produkty na podstawie trzech kryteriów: cena (tania/średnia/droga), jakość z ocen użytkowników (niska/średnia/wysoka) oraz popularność mierzona liczbą zamówień. Dla każdego użytkownika budowany jest profil na podstawie jego historii zakupów – system oblicza parametr wrażliwości cenowej, który określa czy użytkownik preferuje tanie produkty czy drogie premium. Ten sam produkt może być polecony użytkownikowi premium jako „wysoka jakość, warta swojej ceny” i odrzucony dla użytkownika budżetowego jako „zbyt drogi”. Metoda jest dostępna w dedykowanej sekcji panelu klienta. Wnioskowanie rozmyte używa funkcji przynależności trójkątnych, które modelują płynne przejścia między kategoriami cenowymi zamiast ostrych granic. Dzięki temu system unika sytuacji gdzie produkt za 499 PLN jest „tani” a za 501 PLN nagle staje się „drogi”.

Modele Probabilistyczne przewidują przyszłe zakupy łącząc dwa algorytmy. Pierwszy analizuje sekwencje zakupów w czasie i przewiduje którą kategorię użytkownik prawdopodobnie kupi następną (np. „po laptopie zwykle następują akcesoria komputerowe”).

Drugi algorytm ocenia prawdopodobieństwo zakupu na podstawie pięciu cech użytkownika: łączna liczba zamówień, średnia wartość zamówienia, dni od ostatniego zakupu, ulubiona kategoria oraz częstotliwość zakupów. Oba modele działają razem, co pozwala identyfikować użytkowników zagrożonych odejściem oraz planować kampanie retention. Wyniki są widoczne w sekcji analiz probabilistycznych panelu klienta z wizualizacją łańcucha przejść między kategoriami. Model sekwencji wykorzystuje macierz przejść trenowaną na rzeczywistych sekwencjach zamówień, co pozwala modelować zachowania specyficzne dla danego sklepu.

Porównanie par metod

Collaborative Filtering vs Content-Based Filtering

Tabela 1 przedstawia kluczowe różnice między metodami CF i CBF. Item-Based CF analizuje historię zakupów i buduje macierz podobieństw produktów używając algorytmu Adjusted Cosine Similarity z centrowaniem średniej użytkownika. CBF ekstrahuje cechy bezpośrednio z atrybutów produktów (kategoria, tagi, cena) bez potrzeby historii zakupów.

Tabela 1: Porównanie metod Collaborative Filtering i Content-Based Filtering

Kryterium	CF (Item-Based)	CBF (Feature-Based)
Źródło danych	Historia zakupów	Atrybuty produktów
Pokrycie katalogu	Częściowe - tylko produkty z historią	Pełne - każdy produkt ma cechy
Problem cold start	Występuje dla nowych produktów	Nie występuje
Typ powiązań	Nieoczywiste cross-category (aparat → plecak)	Oczywiste w kategorii (laptop A → laptop B)
Algorytm	Adjusted Cosine + centrowanie średniej	Weighted TF-IDF + Cosine Similarity
Przechowywanie	ProductSimilarity (type='collaborative')	ProductSimilarity (type='content_based')
Złożoność	Wysza - macierz wszystkich produktów	Niższa - wektory powiązanych produktów

Różnice w działaniu: CF wykrywa powiązania które nie są oczywiste na podstawie samych cech produktów. Jeśli użytkownicy kupujący aparaty fotograficzne często kupują też plecaki turystyczne, CF połączy te produkty mimo różnych kategorii. CBF natomiast zaleci laptopy podobne do laptopów – produkty z tej samej kategorii, w podobnym przedziale cenowym, o podobnych tagach. CF wymaga dużo danych historycznych aby działać

dobrze, podczas gdy CBF działa od razu bo każdy produkt ma cechy.

Zastosowanie praktyczne: W projekcie obie metody działają równolegle. Macierz podobieństw CF jest obliczana offline na podstawie historii zakupów wszystkich użytkowników — to nie wymaga logowania. Natomiast spersonalizowane rekomendacje „Polecane dla Ciebie” wymagają zalogowania, aby system wiedział która historia zakupów ma być podstawą rekomendacji. CBF jest używany dla nowych produktów bez historii współ-zakupów oraz jako fallback — gwarantuje że każdy produkt może być rekommendowany nawet bez danych transakcyjnych. Dla sklepów z małą liczbą transakcji CBF jest bezpieczniejszym wyborem. Dla dojrzałych sklepów z bogatą historią CF odkrywa ciekawsze po-wiązania które zwiększą cross-selling.

Sentiment Analysis vs Fuzzy Logic

Tabela 2 zestawia metody uniwersalną (Sentiment) i spersonalizowaną (Fuzzy Logic). Sentiment agreguje tekst z pięciu źródeł używając leksykonów Opinion Lexicon (Hu & Liu 2004) i AFINN-165 (Nielsen 2011). Fuzzy Logic buduje indywidualny FuzzyUserProfile z historii zakupów każdego użytkownika.

Tabela 2: Porównanie metod Sentiment Analysis i Fuzzy Logic

Kryterium	Sentiment (uniwersalny)	Fuzzy (spersonalizowany)
Personalizacja	Nie - identyczny dla wszystkich	Tak - FuzzyUserProfile z parametrem price_sensitivity
Źródła danych	5 źródeł: opinie, opis, nazwa, specs, kategorie	Historia: średnia cena, częstotliwość kategorii, liczba zamówień
Pokrycie	Pełne - każdy produkt ma tekst	Częściowe - zakres cenowy użytkownika
Typ oceny	Obiektywna jakość (pozytywny/negatywny)	Relatywna wartość („tani” vs „drogi”)
Algorytm	Leksykony słów pozytywnych/negatywnych	Mamdani z 6 regułami IF-THEN
Cache	Tak - model ProductSentimentSummary	Nie - dynamiczne
Użycie	Wyszukiwarka (sortowanie)	Panel klienta (sekcja Fuzzy)

Różnice w działaniu: Sentiment ocenia czy produkt jest obiektywnie dobry czy zły analizując tekst opinii, opisów i specyfikacji. Laptop z wieloma pozytywnymi opiniami dostanie wysoki score niezależnie od tego kto go przegląda. Fuzzy Logic natomiast ocenia czy produkt pasuje do konkretnego użytkownika - ten sam laptop może być „zbyt drogi” dla użytkownika budżetowego i „świetna wartość” dla użytkownika premium. Sentiment

jest szybszy bo wynik jest obliczany raz i zapisywany w bazie, Fuzzy musi przeliczać 6 reguł dla każdego użytkownika osobno.

Zastosowanie praktyczne: Metody działają komplementarnie. Sentiment jest używany w wyszukiwarce do sortowania produktów według jakości – pokazuje obiektywnie najlepsze produkty na górze listy. Fuzzy Logic jest w panelu klienta jako osobna sekcja rekomendacji – filzuje produkty według profilu cenowego użytkownika. Użytkownik który zawsze kupuje produkty poniżej 300 PLN nie zobaczy laptopów za 5000 PLN nawet jeśli mają doskonałe opinie. System buduje profil automatycznie analizując poprzednie zakupy.

Apriori vs Markov Chain

Tabela 3 porównuje metody przewidywania zakupów. Apriori analizuje współwystępowanie produktów w koszykach zakupowych i generuje reguły asocjacyjne z metrykami support, confidence, lift. Markov analizuje sekwencje kategorii w czasie i przewiduje przyszłe wizyty.

Tabela 3: Porównanie metod Apriori i Markov Chain

Kryterium	Apriori (współzakupy)	Markov (sekwencje)
Zakres czasowy	Teraźniejszość - koszyk zakupowy	Przyszłość - następna wizyta
Typ predykcji	Produkty kupowane razem (laptop + mysz)	Kategorie w kolejnych transakcjach
Pokrycie	Częściowe - produkty kupione razem	Szerokie - poziom kategorii
Algorytm	Bitmap pruning + antymonotoniczność	First-order Markov (48 stanów)
Przechowywanie	Model Product Association	Macierz przejść z historii
Optymalizacja	Bitmap - liczby binarne, operacje AND	Naive Bayes (5 cech użytkownika)
Użycie	Koszyk - „Często kupowane razem”	Panel - wizualizacja przejść
Wartość	Cross-selling (\uparrow wartość transakcji)	Retention (identyfikacja churn)

Różnice w działaniu: Apriori szuka produktów które ludzie kupują razem w jednym zamówieniu. Jeśli klient dodaje laptop do koszyka, Apriori pokaże mysz i torbę bo poprzedni klienci kupowali to razem. Metryki support, confidence i lift określają jak silne jest powiązanie. Markov natomiast analizuje kolejność zakupów w czasie – jeśli użytkownik kupił laptop w styczniu, Markov przewiduje że w lutym prawdopodobnie wróci po

akcesoria komputerowe. Apriori jest szybszy bo używa bitmap pruning (operacje bitowe zamiast pętli), Markov wymaga więcej obliczeń bo musi przeanalizować całą historię użytkownika.

Zastosowanie praktyczne: Apriori maksymalizuje wartość bieżącej transakcji – pokazuje dodatkowe produkty w koszyku które klient może chcieć kupić od razu. Markov służy do planowania kampanii retention – identyfikuje użytkowników którzy prawdopodobnie nie wrócą do sklepu i można im wysłać rabat zachęcający do powrotu. W panelu admina Markov wizualizuje przepływ między kategoriami jako graf, co pomaga zrozumieć ścieżki zakupowe klientów i zaplanować strategię merchandisingową.

Tabela 4 zestawia wszystkie sześć metod według kluczowych charakterystyk. Każda metoda ma specyficzne zastosowanie w zależności od kontekstu użycia i dostępnych danych.

Tabela 4: Zestawienie zbiorcze sześciu metod rekomendacyjnych

Metoda	Dane	Cold start	Typ	Zastosowanie
CF	Historia zakupów	Tak (nowe produkty)	Powiązania cross-category	Discovery
CBF	Atrybuty produktów	Nie	Podobieństwa w kategorii	Nowe produkty
Sentiment	Tekst	Częściowy	Ocena jakości	Ranking
Fuzzy	Historia użytkownika	Tak (nowi użytkownicy)	Profil cenowy	Personalizacja
Apriori	Koszyki	Tak (nowe produkty)	Komplementarne	Cross-selling
Markov	Sekwencje	Nie	Predykcja kategorii	Retention

Wnioski z implementacji:

(1) Metody uzupełniają się wzajemnie. Żadna pojedyncza metoda nie rozwiązuje wszystkich problemów rekomendacji. CF doskonale wykrywa nieoczywiste powiązania ale wymaga bogatej historii. CBF gwarantuje pokrycie wszystkich produktów ale generuje oczywiste sugestie. Sentiment ocenia jakość ale nie personalizuje. Fuzzy personalizuje ale wymaga profilu użytkownika. Najlepsze rezultaty daje połączenie wszystkich metod w różnych częściach interfejsu.

(2) Wybór metody zależy od dojrzałości sklepu. Dla nowego sklepu z małą liczbą produktów i transakcji najlepszy jest start z CBF i Sentiment – działają od razu bez historii. Po zgromadzeniu kilkuset transakcji można dodać Apriori do koszyka dla cross-sellingu. Gdy sklep ma tysiące transakcji i setki aktywnych użytkowników, CF i Markov zaczynają dawać wartość odkrywając wzorce zachowań.

(3) Optymalizacja jest kluczowa dla wydajności. Bitmap pruning w Apriori znacząco przyspiesza przetwarzanie – reprezentacja transakcji jako liczb binarnych pozwala na operacje bitowe zamiast iteracji po listach. Cache'owanie wyników Sentiment elimi-

nuje powtarzalne obliczenia. Indeksowanie w bazie danych (model ProductSimilarity) przyspiesza wyszukiwanie podobnych produktów.

(4) Praktyczne zastosowanie jest różne. Apriori daje efekt natychmiast – sekcja „Często kupowane razem” w koszyku bezpośrednio zwiększa wartość zamówienia. Markov ma wartość długoterminową – identyfikuje użytkowników którzy przestają być aktywni i pozwala reagować kampaniami. CF i CBF działają w tle stale sugerując produkty. Sentiment pomaga w nawigacji po katalogu.

Ograniczenia badania: System był testowany z danymi z seedera, nie z prawdziwymi użytkownikami. Rzeczywiste wzorce zachowań mogą być inne. Wydajność mierzona była bez równoczesnego obciążenia wieloma użytkownikami. Brak testów A/B uniemożliwia precyzyjne określenie wpływu każdej metody na współczynnik konwersji. Przyszłe wdrożenie produkcyjne wymaga monitorowania rzeczywistych metryk biznesowych.

Podsumowanie i wnioski końcowe

Niniejsza praca przedstawiła proces implementacji oraz analizy kompletnego systemu e-commerce wyposażonego w mechanizmy rekomendacji produktów. System został opracowany od podstaw we współpracy dwuosobowej, przy czym w ramach niniejszej pracy zaimplementowano trzy metody rekomendacyjne: Collaborative Filtering z metryką Adjusted Cosine Similarity, analizę sentymentu opartą na podejściu słownikowym oraz reguły asocjacyjne wykorzystujące algorytm Apriori.

Ograniczenia systemu

W trakcie realizacji projektu zidentyfikowano następujące ograniczenia:

Problem zimnego startu — algorytmy Collaborative Filtering oraz Apriori wymagają historycznych danych o interakcjach użytkowników z produktami. Dla nowych użytkowników bez historii zakupów oraz nowych produktów bez opinii mechanizmy te nie są w stanie generować efektywnych rekomendacji. Analiza sentymentu częściowo kompensuje to ograniczenie, ponieważ może ocenić jakość produktu na podstawie jego opisu, specyfikacji technicznych oraz nazwy, nawet w przypadku braku opinii użytkowników.

Ograniczenia analizy sentymentu — zastosowane podejście słownikowe nie radzi sobie efektywnie z negacją językową (przykład: „nie polecam”) oraz z ironią i sarkazmem. Słowa pozytywne w kontekście negatywnym mogą być błędnie klasyfikowane, co wpływa na dokładność oceny sentymentu. Rozwiążanie tego problemu wymagałoby zastosowania bardziej zaawansowanych technik przetwarzania języka naturalnego, takich jak modele kontekstowe.

Skalowalność dla bardzo dużych katalogów — dla katalogów produktów przekraczających tysiące pozycji mogą wystąpić wyzwania wydajnościowe wymagające dalszych optymalizacji, takich jak partycjonowanie danych, rozproszenie obliczeń lub zastosowanie dedykowanych struktur danych.

Kierunki dalszego rozwoju

Zidentyfikowano następujące kierunki rozwoju systemu:

Zastosowanie głębokiego uczenia maszynowego — obecny system wykorzystuje klasyczne algorytmy rekomendacyjne oparte na analizie podobieństw oraz regułach asocjacyjnych. Zastosowanie sieci neuronowych, takich jak autoencodery czy sieci rekurencyjne, mogłoby umożliwić automatyczne uczenie się ukrytych wzorców w danych bez konieczności ręcznego definiowania reguł. Przykładowo, sieci neuronowe mogłyby odkryć nieoczywiste zależności między produktami oraz preferencjami użytkowników, które nie są widoczne w tradycyjnych metrykach podobieństwa.

Rekomendacje w czasie rzeczywistym — obecny system wykorzystuje mechanizm cache'owania z okresem ważności 2 godzin (CACHE_TIMEOUT_LONG = 7200 sekund), co oznacza, że rekomendacje są przeliczane cyklicznie. Implementacja systemu aktualizującego rekomendacje w czasie rzeczywistym po każdej akcji użytkownika (przeglądanie produktów, dodawanie do koszyka, finalizacja zakupu) mogłaby znaczco zwiększyć trafność sugestii poprzez uwzględnienie bieżącego kontekstu sesji zakupowej. Jednakże należy rozważyć, czy takie rozwiązanie nie wpłynęłoby negatywnie na efektywność działania całego systemu ze względu na konieczność ciągłego przeliczania rekomendacji.

Zaawansowane metody obsługi zimnego startu — zastosowanie technik faktoryzacji macierzy, takich jak Singular Value Decomposition (SVD), mogłoby umożliwić generowanie rekomendacji dla nowych produktów na podstawie ich cech (kategoria, cena, marka, specyfikacja) oraz analogii do istniejących produktów.

Wnioski końcowe

Zrealizowany system stanowi kompletne rozwiązanie e-commerce z mechanizmami rekomendacji produktów, gotowe do wdrożenia w środowisku produkcyjnym. Implementacja od podstaw bez wykorzystania gotowych bibliotek rekomendacyjnych umożliwiła pełne zrozumienie mechanizmów działania algorytmów oraz ich świadome dostosowanie do specyfiki handlu elektronicznego. Komplementarność zastosowanych metod — Collaborative Filtering dla identyfikacji produktów podobnych, analiza sentymentu dla oceny jakości oraz algorytm Apriori dla cross-sellingu — zapewnia wszechstronne wsparcie procesu decyzyjnego użytkownika. Zastosowane techniki optymalizacyjne, w tym bitmap pruning, cache'owanie oraz indeksowanie bazy danych, gwarantują akceptowalne czasy odpowiedzi systemu nawet przy większych katalogach produktów.

Praca wykazała, że implementacja systemu rekomendacyjnego od podstaw jest możliwa i celowa w kontekście edukacyjnym oraz w sytuacjach wymagających pełnej kontroli nad logiką biznesową. Zrealizowany projekt pozwolił na zdobycie praktycznej wiedzy w zakresie projektowania systemów rekomendacyjnych, optymalizacji algorytmów, rozwoju aplikacji.

Literatura

- [1] Rakesh Agrawal, Ramakrishnan Srikant, *Fast Algorithms for Mining Association Rules*, Proceedings of the 20th International Conference on Very Large Data Bases (VLDB), 1994.
- [2] James Bennett, Stan Lanning, *The Netflix Prize*, Proceedings of KDD Cup and Workshop, 2007.
- [3] Jonathan L. Herlocker, Joseph A. Konstan, John Riedl, *Explaining Collaborative Filtering Recommendations*, Proceedings of the 2000 ACM Conference on Computer Supported Cooperative Work (CSCW), 2000.
- [4] Greg Linden, Brent Smith, Jeremy York, *Amazon.com Recommendations: Item-to-Item Collaborative Filtering*, IEEE Internet Computing, 2003.
- [5] Bing Liu, *Sentiment Analysis and Opinion Mining*, Synthesis Lectures on Human Language Technologies, Morgan & Claypool Publishers, 2012.
- [6] Jacques Bughin, Michael Chui, James Manyika, *Ten IT-enabled business trends for the decade ahead*, McKinsey Quarterly, May 2013.
- [7] Paul Resnick, Hal R. Varian, *Recommender Systems*, Communications of the ACM, 1997.
- [8] Badrul Sarwar, George Karypis, Joseph Konstan, John Riedl, *Item-based Collaborative Filtering Recommendation Algorithms*, Proceedings of the 10th International Conference on World Wide Web (WWW), 2001.
- [9] Mohammed J. Zaki, *Scalable Algorithms for Association Mining*, IEEE Transactions on Knowledge and Data Engineering, 2000.

Wykaz rysunków i tabel

Spis rysunków

1	Diagram przypadków użycia systemu.	16
2	Diagram ERD głównych tabel aplikacji.	18
3	Diagram ERD tabel metod rekomendacyjnych.	19
4	Architektura deweloperska aplikacji w Docker Compose z mechanizmem hot-reload.	25
5	Diagram sekwencji: Collaborative Filtering.	33
6	Diagram sekwencji: Analiza sentymentu.	36
7	Diagram sekwencji: Algorytm Apriori.	40
8	Strona główna - pierwsza sekcja rekomendacji.	41
9	Strona główna - druga sekcja rekomendacji.	41
10	Strona główna - trzecia sekcja rekomendacji.	42
11	Panel debugowania Collaborative Filtering - formuła algorytmu i dane z bazy.	43
12	Panel debugowania Collaborative Filtering - podsumowanie obliczeń.	44
13	Dashboard klienta z sekcją rekomendacji.	44
14	Formularz dodawania opinii na stronie produktu z oceną gwiazdkową i recenzją tekową.	45
15	Lista opinii produktu z badge'ami sentymentu i oceną gwiazdkową.	46
16	Wyszukiwarka produktów z sortowaniem według sentymentu.	46
17	Panel debugowania analizy sentymentu.	47
18	Sekcja „Frequently Bought Together” na stronie produktu.	48
19	Panel administracyjny zarządzania regułami Apriori.	48
20	Panel debugowania Apriori - wybór produktu i dane z bazy.	49
21	Panel debugowania Apriori - top 10 reguł i szczegóły analizy.	50
22	Panel zarządzania metodami rekomendacji.	51

Spis tabel

1	Porównanie metod Collaborative Filtering i Content-Based Filtering	54
2	Porównanie metod Sentiment Analysis i Fuzzy Logic	55
3	Porównanie metod Apriori i Markov Chain	56
4	Zestawienie zbiorcze sześciu metod rekomendacyjnych	57

Streszczenie

Tytuł pracy w języku polskim:

System rekomendacji produktów oparty na filtracji współpracy, analizie sentymenu i regułach asocjacyjnych

Tytuł pracy w języku angielskim:

Product Recommendation System Based on Collaborative Filtering, Sentiment Analysis, and Association Rules

Streszczenie:

Niniejsza praca inżynierska przedstawia projekt oraz implementację systemu rekomendacji produktów dla platformy e-commerce, łączącego trzy komplementarne metody rekomendacyjne: collaborative filtering, analizę sentymenu oraz reguły asocjacyjne. Celem było zaprojektowanie rozwiązania eliminującego problem przeładowania informacyjnego w sklepach internetowych poprzez dostarczanie użytkownikom spersonalizowanych rekomendacji.

Część teoretyczna obejmuje przegląd systemów rekomendacyjnych oraz analizę rozwiązań alternatywnych (Amazon Personalize, Google Recommendations AI, Apache Mahout) wraz z uzasadnieniem implementacji dedykowanego systemu. Przedstawiono fundament matematyczny wykorzystanych algorytmów: metrykę Adjusted Cosine Similarity dla Item-Based Collaborative Filtering, słownikowe podejście do analizy sentymenu z agregacją wieloźródłową oraz metryki support, confidence i lift dla reguł asocjacyjnych algorytmu Apriori.

Część projektowa obejmuje szczegółowy projekt architektury systemu w modelu trójwarstwowym (warstwa prezentacji React, warstwa logiki biznesowej Django, warstwa danych PostgreSQL), projekt struktury bazy danych z tabelami dla prekalkulowanych wyników algorytmów, projekt interfejsów użytkownika (widoki użytkownika końcowego i panele administracyjne) oraz projekt mechanizmów optymalizacyjnych (cache'owanie, indeksowanie, operacje zbiorcze).

Część implementacyjna przedstawia realizację aplikacji webowej w architekturze Django REST Framework (backend) oraz React 18 (frontend). System integruje trzy metody działające komplementarnie w różnych kontekstach: Collaborative Filtering dla personalizacji na stronie głównej, analizę sentymenu dla oceny jakości w wyszukiwarce oraz algorytm Apriori dla cross-sellingu w koszyku zakupowym. Zaimplementowano kompletny interfejs z narzędziami debugowania oraz panel administracyjny umożliwiający dynamiczne przełączanie metod rekomendacyjnych.

Wartością pracy jest implementacja algorytmów od podstaw, co umożliwiło głębokie zrozumienie mechanizmów oraz świadomie dostosowanie do specyfiki e-commerce.

Załącznik A

Szczegółowe scenariusze użycia

Poniżej przedstawiono szczegółowe opisy scenariuszy użycia systemu odpowiadających przypadkom użycia zaprezentowanym na diagramie w rozdziale 3.3. Scenariusze zostały opisane zgodnie z notacją: Aktor, Warunki początkowe, Przebieg scenariusza głównego, Warunki końcowe.

Scenariusz 1: Przeglądanie i wyszukiwanie produktów

Aktor: Gość (użytkownik niezalogowany)

Warunki początkowe: Użytkownik znajduje się na stronie głównej aplikacji

Przebieg scenariusza głównego:

1. Użytkownik otwiera stronę główną aplikacji w przeglądarce
2. Użytkownik otwiera pasek wyszukiwania z standardową opcją
3. Użytkownik wpisuje szukaną frazę
4. System sortuje produkty według wartości `sentiment_score` malejąco
5. Użytkownik przegląda listę produktów
6. Użytkownik klikna na wybrany produkt
7. System wyświetla szczegółową stronę produktu z opisem, specyfikacjami, zdjęciami i opiniami

Warunki końcowe: Użytkownik widzi szczegółowe informacje o wybranym produkcie

Scenariusz 2: Dodawanie produktów do koszyka

Aktor: Gość (użytkownik niezalogowany)

Warunki początkowe: Użytkownik przegląda szczegółową stronę produktu (laptop)

Przebieg scenariusza głównego:

1. Użytkownik klikna przycisk „Dodaj do koszyka”
2. System dodaje produkt do koszyka i wyświetla powiadomienie o sukcesie
3. Użytkownik klikna ikonę koszyka w nawigacji
4. System wyświetla widok koszyka z dodanymi produktami
5. System automatycznie wywołuje algorytm Apriori dla produktów w koszyku
6. System wyświetla sekcję „Frequently Bought Together” z trzema produktami rekomendowanymi przez algorytm Apriori (torba na laptopa, mysz bezprzewodowa, hub USB-C)

7. Każda rekomendacja zawiera metryki: lift, confidence oraz przycisk „Dodaj do koszyka”
8. Użytkownik przegląda rekomendacje
9. Użytkownik kliką „Dodaj do koszyka” przy torbie i myszy
10. System dodaje wybrane produkty do koszyka i aktualizuje sumę całkowitą

Warunki końcowe: Koszyk zawiera laptop, torbę i mysz, wyświetlona jest zaktualizowana suma

Scenariusz 3: Rejestracja nowego użytkownika

Aktor: Gość (użytkownik niezalogowany)

Warunki początkowe: Użytkownik znajduje się na stronie głównej

Przebieg scenariusza głównego:

1. Użytkownik kliką przycisk „Zarejestruj się” w nawigacji
2. System wyświetla formularz rejestracji
3. Użytkownik wypełnia pola: imię, nazwisko, adres e-mail, hasło, potwierdzenie hasła
4. Użytkownik kliką przycisk „Zarejestruj”
5. System waliduje dane: sprawdza czy e-mail jest unikalny, czy hasła się zgadzają, czy hasło spełnia wymagania bezpieczeństwa
6. System tworzy nowe konto użytkownika w bazie danych
7. System wyświetla komunikat o pomyślnej rejestracji
8. System automatycznie loguje użytkownika i generuje token JWT
9. System przekierowuje użytkownika do panelu klienta

Warunki końcowe: Użytkownik jest zalogowany i posiada aktywne konto w systemie

Scenariusz 4: Logowanie do systemu

Aktor: Gość (użytkownik niezalogowany, posiadający konto)

Warunki początkowe: Użytkownik znajduje się na stronie głównej

Przebieg scenariusza głównego:

1. Użytkownik kliką przycisk „Zaloguj się” w nawigacji
2. System wyświetla formularz logowania
3. Użytkownik wpisuje adres e-mail i hasło
4. Użytkownik kliką przycisk „Zaloguj”

5. System weryfikuje dane logowania w bazie danych
6. System generuje token JWT i zwraca go do klienta
7. Frontend zapisuje token w localStorage przeglądarki
8. System przekierowuje użytkownika do panelu klienta

Warunki końcowe: Użytkownik jest zalogowany, posiada ważny token JWT

Scenariusz 5: Śledzenie statusu zamówienia

Aktor: Klient (użytkownik zalogowany)

Warunki początkowe: Użytkownik jest zalogowany, posiada co najmniej jedno zamówienie

Przebieg scenariusza głównego:

1. Użytkownik otwiera panel klienta
2. Użytkownik kliką zakładkę „My Orders”
3. System pobiera wszystkie zamówienia użytkownika z bazy danych
4. System wyświetla listę zamówień posortowaną od najnowszych
5. Dla każdego zamówienia wyświetlane są: numer zamówienia, status (oczekujące/w realizacji/zakończone/anulowane)

Warunki końcowe: Użytkownik widzi szczegółowe informacje o statusie wybranego zamówienia

Scenariusz 6: Wystawianie opinii o produkcie

Aktor: Klient (użytkownik zalogowany)

Warunki początkowe: Użytkownik posiada zakończone zamówienie zawierające produkt

Przebieg scenariusza głównego:

1. Użytkownik otwiera panel klienta, zakładkę „My Orders”
2. Użytkownik znajduje zakończone zamówienie
3. Użytkownik kliką przycisk „Add Review” przy zakupionym produkcie
4. System wyświetla formularz opinii
5. Użytkownik wybiera ocenę gwiazdkową (1-5 gwiazdek)
6. Użytkownik wpisuje treść tekstową opinii
7. Użytkownik kliką „Wyślij opinię”
8. System zapisuje opinię w bazie danych z powiązaniem: użytkownik, produkt, zamówienie

9. System automatycznie wywołuje algorytm analizy sentymenu dla nowej opinii
10. Algorytm tokenizuje tekst, wyszukuje słowa w słowniku pozytywnym/negatywnym
11. Algorytm oblicza sentiment_score dla opinii zgodnie ze wzorem (2)
12. System przelicza zagregowany sentyment produktu zgodnie ze wzorem (3) (wieloźródłowa agregacja z 5 źródeł)
13. System aktualizuje pole sentiment_score w rekordzie produktu
14. System wyświetla komunikat o pomyślnym dodaniu opinii
15. System odświeża widok produktu - zaktualizowany sentyment jest widoczny

Warunki końcowe: Opinia została dodana, sentyment produktu zaktualizowany

Scenariusz 7: Zarządzanie kontem użytkownika

Aktor: Klient (użytkownik zalogowany)

Warunki początkowe: Użytkownik jest zalogowany

Przebieg scenariusza głównego:

1. Użytkownik otwiera panel klienta
2. Użytkownik klika zakładkę „Konto”
3. System wyświetla formularz z danymi użytkownika: imię, nazwisko, e-mail
4. Użytkownik edytuje wybrane pola (np. zmienia nazwisko)
5. Użytkownik klika „Zapisz zmiany”
6. System waliduje dane (sprawdza czy e-mail jest unikalny, jeśli został zmieniony)
7. System aktualizuje rekord użytkownika w bazie danych
8. System wyświetla komunikat o pomyślnym zapisaniu zmian

Warunki końcowe: Dane użytkownika zostały zaktualizowane

Scenariusz 8: Administrator zarządza produktami

Aktor: Administrator

Warunki początkowe: Administrator jest zalogowany, posiada uprawnienia administratora

Przebieg scenariusza głównego - dodawanie produktu:

1. Administrator otwiera panel administracyjny
2. Administrator klika sekcję „Products”

3. System wyświetla listę wszystkich produktów
4. Administrator klika przycisk „Add New Product”
5. System wyświetla formularz dodawania produktu
6. Administrator wypełnia pola: nazwa, opis, cena, kategorie, specyfikacje techniczne, przesyła zdjęcie
7. Administrator klika „Zapisz produkt”
8. System waliduje dane (sprawdza czy wszystkie wymagane pola są wypełnione)
9. System tworzy nowy rekord produktu w bazie danych
10. System automatycznie wywołuje algorytm analizy sentymentu dla nowego produktu
11. Algorytm oblicza sentiment_score na podstawie nazwy i opisu (brak jeszcze opinii)
12. System zapisuje obliczony sentyment w rekordzie produktu
13. System wyświetla komunikat o pomyślnym dodaniu produktu
14. System odświeża listę produktów

Warunki końcowe: Nowy produkt został dodany do katalogu z obliczonym sentymentem

Scenariusz 9: Administrator zarządza zamówieniami

Aktor: Administrator

Warunki początkowe: Administrator jest zalogowany

Przebieg scenariusza głównego:

1. Administrator otwiera panel administracyjny
2. Administrator klika sekcję „Orders”
3. System wyświetla listę wszystkich zamówień w systemie
4. Dla każdego zamówienia wyświetlane są: numer, aktualny status
5. Administrator klika na wybrane zamówienie ze statusem „oczekujące”
6. Administrator klika przycisk „Zmień status”
7. System wyświetla listę dostępnych statusów (w realizacji, zakończone, anulowane)
8. Administrator wybiera „w realizacji”
9. System aktualizuje status zamówienia w bazie danych
10. System zapisuje zdarzenie zmiany statusu z timestampem

11. System wyświetla komunikat o pomyślnej zmianie statusu
12. Użytkownik właściciel zamówienia widzi zaktualizowany status w swoim panelu

Warunki końcowe: Status zamówienia został zmieniony, użytkownik ma dostęp do aktualnej informacji

Scenariusz 10: Administrator zarządza użytkownikami

Aktor: Administrator

Warunki początkowe: Administrator jest zalogowany

Przebieg scenariusza głównego:

1. Administrator otwiera panel administracyjny
2. Administrator kliką sekcję „Users”
3. System wyświetla listę wszystkich użytkowników
4. Dla każdego użytkownika wyświetlane są: ID, imię, nazwisko, e-mail, rola, data rejestracji
5. Administrator może filtrować użytkowników według roli (klient/administrator)
6. Administrator kliką na wybranego użytkownika
7. System wyświetla szczegóły użytkownika: profil, historia zamówień, statystyki
8. Administrator może zmienić rolę użytkownika (nadać uprawnienia administratora) lub usunąć konto

Warunki końcowe: Administrator ma pełny wgląd w dane użytkowników i może zarządzać uprawnieniami

Scenariusz 11: Administrator przegląda statystyki i dashboard

Aktor: Administrator

Warunki początkowe: Administrator jest zalogowany

Przebieg scenariusza głównego:

1. Administrator otwiera panel administracyjny
2. System automatycznie wyświetla dashboard ze statystykami
3. Dashboard zawiera następujące kluczowe metryki:
 - Całkowita liczba produktów w katalogu
 - Całkowita liczba zarejestrowanych użytkowników
 - Całkowita liczba zamówień (wszystkie statusy)

- Całkowity przychód (suma wartości zamówień zakończonych)

4. System wyświetla wykresy:

- Wykres słupkowy: miesięczny obrót (ostatnie 12 miesięcy)
- Wykres kołowy: rozkład zamówień według kategorii produktów
- Wykres liniowy: liczba nowych użytkowników (ostatnie 30 dni)

5. Administrator kliką sekcję „Statistics” dla bardziej szczegółowych analiz

6. System wyświetla widok do zmiany rekomentacji, odświeżanie reguł asocjacyjnych

Warunki końcowe: Administrator ma pełny wgląd w kluczowe wskaźniki biznesowe systemu

Scenariusz 12: Administrator debuguje algorytmy rekommendacji

Aktor: Administrator

Warunki początkowe: Administrator jest zalogowany, algorytmy rekommendacji zostały przeliczone

Przebieg scenariusza głównego - Collaborative Filtering:

1. Administrator otwiera panel administracyjny
2. Administrator kliką sekcję „Debug”
3. Administrator wybiera zakładkę „Collaborative Filtering”
4. System wyświetla panel debugowania Collaborative Filtering zawierający:
 - Wzór matematyczny Adjusted Cosine Similarity
 - Statystyki: liczba par produktów, średnie podobieństwo, czas ostatniego przeliczenia
 - Tabelę z przykładowymi podobieństwami (product_a, product_b, similarity_score)
5. Administrator może wpisać ID produktu i zobaczyć top 10 najbardziej podobnych produktów
6. System pobiera dane z tabeli ProductSimilarity i wyświetla wyniki

Warunki końcowe: Administrator zweryfikował poprawność działania algorytmu Collaborative Filtering

Scenariusz 13: Przeglądanie rekommendacji na stronie głównej

Aktor: Klient (użytkownik zalogowany)

Warunki początkowe: Użytkownik jest zalogowany, posiada historię zakupów

Przebieg scenariusza głównego:

1. Użytkownik loguje się do systemu

2. System przekierowuje użytkownika do strony głównej
3. System wywołuje algorytm Collaborative Filtering dla zalogowanego użytkownika
4. Algorytm analizuje historię zakupów użytkownika
5. Algorytm pobiera produkty podobne do wcześniej zakupionych (na podstawie macierzy podobieństw)
6. System wyświetla sekcję „Rekomendowane dla Ciebie” z 6 produktami
7. Użytkownik przegląda rekomendacje
8. Użytkownik kliką na wybrany produkt
9. System wyświetla szczegółową stronę produktu

Warunki końcowe: Użytkownik widzi spersonalizowane rekomendacje oparte na swojej historii zakupów

Scenariusz 14: Przeglądanie podobnych produktów (Content-Based Filtering)

Aktor: Klient lub Gość

Warunki początkowe: Użytkownik przegląda szczegółową stronę produktu (np. laptop Dell XPS 15)

Przebieg scenariusza głównego:

1. Użytkownik otwiera stronę szczegółową produktu
2. System automatycznie wywołuje endpoint GET /api/recommendations/content-based/?product_id={id}
3. Backend wywołuje metodę ContentBasedAPI z parametrem product_id
4. System wykonuje zapytanie do tabeli ProductSimilarity filtrując po product1_id = {id} oraz type='content_based'
5. System sortuje wyniki malejąco według similarity_score
6. System pobiera Top 10 najbardziej podobnych produktów z bazy danych
7. Backend zwraca JSON z listą produktów zawierającą: product_id, name, price, similarity_score
8. Frontend wyświetla sekcję „Podobne produkty” z kafelkami produktów
9. Każdy kafelek zawiera zdjęcie, nazwę, cenę oraz wskaźnik podobieństwa (np. „85% podobny”)

10. Użytkownik przegląda rekomendacje
11. Użytkownik kliką na wybrany podobny produkt
12. System przekierowuje do strony szczegółowej wybranego produktu

Warunki końcowe: Użytkownik widzi produkty podobne do oglądanego, obliczone na podstawie cech (kategorie 40%, tagi 30%, cena 20%, słowa kluczowe 10%)

Scenariusz 15: Generowanie macierzy podobieństw Content-Based Filtering

Aktor: Administrator

Warunki początkowe: Administrator jest zalogowany, katalog zawiera produkty

Przebieg scenariusza głównego:

1. Administrator otwiera panel administracyjny
2. Administrator kliką sekcję „Admin Tools”
3. Administrator wybiera zakładkę „Content-Based Filtering”
4. System wyświetla panel zarządzania CBF z przyciskiem „Generate Similarity Matrix”
5. Administrator kliką „Generate Similarity Matrix”
6. System wywołuje endpoint POST /api/admin/content-based/generate
7. Backend uruchamia algorytm ContentBasedRecommendationEngine.generate_similarities()
8. System pobiera wszystkie produkty z bazy danych
9. Dla każdego produktu system ekstrahuje cechy:
 - Kategorie (waga 40%) - konwersja do wektora one-hot
 - Tagi (waga 30%) - ekstrakcja unikalnych tagów
 - Przedział cenowy (waga 20%) - normalizacja do zakresu [0,1]
 - Słowa kluczowe z opisu (waga 10%) - tokenizacja i TF-IDF
10. System oblicza podobieństwo cosinusowe między każdą parą produktów zgodnie ze wzorem Weighted Cosine Similarity
11. System filtryuje pary z podobieństwem > 20% (próg minimalny)
12. System usuwa stare rekordy z tabeli ProductSimilarity dla type='content_based'
13. System zapisuje nowe podobieństwa do tabeli ProductSimilarity

14. System wyświetla komunikat o sukcesie: „Wygenerowano 1247 podobieństw dla 500 produktów w czasie 58 sekund”
15. Administrator widzi zaktualizowane statystyki: liczba par produktów, średnie podobieństwo, timestamp ostatniego przeliczenia

Warunki końcowe: Macierz podobieństw została wygenerowana i zapisana w bazie danych, rekommendacje CBF są aktualne

Scenariusz 16: Debugowanie algorytmu Content-Based Filtering

Aktor: Administrator

Warunki początkowe: Administrator jest zalogowany, macierz podobieństw została wygenerowana

Przebieg scenariusza głównego:

1. Administrator otwiera panel administracyjny
2. Administrator kliką sekcję „Debug”
3. Administrator wybiera zakładkę „Content-Based Debug”
4. System wyświetla panel debugowania CBF zawierający:
 - Wzór matematyczny Weighted Cosine Similarity z opisem wag cech
 - Statystyki globalne: liczba produktów w katalogu, liczba wygenerowanych par, średnie podobieństwo, czas ostatniego przeliczenia
 - Histogram rozkładu podobieństw (przedziały: 20-40%, 40-60%, 60-80%, 80-100%)
5. Administrator wprowadza ID produktu w pole „Product ID for analysis”
6. Administrator kliką „Analyze Product”
7. System wywołuje endpoint GET `/api/admin/content-based/debug/?product_id={id}`
8. System pobiera wybrany produkt oraz jego Top 10 najbardziej podobnych produktów
9. System wyświetla szczegółową analizę dla wybranego produktu:
 - Podstawowe dane: nazwa, kategorie, tagi, cena
 - Ekstrahowane cechy: wektor kategorii, lista tagów, znormalizowana cena, słowa kluczowe
 - Tabelę Top 10 podobnych produktów z kolumnami: ID, nazwa, similarity_score, wspólne kategorie, wspólne tagi
10. Administrator analizuje wyniki i weryfikuje poprawność podobieństw
11. Administrator może wyeksportować dane do CSV klikając „Export to CSV”

Warunki końcowe: Administrator zweryfikował poprawność działania algorytmu CBF dla wybranego produktu

Scenariusz 17: Przeglądanie rekomendacji Fuzzy Logic w panelu klienta

Aktor: Klient (użytkownik zalogowany)

Warunki początkowe: Użytkownik jest zalogowany, posiada historię zakupów

Przebieg scenariusza głównego:

1. Użytkownik loguje się do systemu
2. Użytkownik otwiera panel klienta
3. Użytkownik kliką zakładkę „Fuzzy Logic Recommendations”
4. System wywołuje endpoint GET /api/fuzzy-logic-recommendations/?limit=10
5. Backend wywołuje FuzzyLogicAPI z parametrem user_id (z tokenu JWT)
6. System inicjalizuje silnik rozmyty FuzzyEngine.initialize_fuzzy_system(user_id)
7. System buduje profil użytkownika FuzzyUserProfile:
 - Oblicza parametr price_sensitivity na podstawie średniej ceny zakupionych produktów
 - Ekstrahuje preferowane kategorie z historii zakupów (top 3 kategorie)
8. System pobiera wszystkie produkty z bazy danych z metrykami: cena, średni rating, liczba zamówień
9. Dla każdego produktu system wykonuje wnioskowanie rozmyte:
 - Fuzzyfikacja - oblicza przynależność ceny, jakości i popularności do zbiorów rozmytych (cheap/medium/expensive, low/medium/high)
 - Aplikacja 6 reguł IF-THEN typu Mamdani (R1: preferred category match, R2: quality-price balance, R3: price sensitive match, R4: premium match, R5: popular high quality, R6: budget friendly)
 - Agregacja wyników reguł z wagami (R1: 0.9, R2: 0.85, R3: 0.6, R4: 0.75, R5: 0.8, R6: 0.7)
 - Defuzzyfikacja - oblicza końcowy fuzzy_score metodą średniej ważonej
10. System sortuje produkty malejąco według fuzzy_score
11. System zwraca JSON z Top 10 rekomendacji zawierający: product_id, name, price, fuzzy_score, activated_rules
12. Frontend wyświetla trzy zakładki:
 - „Fuzzy Recommendations lista Top 10 produktów z fuzzy_score i aktywowanymi regułami

- „User Profile wyświetla price_sensitivity (np. 60% - moderate) oraz preferowane kategorie
 - „Fuzzy Rules opis 6 reguł IF-THEN z wyjaśnieniem logiki
- Użytkownik przegląda rekomendacje dopasowane do jego profilu cenowego
 - Użytkownik kliką przycisk „View Rule Activations” przy wybranym produkcie
 - System wyświetla szczegóły aktywacji reguł: które reguły zostały aktywowane, z jaką siłą (α_i), jaki był ich wkład w końcowy wynik

Warunki końcowe: Użytkownik widzi spersonalizowane rekomendacje dopasowane do jego wrażliwości cenowej oraz preferowanych kategorii z pełną przejrzystością procesu decyzyjnego

Scenariusz 18: Wyszukiwanie tolerujące błędy (Fuzzy Search)

Aktor: Klient lub Gość

Warunki początkowe: Użytkownik znajduje się na stronie głównej

Przebieg scenariusza głównego:

- Użytkownik otwiera pasek wyszukiwania
- Użytkownik przełącza opcję wyszukiwania na „Fuzzy Search”
- System wyświetla suwak „Fuzzy Threshold”(domyślnie 0.5 = 50%)
- Użytkownik wpisuje frazę z literówką: „loptap”(zamiast „laptop”)
- Użytkownik ustawia próg podobieństwa na 0.3 (30%)
- Użytkownik kliką przycisk „Search”
- System wywołuje endpoint GET /api/search/fuzzy/?query=loptap&threshold=0.3
- Backend iteruje po wszystkich produktach w katalogu
- Dla każdego produktu system oblicza odległość Levenshteina między zapytaniem a nazwą produktu:
 - Algorytm rekurencyjny oblicza minimalną liczbę operacji edycji (wstawienie, usunięcie, zamiana znaku)
 - System normalizuje odległość do zakresu [0,1] dzieląc przez maksymalną długość
 - Oblicza fuzzy_match_score = 1 - normalized_distance
- System filtryuje produkty z fuzzy_match_score ≥ 0.3 (próg użytkownika)
- System sortuje wyniki malejąco według fuzzy_match_score
- Backend zwraca JSON z produktami: product_id, name, price, fuzzy_match_score

13. Frontend wyświetla wyniki wyszukiwania:
 - Laptop Dell XPS 15 - 86% match (zawiera „Laptop”)
 - Laptop HP Pavilion - 86% match (zawiera „Laptop”)
 - Desktop Hub USB-C - 45% match (częściowe dopasowanie)
14. Użytkownik widzi produkty mimo błędu w zapytaniu
15. Użytkownik klikna na wybrany produkt

Warunki końcowe: Użytkownik znalazł poszukiwane produkty mimo literówki dzięki algorytmowi Levenshteina

Scenariusz 19: Debugowanie algorytmu Fuzzy Logic

Aktor: Administrator

Warunki początkowe: Administrator jest zalogowany, system posiada użytkowników z historią zakupów

Przebieg scenariusza głównego:

1. Administrator otwiera panel administracyjny
2. Administrator klikna sekcję „Debug”
3. Administrator wybiera zakładkę „Fuzzy Logic Debug”
4. System wyświetla widok ogólny panelu debugowania zawierający:
 - Szczegóły algorytmu: metoda Mamdani Fuzzy Inference, liczba reguł (6), T-norma (min), T-conorma (max)
 - Definicje funkcji przynależności dla price (cheap: 0-500 PLN, medium: 300-1500 PLN, expensive: 1000+ PLN)
 - Definicje funkcji przynależności dla quality (low: 0-2.5, medium: 2.0-4.0, high: 3.5-5.0)
 - Definicje funkcji przynależności dla popularity (low: 0-10 zamówień, medium: 5-50, high: 30+ zamówień)
 - Listę profili użytkowników z parametrem price_sensitivity
5. Administrator wprowadza ID produktu w pole „Product ID for detailed analysis”
6. Administrator klikna „Analyze Product”
7. System wywołuje endpoint GET /api/admin/fuzzy-debug/?product_id={id}
8. System pobiera wybrany produkt oraz wykonuje szczegółową ewaluację rozmytą
9. System wyświetla widok szczegółowy dla produktu:

- Dane produktu: nazwa, cena, średni rating, liczba zamówień
- Wartości fuzzyfikacji:
 - Price: cheap=0.3, medium=0.7, expensive=0.0
 - Quality: low=0.0, medium=0.2, high=0.8
 - Popularity: low=0.0, medium=0.6, high=0.4
- Aktywacja wszystkich 6 reguł z siłą aktywacji α_i :
 - R1 (Preferred Category Match): $\alpha_1 = 0.85$, waga = 0.9, wkład = 0.765
 - R2 (Quality-Price Balance): $\alpha_2 = 0.7$, waga = 0.85, wkład = 0.595
 - R3 (Price Sensitive Match): $\alpha_3 = 0.3$, waga = 0.6, wkład = 0.18
 - R4 (Premium Match): $\alpha_4 = 0.0$, waga = 0.75, wkład = 0.0
 - R5 (Popular High Quality): $\alpha_5 = 0.6$, waga = 0.8, wkład = 0.48
 - R6 (Budget Friendly): $\alpha_6 = 0.2$, waga = 0.7, wkład = 0.14
- Agregacja: suma wkładów = 2.16, fuzzy_score = 2.16 / 4.6 = 0.47 (47%)

10. Administrator analizuje które reguły dominują dla danego produktu

11. Administrator może dostroić wagę reguły klikając „Edit Rule Weights”

12. System zapisuje nowe wagę w konfiguracji

Warunki końcowe: Administrator zweryfikował proces wnioskowania rozmytego i zoptymalizował wagę reguł

Scenariusz 20: Przeglądanie rekomendacji probabilistycznych w panelu klienta

Aktor: Klient (użytkownik zalogowany)

Warunki początkowe: Użytkownik jest zalogowany, posiada historię zakupów, modele probabilistyczne zostały wytrenowane

Przebieg scenariusza głównego:

1. Użytkownik loguje się do systemu
2. Użytkownik otwiera panel klienta
3. Użytkownik kliką zakładkę „Probabilistic Recommendations”
4. System wywołuje endpoint GET `/api/probabilistic-recommendations/?user_id={id}`
5. Backend wywołuje ProbabilisticAPI z parametrem `user_id`
6. System pobiera historię zamówień użytkownika z bazy danych wywołując `get_user_orders(user_id)`

7. System ekstrahuje sekwencję kategorii produktów z zamówień uporządkowanych chronologicznie
8. System wywołuje `MarkovChain.predict_next_products(order_sequence)`:
 - Identyfikuje ostatnią zakupioną kategorię (np. „Laptops”)
 - Odczytuje macierz przejść dla kategorii „Laptops”
 - Pobiera Top 3 kategorie z najwyższym prawdopodobieństwem przejścia (np. Akcesoria komputerowe: 0.45, Peryferia: 0.30, Torby: 0.15)
 - Dla każdej kategorii pobiera Top produkty
9. System wywołuje `NaiveBayes.predict_purchase_probability(user_profile)`:
 - Ekstrahuje 5 cech użytkownika: liczba zamówień, średnia wartość, dni od ostatniego zakupu, ulubiona kategoria, częstotliwość
 - Stosuje twierdzenie Bayesa dla klasyfikacji binarnej (kupi/nie kupi)
 - Oblicza prawdopodobieństwo zakupu w najbliższym okresie
10. System agreguje wyniki: 60% waga dla Markov, 40% waga dla Naive Bayes
11. Backend zwraca JSON z Top 10 rekomendacji zawierający: `product_id, name, price, markov_probability, bayes_probability, combined_score`
12. Frontend wyświetla trzy zakładki:
 - „Probabilistic Recommendations” lista Top 10 produktów z prawdopodobieństwami
 - „Markov Chain Visualization” graf przejść między kategoriami z prawdopodobieństwami
 - „Purchase Probability Analysis” wykres prawdopodobieństwa zakupu oraz analiza cech użytkownika
13. Użytkownik przegląda rekomendacje oparte na sekwencjach zakupowych
14. Użytkownik kliką zakładkę „Markov Chain Visualization”
15. System wyświetla interaktywny graf pokazujący możliwe przejścia z obecnej kategorii do kolejnych
16. Użytkownik kliką zakładkę „Purchase Probability Analysis”
17. System wyświetla:
 - Prawdopodobieństwo zakupu: 73% (high probability)
 - Breakdown cech: liczba zamówień: 12 (pozytywny wpływ +0.15), średnia wartość: 450 PLN (pozytywny +0.10), dni od ostatniego: 15 (pozytywny +0.20)
 - Rekomendacja: „Użytkownik jest aktywny, wysokie prawdopodobieństwo konwersji”

Warunki końcowe: Użytkownik widzi rekomendacje przewidujące jego przyszłe zakupy oparte nałańcuchach Markowa i klasyfikatorze Bayesa

Scenariusz 21: Trenowanie modeli probabilistycznych przez administratora

Aktor: Administrator

Warunki początkowe: Administrator jest zalogowany, system posiada historię zamówień

Przebieg scenariusza głównego:

1. Administrator otwiera panel administracyjny
2. Administrator kliką sekcję „Admin Tools”
3. Administrator wybiera zakładkę „Probabilistic Models”
4. System wyświetla panel zarządzania modelami probabilistycznymi
5. Administrator widzi status modeli:
 - Markov Chain: ostatni trening 2024-01-15, liczba stanów: 48 kategorii, wygładzanie Laplace'a: $\alpha = 1.0$
 - Naive Bayes: ostatni trening 2024-01-15, liczba próbek treningowych: 200 zamówień, accuracy: 78%
6. Administrator kliką przycisk „Train Markov Chain Model”
7. System wywołuje endpoint POST /api/admin/probabilistic/train-markov
8. Backend uruchamia `MarkovChainEngine.train()`:
 - Pobiera wszystkie zamówienia z bazy danych uporządkowane chronologicznie per użytkownik
 - Ekstrahuje sekwencje kategorii dla każdego użytkownika
 - Buduje macierz przejść 48x48 (48 kategorii produktowych)
 - Oblicza prawdopodobieństwa przejść: $P(s_j|s_i) = \frac{\text{count}(s_i \rightarrow s_j) + \alpha}{\sum_k \text{count}(s_i \rightarrow s_k) + \alpha \cdot N}$
 - Stosuje wygładzanie Laplace'a ($\alpha = 1.0$) zapobiegające zerowemu prawdopodobieństwu
 - Zapisuje macierz w cache Django z timeout 24h
9. System wyświetla komunikat: „Markov Chain trained successfully. 48 states, 2304 transitions, training time: 3.2s”
10. Administrator kliką przycisk „Train Naive Bayes Model”
11. System wywołuje endpoint POST /api/admin/probabilistic/train-bayes
12. Backend uruchamia `NaiveBayesEngine.train()`:
 - Pobiera wszystkich użytkowników z zamówieniami

- Dla każdego użytkownika ekstrahuje 5 cech: liczba zamówień, średnia wartość, dni od ostatniego, ulubiona kategoria, częstotliwość
 - Tworzy etykiety binarne (aktywny/nieaktywny) na podstawie heurystyki (zakup w ostatnich 30 dniach)
 - Oblicza prawdopodobieństwa warunkowe dla każdej cechy: $P(feature|class)$
 - Oblicza prawdopodobieństwa a priori: $P(active)$, $P(inactive)$
 - Waliduje model na zbiorze testowym (80%/20% split)
 - Zapisuje model w tabeli cache
13. System wyświetla komunikat: „Naive Bayes trained successfully. Training samples: 200, Test accuracy: 78%, training time: 1.8s”
14. Administrator widzi zaktualizowane timestampy i metryki

Warunki końcowe: Modele probabilistyczne (Markov Chain i Naive Bayes) zostały wytrenowane na aktualnych danych, rekomendacje są aktualne

Scenariusz 22: Debugowanie modeli probabilistycznych

Aktor: Administrator

Warunki początkowe: Administrator jest zalogowany, modele zostały wytrenowane

Przebieg scenariusza głównego - Markov Chain:

1. Administrator otwiera panel administracyjny
2. Administrator kliką sekcję „Debug”
3. Administrator wybiera zakładkę „Markov Chain Debug”
4. System wyświetla panel debugowania zawierający:
 - Wzór matematyczny macierzy przejść z wygładzaniem Laplace'a
 - Statystyki: liczba stanów (48 kategorii), łączna liczba przejść, wygładzanie $\alpha = 1.0$, timestamp ostatniego treningu
 - Wizualizację macierzy przejść jako heatmap 48x48
5. Administrator wybiera kategorię źródłową z listy rozwijanej (np. „Laptopy”)
6. System wyświetla Top 10 kategorii docelowych z najwyższymi prawdopodobieństwami przejścia:
 - Akcesoria komputerowe: 0.45 (45%)
 - Peryferia: 0.30 (30%)
 - Torby i plecaki: 0.15 (15%)

- Oprogramowanie: 0.05 (5%)
- Inne kategorie: <0.05 (łącznie 5%)

- Administrator kliką „Show Transition Examples”
- System pobiera przykładowe rzeczywiste sekwencje zamówień użytkowników, które wygenerowały te przejścia
- Administrator weryfikuje sensowność przejść
- Administrator przełącza zakładkę na „Naive Bayes Debug”
- System wyświetla panel Naive Bayes zawierający:
 - Wzór twierdzenia Bayesa
 - Statystyki: liczba próbek treningowych, accuracy, precision, recall, F1-score
 - Tabelę prawdopodobieństw warunkowych $P(feature|class)$ dla każdej z 5 cech
 - Prawdopodobieństwa a priori: $P(active) = 0.65$, $P(inactive) = 0.35$
- Administrator wprowadza ID użytkownika w pole „User ID for prediction”
- System pobiera profil użytkownika i wykonuje predykcję krok po kroku:
 - Ekstrahuje cechy użytkownika
 - Pokazuje obliczenia $P(active|features)$ z rozpisaniem każdego czynnika
 - Wyświetla końcowe prawdopodobieństwo oraz klasyfikację (active/inactive)
- Administrator weryfikuje poprawność predykcji

Warunki końcowe: Administrator zweryfikował poprawność działania modeli probabilistycznych (Markov Chain i Naive Bayes)