

Propozycje tematów pracy magisterskiej

Rozszerzenie pracy inżynierskiej:

System rekomendacji produktów oparty na metodach hybrydowych

Niniejszy dokument zawiera zestawienie ośmiu propozycji tematów pracy magisterskiej, stanowiących rozszerzenie wcześniejszej pracy inżynierskiej poświęconej hybrydowemu systemowi rekomendacji produktów. Praca inżynierska zaowocowała w pełni działającym systemem integrującym dziewięć metod generowania rekomendacji, opartych zarówno na danych jawnych (oceny, treści opinii) jak i ukrytych (interakcje użytkownika, historia zakupów). Praca magisterska ma rozszerzyć ten dorobek o warstwę badawczo-eksperymentalną.

Dokument otwiera krótki przegląd zaimplementowanych metod oraz stanowiska promotora wyrażonego w korespondencji. Każdy kolejny rozdział poświęcony jest jednemu tematowi i obejmuje sześć stałych sekcji: opis tematu, zakres prac implementacyjnych, stack technologiczny, ocenę innowacyjności na tle literatury, plan badań eksperymentalnych wraz z hipotezami oraz dobór najistotniejszej literatury. Spośród ośmiu tematów siedem stanowi propozycje autorskie, jeden zaś zaproponowany został przez promotora. Dokument zamyka rekomendacja końcowa wraz z trzema możliwymi konfiguracjami tematów oraz lista pytań do dalszego przedyskutowania na seminarium.

Kontekst i punkt wyjścia

Praca inżynierska zrealizowana wspólnie z Piotrem Smołą zaowocowała hybrydowym systemem rekomendacji produktów zaimplementowanym w architekturze Django wraz z Django REST Framework. System integruje dziewięć niezależnych metod generowania rekomendacji, operujących na różnorodnych typach danych — od deklaratywnych ocen produktów po obserwowalne wzorce zachowań użytkowników. Każda z metod została zaimplementowana w sposób umożliwiający niezależne uruchomienie i diagnostykę, co stanowi solidną bazę do dalszych prac badawczych.

Zaimplementowane metody rekomendacji

Lp.	Metoda	Charakter danych
1	Filtracja oparta na zawartości (TF-IDF, podobieństwo kosinusowe), atrybuty produktu	jawne
2	Filtracja kolaboratywna (Adjusted Cosine Similarity)	ukryte, historia transakcji
3	Wnioskowanie rozmyte typu Mamdani (logika rozmyta typu 1)	mieszane
4	Wyszukiwanie rozmyte (odległość Levenshteina)	tekst, zapytania
5	Analiza sentymentu opinii (metoda leksykonowa)	tekst opinii
6	Łańcuchy Markowa (przejścia między produktami)	sekwencyjne
7	Klasyfikator naiwny Bayesa (predykcja zakupu)	mieszane
8	Reguły asocjacyjne (algorytm Apriori)	transakcje
9	Analiza sezonowości (komponent temporalny)	czasowe

Stanowisko promotora — kluczowe wnioski z korespondencji

Promotor zaakceptował generalny kierunek myślenia. W jego ocenie zestawienie metod łączonych z metodami pojedynczymi stanowi jedną z dobrych ścieżek pracy magisterskiej, a włączenie dużych modeli językowych do badań porównawczych jest wartościowe ze względu na aktualność tematu. Strojenie hiperparametrów wskazane zostało jako element pomocniczy, który powinien towarzyszyć szerszym badaniom, a nie stanowić ich główną oś — w związku z tym nie został on uwzględniony jako odrębny temat w niniejszym zestawieniu. Promotor zaproponował również własny temat: zastosowanie wnioskowania rozmytego typu drugiego (IT2-FLS) z biblioteką pyit2fls, co pozwoliłoby uwzględnić niepewność danych w warstwie podejmowania decyzji rekomendacyjnych.

Spis tematów

1.	Kombinacja metod rekomendacji a metody pojedyncze — analiza synergii	autorski
2.	Pre-trenowane modele LLM a metody klasyczne w jakości rekomendacji	autorski

3.	Sieć neuronowa jako meta-learner łączący dziewięć metod rekomendacji	<i>autorski</i>
4.	Segmentacja użytkowników i dopasowane konfiguracje metod	<i>autorski</i>
5.	Dane jawne a dane ukryte — porównawcza jakość rekomendacji	<i>autorski</i>
6.	Skalowalność metod i identyfikacja wąskich gardeł	<i>autorski</i>
7.	Wnioskowanie przedziałowe (IT2-FLS) z biblioteką pyit2fls	<i>promotor</i>
8.	Odporność systemu rekomendacji na ataki shilling i fałszywe opinie	<i>autorski</i>

Kombinacja metod rekomendacji a metody pojedyncze — analiza synergii i interferencji

Opis tematu

Centralny temat zaakceptowany przez promotora jako jedna z głównych ścieżek pracy. Polega na systematycznym porównaniu jakości rekomendacji generowanych przez każdą z dziewięciu zaimplementowanych metod działających w izolacji oraz przez ich wszystkie sensowne kombinacje — od dwuelementowych po dziewięcioelementową. Badanie ma odpowiedzieć na pytania: które pary lub trójki metod wzajemnie się uzupełniają (efekt synergii), a które konkurują, dając wynik gorszy niż każda z nich osobno (efekt interferencji)? Czy istnieje optymalny rozmiar zespołu metod, powyżej którego dodawanie kolejnych nie poprawia jakości lub wręcz ją obniża? Praca magisterska ma odpowiedzieć na te pytania ilościowo, w oparciu o powtarzalny eksperyment przeprowadzony na ujednoliconym zbiorze danych.

Zakres prac implementacyjnych

W obecnej bazie kodu istnieje dziewięć osobnych modułów generujących rekomendacje. Ich aktualne sygnatury wyjściowe nie są ujednolicone — każda metoda zwraca dane w nieco innym formacie. Pierwszym krokiem prac magisterskich będzie zatem refaktoryzacja polegająca na wprowadzeniu wspólnej klasy bazowej oraz ujednoliconego formatu wyjściowego, dzięki czemu wszystkie metody staną się wymienne z perspektywy warstwy nadrzędnej. Następnie powstanie nowy moduł odpowiedzialny za orkiestrację łączenia metod, oferujący kilka strategii fuzji rankingów: kombinację liniową, ważone głosowanie Borda, agregację rankingów oraz strategię przełączającą. Równolegle utworzony zostanie moduł oceny offline implementujący standardowe metryki jakościowe systemów rekomendacji (Precision@K, Recall@K, NDCG@K, MAP, pokrycie katalogu, różnorodność rankingu) wraz z reprodukowalną procedurą podziału danych na zbiór treningowy i testowy z zachowaniem porządku temporalnego.

Stack technologiczny

Backend	Django wraz z Django REST Framework (środowisko bazowe)
Numeryka	NumPy, SciPy, scikit-learn
Eksperymenty	Jupyter Notebook, pandas, matplotlib, seaborn
Orkiestracja zadań	Celery wraz z brokerem Redis dla równoległego uruchamiania kombinacji
Tracking eksperymentów	MLflow (wersjonowanie konfiguracji i wyników)
Analiza statystyczna	scipy.stats — testy nieparametryczne (Wilcoxon, Friedman, Nemenyi)

Innowacyjność

Większość prac w obszarze hybrydowych systemów rekomendacji bada dwie lub trzy metody, najczęściej kombinację filtracji opartej na zawartości i filtracji kolaboratywnej. Kompleksowa analiza wszystkich kombinacji dziewięciu metod wraz z kilkoma strategiami fuzji jest w literaturze rzadkością. Wkład pracy obejmuje: empiryczną mapę synergii i interferencji metod rekomendacji, zaproponowanie metryki kompromisu między różnorodnością a jakością dla zespołów metod, a także zbudowanie reprodukowalnego benchmarku na własnym zbiorze danych e-commerce, który może być wykorzystany w dalszych pracach badawczych.

Aspekt badawczy i eksperymentalny

Hipoteza H1: Kombinacje od trzech do pięciu metod osiągają lepsze wyniki niż każda metoda pojedynczo oraz niż kombinacja wszystkich dziewięciu metod (efekt nadmiarowości zespołu). Hipoteza H2: Metody operujące na różnych typach danych (jawne, ukryte, sekwencyjne) wykazują większą synergię niż metody pokrewne. Hipoteza H3: Strategia fuzji ma istotny wpływ na ranking — różnice między kombinacją liniową, głosowaniem Borda i agregacją rankingów nie są statystycznie istotne.

Plan eksperymentu:

Pierwszym krokiem jest rozszerzenie istniejącego seedera danych do skali około pięciuset użytkowników, dwóch tysięcy produktów i dwudziestu tysięcy interakcji, co pozwoli na wiarygodną ocenę statystyczną. Następnie zbiór dzielony jest w proporcji osiemdziesiąt do dwudziestu z zachowaniem temporalności (najnowsze interakcje stanowią zbiór testowy). Uruchomienie wszystkich kombinacji niepustych (pięćset trzy podzbiory dwu- do dziesięcio-elementowych) razy cztery strategie fuzji razy pięciokrotna walidacja krzyżowa daje około dziesięciu tysięcy eksperymentów. Dla każdego z nich obliczane są metryki Precision@10, NDCG@10, pokrycie katalogu i różnorodność rankingu. Następuje analiza statystyczna testami nieparametrycznymi (Friedman z post-hoc Nemenyi) oraz wizualizacja w postaci heatmapy synergii — macierzy dziewięć na dziewięć przedstawiającej średni zysk jakościowy dla każdej pary metod.

Literatura

- Burke, R. (2002). Hybrid Recommender Systems: Survey and Experiments. *User Modeling and User-Adapted Interaction*, 12(4), 331–370.
- Çano, E. & Morisio, M. (2017). Hybrid recommender systems: A systematic literature review. *Intelligent Data Analysis*, 21(6), 1487–1524.
- Ricci, F., Rokach, L. & Shapira, B. (red., 2022). *Recommender Systems Handbook*, wyd. 3. Springer.
- Sarwar, B., Karypis, G., Konstan, J. & Riedl, J. (2001). Item-based collaborative filtering recommendation algorithms. WWW '01.
- Da'u, A. & Salim, N. (2025). Recommendation system based on deep learning methods: a systematic review and new directions. *Artificial Intelligence Review*, 58.

Pre-trenowane modele LLM a metody klasyczne w jakości rekomendacji produktów

Opis tematu

Promotor wskazał ten temat jako szczególnie interesujący ze względu na aktualność problematyki. Badanie polega na porównaniu rekomendacji generowanych przez dziewięć klasycznych metod z pracy inżynierskiej z rekomendacjami uzyskanymi z otwarto-źródłowych dużych modeli językowych. Eksplorowane są trzy paradygmaty wykorzystania LLM w rekomendacjach: bezpośrednie generowanie rekomendacji przez model językowy (prompting zero-shot i few-shot), wykorzystanie modelu do generowania reprezentacji wektorowych opisów produktów wzbogacających filtrację opartą na zawartości, oraz podejście Retrieval-Augmented Generation, w którym model otrzymuje w kontekście powiązane opinie i specyfikacje produktów.

Zakres prac implementacyjnych

Praca obejmuje stworzenie nowego modułu rekomendacji opartego na modelach LLM, działającego równolegle do istniejących modułów. Moduł ten składa się z trzech podstawowych klas odpowiadających trzem badanym paradygmatom. Pierwsza generuje rekomendacje przez bezpośredni prompt zawierający historię zakupów użytkownika i listę dostępnych produktów. Druga oblicza reprezentacje wektorowe opisów produktów oraz treści opinii, indeksuje je w lekkiej bazie wektorowej i odpowiada na zapytania semantyczne. Trzecia stanowi pipeline RAG, w którym najpierw wyszukiwane są podobne produkty, a następnie kontekst wzbogacany jest opiniami i specyfikacjami przed wywołaniem modelu generującego ranking i uzasadnienie. Wszystkie trzy klasy korzystają z modeli otwarto-źródłowych — dzięki temu eksperymenty są w pełni reprodukowalne i nie zależą od polityk komercyjnych dostawców API.

Stack technologiczny

LLM otwarto-źródłowe (uniwersalne)	Llama 4 Scout (109B), Mistral Large (Apache 2.0), Qwen 3.5, GLM-5.1 (MIT), DeepSeek V4 Flash — uruchamiane przez vLLM lub Ollama
LLM otwarto-źródłowe (lokalne)	Mistral Small 4 (24B, Apache 2.0), Gemma 4 (~27B), Phi-4 (14B) — możliwe na pojedynczej karcie GPU
LLM polskojęzyczne	Bielik v3 (7B i 11B, SpeakLeash, Apache 2.0), PLLuM (8B–70B, OPI/HIVE)
Reprezentacje wektorowe	sentence-transformers (paraphrase-multilingual-mpnet-base-v2), modele BGE i E5 multilingual
Baza wektorowa	Qdrant lub ChromaDB w trybie lokalnym
Framework RAG	LangChain lub LlamaIndex

Inferencja	vLLM, Ollama, Hugging Face Transformers
Ewaluacja	RAGAS (faithfulness, answer relevance), klasyczne metryki rekomendacji

Innowacyjność

Wkład pracy obejmuje cztery elementy. Po pierwsze, systematyczne porównanie modeli LLM różnej skali (od kilkunastu miliardów do prawie czterystu miliardów parametrów aktywnych) z dziewięcioma klasycznymi metodami rekomendacji na tym samym zbiorze danych e-commerce. Po drugie, analiza kompromisu między jakością rekomendacji a kosztem obliczeniowym (opóźnienie odpowiedzi, zapotrzebowanie na pamięć GPU, koszt energii). Po trzecie, ocena współczynnika halucynacji — częstości, z jaką modele językowe rekomendują produkty nieistniejące w katalogu lub przypisują im fałszywe atrybuty. Po czwarte, badanie wpływu języka na jakość rekomendacji, w tym ocena polskich modeli Bielik i PLLuM, których obecność w literaturze rekomendacyjnej jest minimalna.

Aspekt badawczy i eksperymentalny

Hipoteza H1: Modele LLM wykazują przewagę w scenariuszach niskiej dostępności danych (brak historii lub minimalna historia), ale przegrywają z metodami klasycznymi w przypadku użytkowników o bogatej historii zakupów. Hipoteza H2: Hybryda łącząca reprezentacje wektorowe z modelu LLM oraz filtrację kolaboratywną osiąga lepsze wyniki niż każde z tych podejść osobno. Hipoteza H3: Współczynnik halucynacji różni się istotnie między modelami otwarto-źródłowymi i jest skorelowany z rozmiarem modelu. Hipoteza H4: Model Bielik v3 11B operujący na polskich opisach produktów osiąga jakość niegorszą niż wielokrotnie większe modele uniwersalne, przy znacząco niższym koszcie obliczeniowym.

Plan eksperymentu:

Przygotowanie około pięciuset zapytań rekomendacyjnych odpowiadających różnym profilom użytkowników z bazy danych. Generacja rekomendacji dla każdego zapytania przez wybrane modele otwarto-źródłowe (cztery do sześciu modeli reprezentujących różne klasy wielkości i pochodzenia, w tym co najmniej jeden polskojęzyczny). Generacja rekomendacji przez dziewięć metod klasycznych oraz cztery hybrydy łączące LLM z metodami klasycznymi. Pomiar metryk Precision@10, NDCG@10, współczynnika halucynacji, średniego opóźnienia i kosztu zasobowego. Dodatkowo ocena ekspercka wykonana przez pięcioro sędziów na próbie stu zapytań, oceniająca relewancję, nowość i element zaskoczenia (serendipity). Analiza statystyczna testem Friedmana na rankingach metod.

Literatura

- Wu, L. et al. (2024). A Survey on Large Language Models for Recommendation. *arXiv:2305.19860*.
- Geng, S. et al. (2022). Recommendation as Language Processing (RLP): A Unified P5 Framework. *RecSys '22*.
- Hou, Y. et al. (2024). Large Language Models are Zero-Shot Rankers for Recommender Systems. *ECIR '24*.

- Bao, K. et al. (2023). TALLRec: An Effective and Efficient Tuning Framework to Align Large Language Model with Recommendation. *RecSys '23*.
- Lewis, P. et al. (2020). Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks. *NeurIPS*.
- Reimers, N. & Gurevych, I. (2019). Sentence-BERT: Sentence Embeddings using Siamese BERT-Networks. *EMNLP*.
- Ociepa, K. et al. (2026). Advancing Polish Language Modeling through Tokenizer Optimization in the Bielik v3 7B and 11B Series. *arXiv:2604.10799*.
- Trybus, A., Bartnicki, B. & Kinas, R. (2026). Making Bielik LLM Reason (Better): A Field Report. *arXiv:2603.10640*.

Sieć neuronowa jako meta-learner łączący wyniki dziewięciu metod rekomendacji

Opis tematu

Naturalne rozwinięcie tematu kombinacji metod. Zamiast statycznie testować predefiniowane strategie fuzji, stosuje się uczoną sieć neuronową w roli meta-learnera (paradygmat stacking ensemble). Wejściem sieci jest wektor dziewięciu ocen (po jednej z każdej metody) wzbogacony o wektor cech kontekstowych — pora dnia, segment użytkownika, sezon, cena produktu, rozmiar historii zakupów. Wyjściem jest zagregowana ocena lub bezpośrednio prawdopodobieństwo zakupu. Dodatkowy wymiar pracy stanowi analiza wag wyuczonych przez sieć — w architekturze z mechanizmem uwagi (attention) wagi te są interpretowalne i pozwalają odpowiedzieć na pytanie, która metoda dominuje w jakim scenariuszu kontekstowym.

Zakres prac implementacyjnych

Architektura sieci obejmuje warstwę wejściową łączącą dziewięć ocen z metod rekomendacji z cechami kontekstowymi, dwie do trzech warstw ukrytych typu Dense oraz warstwę wyjściową z funkcją sigmoidalną dla klasyfikacji binarnej (zakup / brak zakupu) lub funkcją liniową dla predykcji ocen. Kluczowym elementem architektury jest warstwa attention nad wektorem dziewięciu ocen — wagi tej warstwy są interpretowalne i wskazują, jak istotna jest każda z metod w danym kontekście. Trening sieci opiera się na danych historycznych z modułu zamówień oraz interakcji użytkowników, gdzie etykietą jest fakt rzeczywistego zakupu. Praca obejmuje stworzenie modułu meta-learnera, dodanie polecenia do cyklicznego treningu modelu w ramach Django management commands oraz nowego punktu końcowego API zwracającego rekomendacje wygenerowane przez wytrenowaną sieć.

Stack technologiczny

Deep Learning	PyTorch 2.x oraz PyTorch Lightning
Mechanizm uwagi	torch.nn.MultiheadAttention lub własna implementacja Bahdanau attention
Tracking	MLflow lub Weights & Biases
Interpretowalność	SHAP, Captum (atrybucja cech wejściowych)
Wdrożenie	ONNX Runtime lub TorchScript dla integracji z Django
Modele referencyjne	Linear regression i XGBoost jako proste meta-learnery do porównania

Innowacyjność

Wkład pracy obejmuje trzy elementy. Po pierwsze, kontekstowy stacking (Context-Aware Stacking) — w klasycznym stackingu wagi metod są statyczne i wspólne dla wszystkich predykcji, podczas gdy proponowany meta-learner generuje wagi dynamicznie, dostosowując je do kontekstu konkretnego zapytania. Po drugie, interpretowalna mapa dominacji metod — na podstawie wag warstwy attention możliwe jest sporządzenie wizualizacji pokazującej, która metoda przeważa w danym segmencie użytkowników, porze roku czy klasie produktów. Po trzecie, empiryczne porównanie z prostszymi meta-learnerami (regresja liniowa, XGBoost) pozwala odpowiedzieć na pytanie, kiedy złożoność sieci neuronowej jest opłacalna, a kiedy prostsze modele są wystarczające.

Aspekt badawczy i eksperymentalny

Hipoteza H1: Meta-learner z mechanizmem uwagi przewyższa najlepsze statyczne strategie fuzji o ponad pięć procent w metryce NDCG@10. Hipoteza H2: Wagi attention wykazują systematyczne wzorce zależne od kontekstu — analiza sezonowości dominuje w okresie świątecznym, łańcuchy Markowa przy długich sesjach przeglądania, filtracja oparta na zawartości w segmentach niszowych. Hipoteza H3: Meta-learner neuronowy przewyższa meta-learner XGBoost przy liczbie próbek treningowych powyżej pięciu tysięcy, ale przegrywa przy mniejszych zbiorach — w pracy zostanie wyznaczony empiryczny próg rentowności złożoności.

Plan eksperymentu:

Pierwszym krokiem jest przygotowanie zbioru treningowego — dla każdej historycznej pary użytkownik-produkt obliczane są oceny wszystkich dziewięciu metod oraz cechy kontekstowe, a etykietą jest informacja o rzeczywistym zakupie. Następnie trenowane są trzy warianty meta-learnera: regresja liniowa, XGBoost oraz sieć neuronowa z mechanizmem uwagi. Wszystkie warianty oceniane są na tym samym zbiorze testowym i porównywane z bazowymi wynikami z eksperymentu pierwszego (statyczne strategie fuzji). Następnie przeprowadzana jest analiza wag attention — generowane są heatmapy metoda-segment użytkownika oraz metoda-pora roku. Badanie ablacyjne polega na kolejnym usuwaniu po jednej z dziewięciu metod z wejścia i obserwacji spadku jakości — pozwala to ocenić niezbędność każdej metody. Pomiar opóźnienia inferencji porównuje koszt prostej fuzji z kosztem sieci neuronowej.

Literatura

Wolpert, D. H. (1992). Stacked generalization. *Neural Networks*, 5(2), 241–259.

Vaswani, A. et al. (2017). Attention Is All You Need. *NeurIPS*.

He, X. et al. (2017). Neural Collaborative Filtering. *WWW '17*.

Cheng, H.-T. et al. (2016). Wide & Deep Learning for Recommender Systems. *DLRS '16*.

Lundberg, S. M. & Lee, S.-I. (2017). A Unified Approach to Interpreting Model Predictions (SHAP). *NeurIPS*.

Tahmasebi, F., Meghdadi, M., Ahmadian, S. & Valiollahi, K. (2021). A hybrid recommendation system based on stacking. *Neural Computing and Applications*, 33, 13895–13909.

Segmentacja użytkowników metodami klasteryzacji i dopasowane konfiguracje metod rekomendacji

Opis tematu

Klasyczne systemy rekomendacji traktują wszystkich użytkowników jednakowo — ten sam algorytm dla każdego. Praca proponuje podejście świadome segmentacji: najpierw użytkowników grupuje się metodami klasteryzacji w segmenty zachowaniowe, a następnie dla każdego segmentu dobiera się optymalną kombinację metod rekomendacji. Intuicyjnie: dla użytkowników wrażliwych cenowo dominować będzie analiza sezonowości i reguły asocjacyjne, dla użytkowników skoncentrowanych na konkretnych markach — filtracja oparta na zawartości i analiza sentymentu, a dla użytkowników przypadkowych — strategia rezerwowa oparta na popularności globalnej i filtracji kolaboratywnej. Praca formalizuje i empirycznie weryfikuje to założenie.

Zakres prac implementacyjnych

Pierwszym etapem jest inżynieria cech użytkowników — agregacja wskaźników behawioralnych z istniejących modeli zamówień, interakcji i opinii. Powstaje wektor opisujący każdego użytkownika za pomocą cech takich jak: średnia wartość zamówienia, częstotliwość zakupów, rozkład pory dnia w której użytkownik jest aktywny, różnorodność kategorii (entropia), stosunek liczby wystawianych opinii do liczby zamówień, średni sentyment opinii oraz współczynnik sezonowości zachowania. Drugim etapem jest sama klasteryzacja — po standaryzacji cech i ewentualnej redukcji wymiarów (PCA lub UMAP) stosowane są trzy algorytmy: K-Means z analizą metody łokcia i wskaźnika Silhouette, DBSCAN do wykrywania użytkowników nietypowych oraz Gaussian Mixture Models. Trzecim etapem jest przypisanie każdemu segmentowi optymalnej kombinacji metod rekomendacji (z wykorzystaniem wyników eksperymentu pierwszego). Ostatnim krokiem jest stworzenie modelu segmentu w bazie danych oraz mechanizmu cyklicznej re-segmentacji uruchamianego w tle przez Celery.

Stack technologiczny

Klasteryzacja	scikit-learn (KMeans, DBSCAN, GaussianMixture)
Redukcja wymiarów	scikit-learn PCA, biblioteka umap-learn
Wizualizacja	matplotlib, seaborn, Plotly (rzuty trójwymiarowe klastrów)
Walidacja klastrów	Silhouette Score, Davies-Bouldin Index, Calinski-Harabasz
Pipeline	Django management command oraz Celery dla cyklicznego przeliczania

Innowacyjność

Wkład pracy obejmuje trzy aspekty. Po pierwsze, automatyczne mapowanie segmentów użytkowników na konfiguracje silnika rekomendacji — w literaturze segmentacja jest zazwyczaj deklaratywna (na przykład rozróżnienie nowych i powracających użytkowników), rzadko stosowana systemowo do wyboru metod. Po drugie, analiza stabilności klastrów w czasie — czy użytkownicy migrują między segmentami i jak często należy retrenować model klasteryzacji, aby zachować jego trafność. Po trzecie, porównanie z bazową konfiguracją jednolitą dla wszystkich użytkowników (najlepszą znaną w temacie pierwszym), co pozwoli ilościowo ocenić zysk z segmentacji.

Aspekt badawczy i eksperymentalny

Hipoteza H1: Strategia świadoma segmentacji przewyższa globalnie najlepszą kombinację metod o ponad trzy procent w metryce NDCG@10. Hipoteza H2: Optymalna liczba klastrów dla typowego zbioru e-commerce mieści się w przedziale od czterech do siedmiu, zgodnie z klasyczną segmentacją RFM (Recency, Frequency, Monetary). Hipoteza H3: DBSCAN identyfikuje mniej niż dziesięć procent użytkowników jako odstających, a użytkownicy ci charakteryzują się niższą jakością rekomendacji niezależnie od użytej metody — stanowią naturalnie trudny przypadek dla systemów rekomendacji.

Plan eksperymentu:

Konstrukcja wektorowej reprezentacji wszystkich użytkowników na podstawie rozszerzonego zbioru danych (około pięciuset użytkowników). Wykonanie klasteryzacji trzema algorytmami z różnymi parametrami: K-Means dla liczby klastrów od dwóch do dziesięciu, DBSCAN z różnymi wartościami parametru epsilon, GMM z optymalizacją kryterium informacyjnego BIC. Wizualizacja klastrów w przestrzeni dwuwymiarowej (PCA i t-SNE) wraz z interpretacją semantyczną każdego segmentu. Dla każdego klastra niezależnie przeprowadzane jest wyszukiwanie po przestrzeni kombinacji metod (z wykorzystaniem wyników eksperymentu pierwszego) i wybór najlepszej. Test offline na zbiorze testowym porównuje strategię świadomą segmentacji z konfiguracją globalną i z losowym przypisaniem. Test stabilności polega na ponownej segmentacji po wstrzyknięciu syntetycznych nowych interakcji, symulujących upływ czasu, i pomiarze odsetka użytkowników, którzy zmieniają segment.

Literatura

- Hennig-Thurau, T., Marchand, A. & Marx, P. (2012). Can Automated Group Recommender Systems Help Consumers Make Better Choices? *Journal of Marketing*, 76(5), 89–109.
- Macqueen, J. (1967). Some methods for classification and analysis of multivariate observations. *Berkeley Symposium on Mathematical Statistics*.
- Ester, M., Kriegel, H.-P., Sander, J. & Xu, X. (1996). A density-based algorithm for discovering clusters in large spatial databases (DBSCAN). *KDD*.
- Christakopoulou, K. & Banerjee, A. (2018). Local Latent Space Models for Top-N Recommendation. *KDD '18*.
- McInnes, L., Healy, J. & Melville, J. (2018). UMAP: Uniform Manifold Approximation and Projection for Dimension Reduction. *arXiv:1802.03426*.
- Aggarwal, C. C. (2016). *Recommender Systems: The Textbook*, rozdział 13: Advanced Topics in Recommender Systems. Springer.

Dane jawne a dane ukryte — porównawcza jakość rekomendacji

Opis tematu

Klasyczne pytanie systemów rekomendacji: czy lepiej polegać na jawnych deklaracjach użytkownika (oceny w skali, treści opinii) czy na obserwowalnych zachowaniach (kliknięcia, czas oglądania produktu, dodanie do koszyka)? Dane jawne są bogate semantycznie, ale rzadkie i mogą być niezgodne z faktycznymi preferencjami — wystawiana ocena bywa kompromisem społecznym, a opinia spóźniona względem decyzji zakupowej. Dane ukryte są obfite, nie podlegają cenzurze społecznej, ale są wieloznaczne — kliknięcie nie zawsze oznacza zainteresowanie. Obecny model danych projektu zawiera zarówno deklaratywne oceny i opinie, jak i zarejestrowane interakcje pięciu typów (przeoglądnięcie, kliknięcie, dodanie do koszyka, zakup, dodanie do ulubionych) — co czyni go dogodnym poligonem do takiego porównania.

Zakres prac implementacyjnych

Implementacja wymaga rozdzielenia każdej z dziewięciu metod na trzy warianty: oparty wyłącznie na danych jawnych, oparty wyłącznie na danych ukrytych oraz hybrydowy. Dla filtracji kolaboratywnej wariant jawny korzysta z ocen, wariant ukryty — z ważonych wag interakcji (zgodnie z propozycją Hu, Korena i Volinsky'ego z 2008 roku). Dla analizy sentymentu wariant jawny korzysta z treści opinii, wariant ukryty wykorzystuje czas spędzony na stronie produktu jako proxy zainteresowania. Dla klasyfikatora Bayesa wariant jawny opiera się na rozkładzie ocen, wariant ukryty — na sekwencji kliknięć. Warianty hybrydowe testowane są z różnymi wagami źródeł — od dziesięciu do dziewięćdziesięciu procent dla danych jawnych. Powstaje moduł benchmarkowy umożliwiający uruchomienie wszystkich wariantów i porównanie ich w jednolitym środowisku.

Stack technologiczny

Backend	Django (środowisko bazowe) wraz z nowym modułem benchmarkowym
Algorytmy implicit feedback	scikit-learn oraz biblioteka 'implicit' (Hu, Koren, Volinsky)
Logowanie czasu	rozszerzenie modelu interakcji o pole z czasem trwania
Frontend (opcjonalnie)	rozszerzenie istniejącego frontu o tracking czasu spędzonego
Analiza statystyczna	pandas, scipy.stats — sparowane testy Wilcoxona

Innowacyjność

Wkład pracy obejmuje trzy aspekty. Po pierwsze, eksperyment sparowany — dla tych samych użytkowników i w tych samych warunkach kontrolnych porównywanych jest dziewięć par wariantów (dane jawne kontra dane ukryte). Pozwala to na rygorystyczną analizę statystyczną przy minimalnej wariancji niezwiązanej z badanym czynnikiem. Po drugie, analiza segmentowa — czy dane jawne są lepsze dla użytkowników wyrażających się aktywnie (często wystawiających opinie) i gorsze dla użytkowników milczących? Po trzecie, krzywa gęstość-jakość — wykres pokazujący, jak jakość rekomendacji rośnie wraz z liczbą dostępnych sygnałów osobno dla danych jawnych i ukrytych. Ten wynik ma wyraźny wymiar biznesowy: pozwala odpowiedzieć na pytanie, czy bardziej opłaca się inwestować w mechanizmy zachęcające do wystawiania ocen, czy w lepszy tracking interakcji.

Aspekt badawczy i eksperymentalny

Hipoteza H1: Dla użytkowników z mniej niż pięcioma ocenami metody oparte na danych ukrytych dają wyższą metrykę NDCG@10 niż metody oparte na danych jawnych. Dla użytkowników z ponad dwudziestoma ocenami przewaga przesuwana się w stronę danych jawnych. Hipoteza H2: Hybryda łącząca dane jawne i ukryte z odpowiednimi wagami przewyższa obydwa warianty czyste. Hipoteza H3: Niektóre metody (na przykład analiza sentymentu, klasyfikator Bayesa) wykazują silną zależność od typu sygnału, podczas gdy inne (łańcuchy Markowa) są względnie indyferentne — pozwala to wyodrębnić metody wszytkostronne od metod specjalistycznych.

Plan eksperymentu:

Pierwszym krokiem jest rozszerzenie istniejącego seedera danych o realistyczne sygnały implicit z rozkładem wzorowanym na publicznych zbiorach danych (między innymi MovieLens i Amazon Reviews). Implementacja dziewięciu par wariantów (jawny i ukryty) oraz dziewięciu wariantów hybrydowych z różnymi proporcjami sygnałów. Podział danych z zachowaniem temporalności. Pomiar metryk Precision@10, NDCG@10 oraz pokrycia katalogu osobno dla pięciu segmentów użytkowników o różnej gęstości interakcji. Generacja krzywej jakość-liczba sygnałów dla każdego wariantu. Końcowa analiza biznesowa: koszt pozyskania jednej oceny w stosunku do kosztu pozyskania dziesięciu obserwowanych interakcji i odpowiednia rekomendacja strategiczna.

Literatura

- Hu, Y., Koren, Y. & Volinsky, C. (2008). Collaborative Filtering for Implicit Feedback Datasets. *ICDM*.
- Rendle, S., Freudenthaler, C., Gantner, Z. & Schmidt-Thieme, L. (2009). BPR: Bayesian Personalized Ranking from Implicit Feedback. *UAI*.
- Jawaheer, G., Szomszor, M. & Kostkova, P. (2010). Comparison of implicit and explicit feedback from an online music recommendation service. *HetRec '10*.
- Oard, D. W. & Kim, J. (1998). Implicit feedback for recommender systems. *AAAI Workshop on Recommender Systems*.
- Lerche, L., Jannach, D. & Ludewig, M. (2016). On the Value of Reminders within E-Commerce Recommendations. *UMAP '16*.
- Pan, R. et al. (2008). One-Class Collaborative Filtering. *ICDM*.

Skalowalność metod rekomendacji i identyfikacja wąskich gardeł

Opis tematu

Aspekt inżynierski o silnym charakterze badawczym. Praca inżynierska udowodniła poprawność działania dziewięciu metod, lecz nie odpowiedziała na pytanie, ile użytkowników i produktów obsłużą one bez utraty założonych parametrów wydajnościowych. Praca magisterska systematycznie bada krzywe skalowalności (czas obliczeń w funkcji rozmiaru danych) oraz profil pamięciowy każdej metody. Identyfikuje wąskie gardła — na przykład naiwna implementacja algorytmu Apriori cierpi na złożoność wykładniczą, filtracja kolaboratywna jest wrażliwa na rzadkość macierzy interakcji, a system rozmyty może doświadczać eksplozji liczby reguł. Następnie proponowane są optymalizacje: cache'owanie, indeksowanie bazy danych, zastąpienie Apriori algorytmem FP-Growth, wykorzystanie macierzy rzadkich, częściowe przeliczanie zamiast pełnego.

Zakres prac implementacyjnych

Powstaje moduł benchmarkowy generujący syntetyczne zbiory danych w sześciu skalach: sto, pięćset, tysiąc, pięć tysięcy, dziesięć tysięcy oraz pięćdziesiąt tysięcy użytkowników i analogicznie produktów. Dla każdej z dziewięciu metod mierzony jest czas wygenerowania pełnego zestawu rekomendacji, szczytowe zużycie pamięci oraz opóźnienie pojedynczego zapytania. Profilowanie z wykorzystaniem narzędzi takich jak cProfile i memory_profiler pozwala zidentyfikować punkty krytyczne. Dodatkowym wymiarem jest analiza zapytań SQL generowanych przez Django ORM — z wykorzystaniem polecenia EXPLAIN ANALYZE w PostgreSQL oraz narzędzia django-debug-toolbar. Po zidentyfikowaniu wąskich gardeł implementowane są wybrane optymalizacje, a następnie ponawiany pomiar — co pozwala ilościowo wykazać zysk.

Stack technologiczny

Profilowanie	cProfile, line_profiler, memory_profiler, py-spy
Profilowanie bazy danych	django-debug-toolbar, PostgreSQL EXPLAIN ANALYZE
Macierze rzadkie	scipy.sparse (formaty CSR i COO)
Optymalizacje algorytmiczne	FP-Growth z biblioteki mlxtend, Locality Sensitive Hashing
Wizualizacja	matplotlib (wykresy log-log), Plotly
Benchmarki	pytest-benchmark zintegrowany z pytest

Innowacyjność

Wkład pracy obejmuje trzy aspekty. Po pierwsze, empiryczne krzywe skalowalności dla dziewięciu różnych metod uruchomionych na tym samym sprzęcie i tych samych danych — w literaturze takie porównanie zwykle obejmuje dwie do trzech metod. Po drugie, identyfikacja fundamentalnych ograniczeń każdej metody (na przykład kombinatoryka Apriori, rzadkość macierzy w filtracji kolaboratywnej, eksplozja reguł rozmytych). Po trzecie, kompendium praktycznych optymalizacji wraz z empirycznym pomiarem zysku — stanowi to materiał o wyraźnej wartości zastosowanej dla każdego inżyniera wdrażającego system rekomendacji w środowisku produkcyjnym.

Aspekt badawczy i eksperymentalny

Hipoteza H1: Metody dzielą się na trzy klasy złożoności empirycznej: liniowe ($O(N)$), kwadratowe ($O(N^2)$) oraz wykładnicze. Klasa złożoności pozwala przewidzieć, która metoda przestanie działać w akceptowalnym czasie jako pierwsza. Hipoteza H2: Implementacja wybranych optymalizacji (macierze rzadkie dla filtracji kolaboratywnej, FP-Growth zamiast Apriori, cache'owanie wyników wnioskowania rozmytego) daje przyspieszenie rzędu pięciu do dwudziestu razy bez utraty jakości — różnica w metryce NDCG@10 nie przekracza jednego procenta. Hipoteza H3: Wąskim gardłem nie jest moc obliczeniowa procesora, lecz operacje wejścia-wyjścia związane z dostępem do bazy danych. Z tego wynika, że odpowiednie indeksowanie bazy danych ma większe znaczenie niż optymalizacje algorytmiczne.

Plan eksperymentu:

Generacja sześciu zbiorów danych o rosnącej skali na bazie PostgreSQL z odpowiednimi indeksami. Dla każdej metody na każdej skali wykonywane jest pięć powtórzeń pomiaru, a wartością raportowaną jest mediana. Wykreślenie zależności czasu od rozmiaru danych w skali logarytmicznej i wyznaczenie empirycznego wykładnika złożoności. Profilowanie szczegółowe najwolniejszej metody w celu identyfikacji konkretnych funkcji odpowiedzialnych za większość kosztu. Implementacja trzech wybranych optymalizacji (macierze rzadkie dla CF, FP-Growth zamiast Apriori, batch processing) i porównanie wyników przed i po. Końcowe zestawienie tabelaryczne porównuje empiryczną złożoność z teoretyczną.

Literatura

- Han, J., Pei, J. & Yin, Y. (2000). Mining frequent patterns without candidate generation (FP-Growth). *SIGMOD*.
- Linden, G., Smith, B. & York, J. (2003). Amazon.com recommendations: item-to-item collaborative filtering. *IEEE Internet Computing*, 7(1), 76–80.
- Karypis, G. (2001). Evaluation of Item-Based Top-N Recommendation Algorithms. *CIKM*.
- Indyk, P. & Motwani, R. (1998). Approximate nearest neighbors: towards removing the curse of dimensionality. *STOC*.
- Sarwar, B., Karypis, G., Konstan, J. & Riedl, J. (2002). Recommender Systems for Large-scale E-Commerce: Scalable Neighborhood Formation. *ICIT*.

Wnioskowanie przedziałowe (Interval Type-2 Fuzzy Logic) z biblioteką pyit2fls

Opis tematu

Temat zaproponowany bezpośrednio przez promotora. Stanowi naturalne rozszerzenie istniejącego modułu logiki rozmytej, który implementuje wnioskowanie typu pierwszego — klasyczny system Mamdani. Logika rozmyta typu drugiego, a w szczególności jej praktyczny wariant przedziałowy (IT2-FLS), modeluje niepewność samej funkcji przynależności. O ile system typu pierwszego stwierdza, że stopień przynależności pewnej ceny do zbioru rozmytego „tani” wynosi dokładnie 0,5, o tyle system przedziałowy mówi, że stopień ten mieści się w przedziale od 0,4 do 0,6. Lepiej oddaje to rzeczywistą niepewność danych w zastosowaniach e-commerce — ceny zmieniają się dynamicznie, oceny są subiektywne, a opinie zaszumione. Biblioteka pyit2fls dostarcza w pełni funkcjonalne klasy zbiorów rozmytych typu drugiego (IT2FS), systemów Mamdani i TSK oraz algorytmy defuzyfikacji Karnika-Mendela.

Zakres prac implementacyjnych

Praca obejmuje stworzenie nowego modułu wnioskowania przedziałowego, działającego równolegle do istniejącego modułu typu pierwszego. Etapy są następujące. Po pierwsze, definicja zbiorów rozmytych typu drugiego dla wszystkich pojęć językowych obecnych w systemie (pojęcia ceny: tani, średni, drogi; pojęcia jakości: niska, średnia, wysoka; pojęcia popularności). Każdy zbiór charakteryzowany jest parą funkcji przynależności (górną i dolną), które wyznaczają obszar niepewności (Footprint of Uncertainty, FOU). Po drugie, przepisanie istniejącej bazy reguł rozmytych do postaci typu drugiego z wykorzystaniem klasy IT2Mamdani z biblioteki pyit2fls. Po trzecie, defuzyfikacja algorytmem Karnika-Mendela lub jego wariantem usprawnionym (EKM). Po czwarte, stworzenie panelu diagnostycznego pokazującego wizualnie obszar niepewności, aktywacje reguł górne i dolne oraz przedział wyjściowy. Po piąte, implementacja mechanizmu porównania równoległego — możliwość uruchomienia obu wariantów (typu pierwszego i drugiego) dla tego samego użytkownika i tych samych danych wejściowych.

Stack technologiczny

System rozmyty typu drugiego	biblioteka pyit2fls (instalacja: <code>pip install pyit2fls</code>)
Numeryka	NumPy, SciPy
Wizualizacja FOU	matplotlib — wykresy obszaru niepewności w przestrzeni dwu- i trójwymiarowej
Backend	Django (środowisko bazowe), nowy moduł logiki rozmytej typu drugiego

Innowacyjność

Wkład pracy obejmuje trzy aspekty. Po pierwsze, jedno z pierwszych zastosowań logiki rozmytej typu drugiego w kontekście systemów rekomendacji w polskim środowisku akademickim — większość prac dotyczących IT2-FLS skupia się na sterowaniu, robotyce oraz finansach. Po drugie, empiryczna weryfikacja pytania, czy modelowanie niepewności faktycznie poprawia jakość rekomendacji, czy też jedynie zwiększa koszt obliczeniowy bez wymiernych korzyści. Po trzecie, propozycja nowej metryki — szerokości przedziału ufności rekomendacji — jako miary tego, jak bardzo system jest pewny swojej propozycji. Otwiera to drogę do rankingu świadomego pewności (confidence-aware ranking), w którym produkty z szerokim przedziałem niepewności są deprezjonowane lub oznaczane jako wymagające ostrożności.

Aspekt badawczy i eksperymentalny

Hipoteza H1: System typu drugiego daje wyższą metrykę Precision@10 niż system typu pierwszego dla użytkowników z mniej niż pięcioma ocenami — w warunkach rzadkich danych modelowanie niepewności ma większe znaczenie. Hipoteza H2: Szerokość przedziału ufności obliczonego przez system typu drugiego koreluje istotnie z błędem predykcji — szeroki przedział wskazuje rzeczywistą niepewność systemu, wąski przedział oznacza wysoką pewność. Hipoteza H3: Koszt obliczeniowy systemu typu drugiego (zwłaszcza defuzyfikacji Karnika-Mendela) jest pięć- do dwudziestokrotnie wyższy niż systemu typu pierwszego, ale opłacalny tylko w wybranych scenariuszach (rzadkie dane, użytkownicy nowi).

Plan eksperymentu:

Wykorzystanie istniejącego modułu typu pierwszego jako bazy odniesienia. Implementacja wariantu typu drugiego z obszarem niepewności wyznaczonym jako plus minus dwadzieścia procent szerokości funkcji przynależności typu pierwszego (parametr regulowany). Test na trzech rozłącznych podzbiorach użytkowników: o niskiej, średniej i wysokiej liczbie ocen. Porównanie wariantu typu pierwszego, drugiego oraz hybrydowego — wykorzystującego system typu drugiego dla użytkowników o niskiej liczbie ocen i system typu pierwszego dla pozostałych. Walidacja przedziałów ufności: czy rzeczywiste oceny mieszczą się w obliczonym przedziale w ponad dziewięćdziesięciu pięciu procentach przypadków? Pomiar opóźnienia obliczeń — średni czas wyznaczenia oceny dla pojedynczego produktu w obu wariantach.

Literatura

- Mendel, J. M. (2017). *Uncertain Rule-Based Fuzzy Systems: Introduction and New Directions*, wyd. 2. Springer.
- Karnik, N. N. & Mendel, J. M. (2001). Centroid of a type-2 fuzzy set. *Information Sciences*, 132(1-4), 195–220.
- Wu, D. (2013). Approaches for reducing the computational cost of interval type-2 fuzzy logic systems. *IEEE Transactions on Fuzzy Systems*, 21(1), 80–99.

- Haghrah, A. A. & Ghaemi, S. (2023). PyIT2FLS: A New Python Toolkit for Interval Type 2 Fuzzy Logic Systems. *arXiv:1909.10051*.
- Castillo, O. & Melin, P. (2008). *Type-2 Fuzzy Logic: Theory and Applications*. Springer.
- Mendel, J. M. & John, R. I. (2002). Type-2 fuzzy sets made simple. *IEEE Transactions on Fuzzy Systems*, 10(2), 117–127.
- Zadeh, L. A. (1975). The concept of a linguistic variable and its application to approximate reasoning. *Information Sciences*, 8(3), 199–249.

Odporność systemu rekomendacji na ataki shilling i fałszywe opinie

Opis tematu

Praca o niedocenianym, lecz coraz istotniejszym aspekcie systemów rekomendacji — bezpieczeństwie. Atakujący może wpływać na rankingi, tworząc fałszywe konta i symulując interakcje, co w literaturze opisywane jest jako atak typu shilling (Lam i Riedl, 2004). Może również wstrzykiwać fałszywe opinie pozytywne dla swoich produktów lub negatywne dla produktów konkurencji. Wraz z rosnącą dostępnością generatywnych modeli językowych tworzenie wiarygodnych fałszywych opinii stało się trywialnie proste. Praca obejmuje trzy elementy: implementację generatorów typowych ataków, pomiar podatności każdej z dziewięciu metod rekomendacji na te ataki oraz zaprojektowanie i ocenę mechanizmów wykrywania anomalii w danych behawioralnych i klasyfikatora fałszywych opinii.

Zakres prac implementacyjnych

Pierwszym etapem jest stworzenie modułu generującego typowe rodzaje ataków. Atak losowy polega na wstawieniu losowych ocen dla losowych produktów wraz z ocenami skrajnymi dla produktu-celu. Atak średniej generuje oceny zgodne z rozkładem średnim w kategorii (jest trudniejszy do wykrycia niż losowy). Atak typu bandwagon polega na tym, że atakujący ocenia wysoko produkty popularne, aby upozorować typowego użytkownika, a jednocześnie podbija ocenę produktu-celu. Generator fałszywych opinii korzysta z modelu LLM do tworzenia pseudo-realistycznych tekstów. Drugim etapem jest pomiar wpływu — dla każdej kombinacji typu ataku oraz każdej z dziewięciu metod rekomendacji wyznaczane jest przesunięcie pozycji produktu-celu w rankingu po ataku. Trzecim etapem jest detekcja: klasyfikator wykrywający shilling wykorzystuje algorytm Isolation Forest na zestawie cech behawioralnych (tempo wystawiania ocen, odchylenie od średniej, odstępy czasowe), a klasyfikator fałszywych opinii to dostrojony model językowy.

Stack technologiczny

Backend	Django wraz z nowymi modułami ataków oraz obrony
Wykrywanie anomalii	scikit-learn (IsolationForest, LocalOutlierFactor, OneClassSVM)
Klasyfikacja fałszywych opinii	Hugging Face Transformers — DistilBERT, RoBERTa, model HerBERT dla języka polskiego
Generator fałszywych opinii (atakujący)	model LLM otwarto-źródłowy — Bielek v3, Mistral Small 4 lub Llama 4
Zbiory danych referencyjne	Amazon Reviews, Yelp Fake Reviews oraz własne dane wygenerowane lokalnie

Innowacyjność

Wkład pracy obejmuje cztery aspekty. Po pierwsze, jedno z pierwszych systematycznych badań odporności systemu rekomendacji na ataki w kontekście polskiego e-commerce — większość prac akademickich w tym obszarze korzysta ze zbioru MovieLens, który nie odzwierciedla specyfiki rynku zakupowego. Po drugie, mapa porównawcza odporności — wskazanie, która z dziewięciu metod jest najbardziej podatna na atak (intuicyjnie: filtracja kolaboratywna), a która niemal odporna (filtracja oparta na zawartości — atakujący nie może zmienić atrybutów produktu). Po trzecie, badanie skuteczności klasyfikatorów wykrywających opinie generowane przez współczesne modele językowe — to jest aktualnie otwarte pytanie badawcze, zważywszy na dynamiczny postęp jakości tych modeli. Po czwarte, kontekst regulacyjny — Digital Services Act (DSA) z 2022 roku wprowadza obowiązki transparentności rankingów, co czyni temat aktualnym także prawnie.

Aspekt badawczy i eksperymentalny

Hipoteza H1: Filtracja kolaboratywna jest najbardziej podatna na atak shilling — wykazuje najwyższe przesunięcie pozycji produktu-celu po ataku. Filtracja oparta na zawartości jest niemal odporna, ponieważ atak nie zmienia atrybutów samego produktu. Hipoteza H2: Atak typu średniej jest około trzykrotnie trudniejszy do wykrycia niż atak losowy przy tej samej skuteczności manipulacji rankingiem. Hipoteza H3: Hybrydowa strategia łącząca wiele metod (z eksperymentu pierwszego) jest bardziej odporna niż każda z metod osobno — redundancja działa jako naturalny mechanizm bezpieczeństwa. Hipoteza H4: Klasyfikator fałszywych opinii oparty na dostrojonym modelu DistilBERT osiąga wskaźnik F1 powyżej 0,85 na opiniach generowanych przez współczesne modele LLM, mimo ich rosnącej realistyczności.

Plan eksperymentu:

Generator: cztery typy ataków razy pięć poziomów intensywności (jeden, trzy, pięć, dziesięć i dwadzieścia procent fałszywych kont w bazie). Pomiar przesunięcia pozycji produktu-celu w rankingach dziewięciu metod, łącznie sto osiemdziesiąt konfiguracji. Trening klasyfikatora fałszywych opinii: własny zbiór tysiąca prawdziwych opinii z bazy oraz tysiąca opinii wygenerowanych przez model LLM, podział na zbiór treningowy i testowy z walidacją krzyżową. Trening klasyfikatora shilling z wykorzystaniem Isolation Forest na sześciu cechach behawioralnych. Ewaluacja detekcji metrykami Precision, Recall i F1 dla różnych poziomów intensywności ataku. Krzywa odporności — wykres pokazujący, jak rośnie podatność każdej metody wraz ze zwiększaniem intensywności ataku, co umożliwia wybór odpowiedniej metody w warunkach podwyższonego ryzyka.

Literatura

Lam, S. K. & Riedl, J. (2004). Shilling recommender systems for fun and profit. WWW '04.

Mobasher, B., Burke, R., Bhaumik, R. & Williams, C. (2007). Toward trustworthy recommender systems: an analysis of attack models and algorithm robustness. *ACM Transactions on Internet*

Technology, 7(4).

Liu, F. et al. (2024). A Survey on Adversarial Attacks and Defenses for Recommender Systems. *arXiv:2402.18550*.

Mukherjee, A., Liu, B. & Glance, N. (2013). What Yelp Fake Review Filter Might Be Doing? *ICWSM*.

Liu, F. T., Ting, K. M. & Zhou, Z.-H. (2008). Isolation Forest. *ICDM*.

Sanh, V., Debut, L., Chaumond, J. & Wolf, T. (2019). DistilBERT, a distilled version of BERT: smaller, faster, cheaper and lighter. *arXiv:1910.01108*.

Parlament Europejski (2022). Rozporządzenie (UE) 2022/2065 w sprawie jednolitego rynku usług cyfrowych (akt o usługach cyfrowych, DSA).

Rekomendacja końcowa — propozycje konfiguracji tematu

Na podstawie analizy obecnej bazy kodu oraz stanowiska promotora można wskazać trzy spójne ścieżki konfiguracji tematu pracy magisterskiej. Każda z nich łączy kilka powyższych zagadnień w jedną opowieść badawczą o ograniczonym, ale zauważalnym ryzyku wykonawczym i o jednoznacznym wkładzie naukowym.

Konfiguracja A — flagowa (najmocniejszy aspekt badawczy)

Połączenie tematu trzeciego (sieć neuronowa jako meta-learner) z tematem siódmym (wnioskowanie przedziałowe). Spaja akceptowane przez promotora podejście kombinacji metod z silnym wkładem w obszar uczenia maszynowego oraz wnioskowania w warunkach niepewności. Aspekt eksperymentalny obejmuje od dziesięciu do piętnastu hipotez badawczych oraz kilka badań ablacyjnych. Realna jest publikacja konferencyjna w czasopiśmie z obszaru systemów rekomendacji lub logiki rozmytej.

Konfiguracja B — atrakcyjna technologicznie

Połączenie tematu drugiego (modele LLM otwarto-źródłowe) z tematem siódmym (IT2-FLS). Korzysta z aktualności zagadnienia LLM, które promotor sam wskazał jako interesujące, wnioskowanie przedziałowe stanowi natomiast wkład w obszar teorii niepewności. Konfiguracja ta jest również najbardziej aktualna w sensie publikacyjnym — w 2026 roku obszar zastosowań otwarto-źródłowych modeli językowych w rekomendacjach jest intensywnie eksplorowany, a praca z naciskiem na modele polskojęzyczne (Bielik, PLLuM) byłaby wkładem do niszowego, ale szybko rosnącego obszaru.

Konfiguracja C — najbardziej kompletna

Połączenie tematu pierwszego (kombinacja a metody pojedyncze), tematu czwartego (segmentacja użytkowników) oraz tematu siódmego (IT2-FLS). Wszystkie trzy zostały zaakceptowane przez promotora bezpośrednio lub pośrednio. Konfiguracja ta charakteryzuje się największą liczbą eksperymentów oraz jasno postawionymi pytaniami badawczymi, przy ograniczonym ryzyku technicznym — nie wymaga ani głębokiego uczenia, ani uruchamiania dużych modeli językowych, co czyni ją bezpiecznym wyborem przy ograniczonych zasobach obliczeniowych.

Pytania do dalszego przedyskutowania

- Która z trzech zaproponowanych konfiguracji najlepiej odpowiada profilowi badawczemu Pana Promotora oraz wymaganiom programowym kierunku?
- Jakie są oczekiwania co do języka publikacji wynikowej (polski czy angielski) oraz potencjalnej publikacji konferencyjnej lub artykułowej powstałej na bazie pracy?
- Czy dostępne są zasoby obliczeniowe (karty graficzne, czas na klastrze obliczeniowym) niezbędne do tematów obejmujących duże modele językowe lub trenowanie sieci neuronowych?
- Czy przewidywany harmonogram pracy magisterskiej dopuszcza tematy o większym ciężarze implementacyjnym (na przykład temat ósmy obejmujący dwa odrębne

klasyfikatory)?

- Czy promotor widzi celowość uwzględnienia w wybranym temacie aspektu związanego z modelami polskojęzycznymi (Bielik, PLLuM), który mógłby wzmocnić lokalny charakter pracy?